

L'ENCYCLOPÉDIE DES BIG DATA 2016


55

IBM

pwc

TURN

ebg
electronic
business group



PRÉAMBULE

Interrogez des DSI ou des Directeurs Digitaux sur ce que représentent pour eux les « Big Data » : la moitié d'entre eux vous en parlera comme de la clé de voûte de leur stratégie d'innovation, l'autre moitié vous regardera de travers et rejettera l'expression comme un buzzword nébuleux, forgé par les éditeurs à des fins strictement commerciales. Pour le grand public, le terme est couramment associé à Google, Facebook et consorts et à l'idée que ces géants du numérique savent tout sur notre vie et pourraient bien un jour nous renvoyer en 1984.

Bref, le besoin de clarification était criant.

Il n'est pas certain que, de cet ouvrage, les réfractaires sortent convaincus, ni que les aficionados y retrouvent exactement leur vision. Avec cette Encyclopédie nous avons tenté de définir un objet multiple et mouvant, qui évolue avec les moyens technologiques et les pratiques de ceux qui le construisent. C'est pour cette raison que nous avons associé à cette démarche trente pratiquants des Big Data, dont les témoignages nous ont paru indispensables pour expliquer concrètement les notions rassemblées ici. C'est pour cela aussi qu'il ne faut pas voir ce lexique comme une base de connaissances consolidées pour la postérité, mais comme un bilan d'étape d'une transformation en cours, une incitation à la réflexion.

Nous avons largement profité dans cette entreprise des excellents conseils de nos quatre partenaires (Fifty-Five, IBM, Turn et PwC) sans lesquels ce projet et les nombreux événements de la Commission Big Data n'auraient pas pu voir le jour. Merci également aux contributeurs qui ont eu la gentillesse de nous recevoir dans leurs locaux et de partager leurs idées et leurs retours d'expérience avec nous. Merci à vous enfin, qui avez pris le temps d'ouvrir ce petit livre au lieu de vous consacrer à votre travail ou à vos enfants.

Arthur Haimovici
EBG

SOMMAIRE

PRÉAMBULE P.1

INTRODUCTION P.4

1 GRANDS CONCEPTS P.7

3V P.8

ALGORITHME P.10

CROWDSOURCING P.14

DATA PRIVACY P.16

DATA VISUALIZATION P.20

MACHINE LEARNING P.22

MAINTENANCE PRÉDICTIVE P.26

OBJETS CONNECTÉS P.29

OPEN DATA P.31

SÉCURITÉ DES DONNÉES P.32

SMART DATA P.35

TEMPS RÉEL P.38

VALEUR P.40

VARIÉTÉ P.41

VÉRACITÉ P.44

VITESSE/VÉLOCITÉ P.46

VOLUME P.48

WEB 3.0/WEB 4.0 P.50

2 TRANSFORMATION DE L'ENTREPRISE P.53

CHIEF DATA OFFICER P.54

CNIL P.57

DATA DRIVEN ORGANISATION P.59

DATA GOUVERNANCE P.62

DATA SCIENTIST P.65

DÉSILOTAGE P.69

MODE AGILE P.73

TEST & LEARN P.75

3 ASPECTS TECHNIQUES P.79

A/B TESTING P.80

AD EXCHANGE P.83

API P.84

CLOUD DATA SERVICES P.87

DATA MINING P.90

DATA WAREHOUSE P.92

LOOK-ALIKE MODELING P.93

MASTER DATA MANAGEMENT P.96

MODÈLES D'ATTRIBUTION P.99

OPT-IN P.102

RTB P.105

SCRAPING P.109

TEXT MINING P.110

THIRD PARTY DATA / FIRST PARTY DATA P.113

TRACKING P.117

TRAITEMENT AUTOMATIQUE DU LANGAGE NATUREL P.119

4 OUTILS P.123

ARBRE DE DÉCISION P.124

CLUSTER P.126

DATA LAKE P.127

DMP P.131

DPI P.135

ETL P.136

HADOOP P.138

LANGAGE R P.142

MAPREDUCE P.144

PYTHON P.145

RÉSEAU DE NEURONES P.147

SPARK P.149

TAG MANAGEMENT SYSTEM P.152

YARN P.154

CONCLUSION P.156
CONTRIBUTEURS P.159
PARTENAIRES P.177



Signe d'un engouement croissant pour le sujet, les ouvrages consacrés au phénomène Big Data ont fleuri au cours des dernières années. Il y a, bien sûr, la cohorte des manuels pratiques destinés aux professionnels, qui s'attardent à explorer un aspect en particulier de cet immense champ nouveau, en le rattachant à des aspects très orientés business, ou en s'attaquant à son versant technique. Mais il y a aussi, de plus en plus, ces livres destinés au grand public, et qui tentent de décrypter - en les « dramatisant » bien souvent - les nouveaux enjeux de ce qu'ils présentent comme une révolution. Entre ces deux catégories, l'une ancrée dans les usages métiers, à fort degré de technicité - et par la force des choses très jargonnante - l'autre ouverte à l'analyse et à la prospection quand ce n'est pas aux fantasmes, il n'existe en réalité pas vraiment d'intermédiaire. S'il n'entend évidemment pas combler à lui seul un tel vide, l'ouvrage que vous vous apprêtez à lire a néanmoins la prétention de se placer exactement dans cet interstice. Pour cela, il a décidé de s'appuyer sur l'expérience d'une trentaine d'acteurs majeurs du monde des Big Data. Directeurs scientifiques ou marketing, chief data officers, data scientists, professeurs, consultants : ils ont partagé avec nous non seulement des cas concrets auxquels l'importance croissante des données massives au sein des entreprises les confrontent de plus en plus. Mais aussi une vision globale de ce nouveau sujet, faite d'enjeux à courts terme et de perspectives plus lointaines. Leurs témoignages, campés dans la réalité de leur business, sont le fil rouge de ce livre.

Quant à la forme de ce dernier, elle est assez classique, mais s'impose pour espérer traiter, dans ses grandes largeurs, d'un sujet aussi vaste. C'est celle d'un dictionnaire, d'une encyclopédie, oserons nous dire. Nous avons regroupé ici les termes qui sont revenus le plus souvent dans la bouche de nos interlocuteurs pour parler de Big Data. Et nous leur avons donné une définition, ni rigoureusement technique, ni éminemment conceptuelle, mais enracinée dans l'expérience. Ces quelque soixante entrées

se répartissent en quatre grandes catégories, au sein desquelles ils sont classés par ordre alphabétique. La première partie est celle des grands concepts qui se rattachent au Big Data, et l'on y trouvera des notions aussi variées que le machine learning, la data privacy, ou les objets connectés. La seconde s'intéresse aux impacts que peuvent avoir les données massives sur la structure même des entreprises, et aux transformations à l'œuvre dans ces dernières : désilotage, nouveaux modèles d'attribution, mise en place d'une data gouvernance, etc. La troisième est dédiée aux aspects techniques (et ils sont nombreux !) qui accompagnent les projets Big Data, qu'on pense tracking, A/B testing, ou traitement automatique du langage naturel. Enfin, la dernière partie regroupe les outils les plus couramment utilisés pour se lancer dans le traitement massif de la donnée, depuis les langages Python ou R, jusqu'aux solutions Spark, YARN ou Hadoop.

Signalons que tous ces mots s'inscrivent dans un écosystème complexe qui tisse entre eux une multitude de liens... si bien qu'il est illusoire de s'attacher à développer chacun en faisant abstraction des autres. Voilà pourquoi vous trouverez souvent, dans les entrées de ce dictionnaire, des termes qui font l'objet ailleurs d'un paragraphe spécifique, et qui sont signalés par un système de renvoi. Dans la version papier de cet ouvrage, ces termes ont été surlignés en couleur. Dans la version numérique, ils sont cliquables sous la forme de lien hypertexte pointant vers leur définition.

Les définitions de cet ouvrage ne prétendent pas à l'exhaustivité, et beaucoup de nos lecteurs en connaîtront sans doute déjà l'essentiel. Ils trouveront pourtant dans chacune, nous en sommes sûrs, de nouvelles perspectives, de nouveaux éclairages, et peut être aussi parfois, quelque fait, quelque anecdote qui aura échappé à leur connaissance. Et puis, dans tous les cas, pour s'y retrouver dans un secteur aussi dense et complexe que celui des Big Data, avoir à portée de main un recueil de mots intelligibles et clairs, ne peut être qu'une bonne idée !

1. GRANDS CONCEPTS

En prenant conscience de l'importance grandissante qu'allaient être amenées à jouer les Big Data, les entreprises se sont retrouvées confrontées à une foule de grandes notions, aux contours flous, dont il s'agit désormais de tirer parti. Algorithmes, Smart Data, temps réel, objets connectés... La maîtrise de ces nouveaux domaines riches en promesses passe d'abord par la compréhension de ce que les Big Data impliquent d'un point de vue business.

3V*

* Volume, Variété, Vitesse

Pour tenter de donner un cadre théorique à la data revolution, qui pointait déjà, au tournant des années 2000, le bout de son nez, Doug Laney, analyste chez META Group (une société américaine de conseil et d'audit rachetée entre temps par Gartner) propose en 2001, un modèle d'interprétation qui a fait, depuis, florès : les 3 V, c'est-à-dire **Volume**, **Variété**, et **Vitesse**. Efficace et simple à comprendre, ce résumé des trois variables caractéristiques du Big Data a par la suite été repris par les consultants du monde entier. Mieux : malgré les évolutions considérables qui agitent le monde de la donnée, il se montre toujours capable d'en saisir la substantifique moelle. Représentant ce modèle devenu classique, **Samir Amellal (Publicis Worldwide)** livre ainsi cette interprétation :



Le Volume et la Variété sont une conséquence directe de la digitalisation. Ils sont en quelque sorte subis. Ces deux premiers "V" induisent une nécessité, la Vélocité, qui constitue le troisième.

Publicis Worldwide
Samir Amellal



« Quand on parle Big Data, on va tout de suite parler volume de données. Mais au delà du volume, rien que la variété de ces dernières va constituer un enjeu crucial, ce phénomène est amplifié par l'avènement des objets connectés. »

Orange Technocentre
Tania Aydenian

Pour rendre plus pertinente et plus actuelle cette analyse tricéphale, certains acteurs peuvent ressentir le besoin d'y ajouter un ou deux autres V (à savoir la **Véracité** et la **Valeur**). On parlera alors des 5V du Big Data. Mais peu importe, en réalité, le nombre de critères. L'important pour une entreprise va surtout consister à déterminer lequel revêt le plus d'intérêt pour elle, en fonction de ses propres spécificités. Rares en effet sont aujourd'hui les acteurs à être concernés à valeur égale par chacun des 5 V. Chez Orange Datavenue, plateforme dédiée à la collecte, au stockage et à l'agrégation de données, c'est par exemple sur le terme de Variété que l'on met l'accent avant tout.

ALGORITHME

Si le Big Data était un organisme vivant, la donnée en constituerait le sang, et les algorithmes... le cerveau. Cette méthode mathématique de résolution de problèmes est le moteur de l'intelligence artificielle. Elle consiste en la description, dans un langage de programmation, d'une suite finie d'étapes qui, à partir de données en entrée, livre des données en sortie, en vue d'un objectif prédéterminé. Les algorithmes utilisés en informatique exécutent ainsi des tâches définies par un humain, mais à des vitesses infiniment plus rapides que ce dernier, rendant possible la réalisation de calculs inenvisageables auparavant. La montée en puissance des ordinateurs permet de faire tourner des algorithmes de plus en plus complexes, qui vont intervenir dans des domaines aussi variés que le routage de l'information, l'optimisation de l'usage des ressources, la prédiction, le machine learning, etc... Face à un éventail aussi large, il s'agit pour les entreprises de trouver le bon cas d'usage, susceptible de leur apporter de la valeur... Et qui correspondent aussi, souligne Elisabeth Zehnder (Kiabi), aux attentes des métiers :

Les algorithmes vont nous permettre de cibler nos clients, de mesurer l'adéquation entre clients et produits. C'est un mot qui résonne donc côté métier, et il faut vraiment que leur mise en place corresponde à un besoin métier troisième.”



Kiabi
Elisabeth Zehnder

Avec l'augmentation radicale des **volumes** de données, certains algorithmes, qui n'avaient auparavant qu'une existence théorique, finissent par susciter un vrai intérêt de la part des entreprises, et par s'incarner dans des projets concrets. C'est le cas des algorithmes de recommandation, dont nous parle **Angélique Bidault-Verliac** (**Voyages-sncf.com**) :



Voyages-sncf.com
Angélique Bidault-Verliac
Responsable du Pôle Data & Webmining



“ Les algorithmes de recommandation, pour lesquels il existait déjà une abondante littérature scientifique, n'ont commencé à trouver chez nous des débouchés concrets que très récemment. Leur mise en place a nécessité la levée de certaines difficultés, grâce à une démarche innovante. Il s'agissait en effet de recommander à nos internautes des voyages, en s'appuyant sur leurs recherches. Pour cela, il fallait être capable d'interroger non pas une dimension unique (l'internaute voit un produit, le moteur lui en suggère un autre qui est lié), mais deux dimensions (le point de départ du voyage, et la destination à recommander). ”

Même si les algorithmes ne font « que » exécuter des tâches qui leur sont confiées par des humains, le fait qu'ils constituent souvent des solutions techniques proposées par des prestataires extérieurs peut donner l'impression, à certains acteurs, de perdre le contrôle sur leur usage. D'où le besoin, souligné par **Geoffrey Zbinden (Orange)**, de reprendre la main :



Le risque principal lorsqu'on se met à faire tourner des algorithmes achetés à des partenaires extérieurs, c'est que ceux-ci fonctionnent entièrement comme des *blackboxes*. On ne peut pas se contenter d'acheter l'algorithme, il faut aussi maîtriser son fonctionnement, et maîtriser la donnée qu'il utilise. L'enjeu du Big Data, c'est moins la partie IT que l'optimisation de ce type de solutions.



Orange

Geoffrey Zbinden

Vice President Big Data Analytics
& Customer Base Management



“Les algorithmes sont devenus un des outils de travail quotidiens du marketing. Ils permettent une compréhension plus fine des consommateurs et notamment des internautes, des mobinautes. Grâce à la vitesse de calcul disponible aujourd’hui et aux APIs, ils produisent une information précieuse qui est actionnable immédiatement. Nous avons par exemple développé un algorithme visant à automatiquement ajuster l’ordonnancement des produits dans les listes de sites de e-commerce : cela rend service à l’utilisateur en lui affichant le contenu le plus judicieux, tout en permettant au e-commerçant d’augmenter ses taux de conversion. Notre solution est basée sur un algorithme de machine learning, cela implique qu’elle s’affine avec le temps à mesure que de la donnée est emmagasinée : l’algorithme apprend de lui-même, et sa performance est à tout instant mesurable via une logique d’A/B test. L’algorithme permet donc de transformer la donnée brute en information précieuse dans le but d’une optimisation. Recommander du contenu plus pertinent ou optimiser l’affichage d’une page web grâce à un algorithme... l’automatisation a ses limites : l’algorithme n’est pas une solution miracle pour le tout venant. S’il se décompose en une suite de calculs que la machine opère plus rapidement que l’homme, pour être et rester efficace, il doit être supervisé par un data scientist et se nourrir d’un volume de données suffisant, mais surtout, il doit refléter une réalité métier spécifique et être construit dans le but de remplir un objectif précis.”

Romain Warlop
Data Scientist
55



CROWDSOURCING

Faire appel à la foule, à la collectivité, pour réaliser des tâches habituellement réalisées par des individus isolés : voilà une idée totalement en phase avec une conception ouverte et innovante de la donnée. L'idée directrice du crowdsourcing, c'est que la mise en commun des intelligences et des savoir-faire va permettre l'émergence de connaissances qui n'auraient pas pu voir le jour autrement.



Intel
Marie-Christine Sawley
Exascale Lab Director



Le crowdsourcing est la traduction IT des « petits ruisseaux qui font de grandes rivières ». Ce concept - matérialisé par exemple par la croissance de la base de connaissances Wikipédia ou par le guidage en temps réel Waze - a pris beaucoup d'ampleur au cours des dernières années. Ceci change la donne sur la fréquence et l'impact des informations recueillies par les entreprises auprès de clients ou utilisateurs finaux. Le crowdsourcing risque aussi de redéfinir en interne les vecteurs par lesquels la base peut remonter les idées pour l'innovation des produits et services. ”

Les technologies Big Data, en permettant la mise en commun de sources de données toujours plus grandes, et en ouvrant surtout la perspective de traitement en temps réel joue le rôle de facilitateur pour les projets de crowdsourcing, comme le constate **Aroua Biri (Sogeti)** :

“ Le Big Data sert d'accélérateur au crowdsourcing, en donnant une nouvelle envergure aux projets mis en oeuvre. Ces derniers ont souvent des difficultés en terme de synchronisation des différentes contributions : comment les mettre de concert, comment les traiter au mieux ? Le Big Data va permettre d'automatiser beaucoup de choses, tout en rendant les processus plus rapides. Il va ainsi agir comme un catalyseur du crowdsourcing, en permettant d'en tirer de mieux en mieux profit. Il va aussi permettre la démocratisation de cette pratique. On peut désormais penser grand, et avec peu de budget, grâce notamment aux offres de Big Data dans le cloud. ”

Sogeti | Aroua Biri

Architecte Cybersécurité & Big Data



Pour les entreprises, le crowdsourcing constitue un univers nouveau propice à l'exploration. A la SNCF, plusieurs projets faisant appel à l'intelligence des foules ont ainsi vu le jour ces dernières années. Voici deux d'entre elles :



SNCF | Maguelonne Chandesris

Responsable de l'équipe Innovation
& Recherche «Statistique, Econométrie et Datamining»



“ Nous avons lancé plusieurs projets qui s'appuient sur une forte composante crowdsourcing. <http://garantiedesgares.com/> permet par exemple aux usagers de nos gares de nous signaler en direct des dysfonctionnements. Ce genre d'initiative a un impact direct sur notre entreprise. Ma conviction c'est que derrière les Big Data, il y a, outre la technique, des aspects humains très forts, liés à notre façon d'appréhender notre métier. ”

Suite à un Hackathon, nous avons également développé en partenariat avec une startup une application, *Tranquillien*, qui permet de localiser le prochain train dans lequel il y a suffisamment de place pour s'asseoir. C'est un système qui s'appuie massivement sur du crowdsourcing, dans la mesure où ce sont les utilisateurs eux mêmes qui ajoutent des indications en temps réel sur l'état des trains. ”

DATA PRIVACY

Jusqu'où une entreprise peut-elle aller dans l'exploitation des données personnelles qu'elle récolte? Et corollaire : la loi en vigueur doit-elle être le seul cadre limitatif à ses ambitions? Répondre à ces interrogations, qui ne peuvent manquer d'apparaître dès lors qu'une entreprise monte en maturité sur le sujet des datas, est une nécessité autant qu'une urgence, puisqu'elles touchent directement à des questions légales de respect de la vie privée, bien sûr, mais aussi de la confiance des utilisateurs/des clients, envers une marque. Relever un tel défi suppose de mettre en place une politique solide et claire de data privacy, et donc de définir un ensemble de règles encadrant l'usage des données personnelles. Encore faut-il être en mesure de définir d'abord ce que recouvre une telle notion, par nature mouvante!



La data privacy est un challenge que je rencontre souvent, et qui va être de plus en plus prégnant avec le développement des technologies Big Data qui exacerbe les problématiques autour de la donnée. Lorsque des entreprises mettent en place des infrastructures et des démarches Big Data, elles sont amenées à stocker des données personnelles - parfois même sans le faire exprès! Il va d'abord falloir pour elles qualifier ce qui relève ou non de la donnée personnelle, ce qui est loin d'être évident, car la Big Data rend floue cette notion même. Les courbes de charge - composées par la consommation électrique suivant un pas de mesure - remontées par les compteurs intelligents, par exemple, sont considérées comme des données personnelles, ce qui n'est pas évident à première approche.



Sogeti
Aroua Biri
Architecte Cybersécurité & Big Data

De manière évidente, la première des règles en terme de data privacy, c'est le respect des lois en vigueur encadrant la protection de la vie privée et le droit à l'oubli. Pas question de transiger sur ce point, surtout sur un sujet aussi sensible, voilà ce que clame Marie-Laure Cassé (**Voyages-sncf.com**) :

“ La notion de respect des lois et des réglementations en vigueur doit primer aussi bien au moment de la collecte des données que de leur exploitation afin de préserver les droits et les libertés de nos clients. Chez Voyages-sncf.com, nous rendons anonymes les données personnelles pour toute analyse Big Data. Les Directions juridiques et sécurité encadrent ce processus de façon très stricte. ”



Voyages-sncf.com | Marie-Laure Cassé
Directrice Marketing Client & Data

Mais une telle démarche legaliste n'est pas toujours évidente à mettre en place pour des entreprises implantées dans plusieurs pays. La sensibilité culturelle autour de la donnée personnelle, et les arsenaux juridiques qui en découlent varient en effet d'une géographie à l'autre, comme l'expliquent **Geoffrey Zbinden (Orange)** et **Mathieu Escarpit (Oney Banque Accord)** :

“ En Italie, les contraintes légales autour de la donnée sont encore plus fortes qu'en France. Pour un programme de fidélité par exemple, il faut que le client signe pratiquement quatre fois le formulaire d'inscription. On ne peut pas non plus détenir un historique de plus de deux ans sur certains types de données et selon l'usage que l'on souhaite en faire. Alors qu'en Angleterre, notamment, il n'y a pas de date limite d'exploitation des données tirées de programme de fidélité. Ces restrictions empêchent, dans certains pays, de tirer profit au maximum des outils de Big Data. ”

**À ROME
TRAITE TA DATA
COMME
LES ROMAINS**



Oney Banque Accord | Mathieu Escarpit
Directeur Général Italie et Joias

“ Les contextes législatifs sur la data privacy varient du tout au tout d'un pays à l'autre. En Europe, on est extrêmement sensibles à tout ce qui touche à l'utilisation des données, et certaines pratiques peuvent être rapidement associées à de la violation de vie privée. Récemment, un projet qui consistait à vendre des données pour piloter des implantations commerciales a été arrêté en Allemagne, parce qu'on a considéré qu'il fallait nécessairement récolter l'assentiment du client - y compris pour des données anonymisées. ”



Orange | Geoffrey Zbinden
Vice President Big Data Analytics
& Customer Base Management

Une politique de Data privacy efficace ne peut pourtant se limiter à un respect scrupuleux de la loi en vigueur. Elle va devoir aussi prendre en compte la sensibilité des clients sur le sujet délicat des données personnelles. La construction d'un rapport de confiance en dépend, comme on juge bon de le rappeler chez Orange et ailleurs :

“ Orange cherche à mettre en place un modèle de confiance vis-à-vis du client concernant l'usage qui sera fait de ses données. L'idée derrière ce Data Privacy Dashboard : demander au client son autorisation pour utiliser ses données non afin de les vendre en externe, mais pour lui offrir un aperçu en temps réel de l'usage qui est fait de sa data. On pourrait ensuite imaginer une sorte de « mode invisible » qu'il suffirait au client d'activer pour bloquer instantanément toute utilisation de sa donnée. ”



Orange
Geoffrey Zbinden
Vice President Big Data
Analytics & Customer Base
Management

DE LA CONFIANCE AVANT TOUTE CHOSE

“ Notre position est simple : le consommateur est propriétaire de sa donnée. Il doit donc donner explicitement son consentement pour qu'elle soit partagée avec un tiers. En sachant qu'il se montre en général plutôt ouvert à ce consentement s'il obtient en contrepartie un service digne de ce nom et une bonne connaissance de l'usage qui sera fait de sa data. Créer un tel cercle vertueux autour du consentement suppose donc à la fois un rapport gagnant gagnant, et une grande limpidité. ”



Orange Technocentre
Tania Aydenian
Directrice du Programme
Datavenue

“ Le grand enjeu de la data privacy, c'est à la fois de respecter l'intimité des citoyens tout en ayant les coudées suffisamment franches pour lutter contre les GAFA... qui ont moins de scrupules sur l'usage de la donnée. ”



AccorHotels group | Fabrice Otaño



JURIDIQUE

Hoche Avocats

« Dès lors qu'elles constituent une donnée à caractère personnel, c'est-à-dire qu'elles constituent une "information relative à une personne physique identifiée ou qui peut être identifiée, directement ou indirectement, par référence à un numéro d'identification ou à un ou plusieurs éléments qui lui sont propres" (art. 2 de la loi Informatique et Libertés), leur protection de leur traitement relève d'une obligation légale.

Le responsable du traitement est tenu de prendre toutes précautions utiles, au regard de la nature des données et des risques présentés par le traitement, pour préserver la sécurité des données et, notamment, empêcher qu'elles soient déformées, endommagées, ou que des tiers non autorisés y aient accès (art. 34 de la loi Informatique et Libertés). Les mesures de sécurité sont d'ordre physique (sécurité des locaux), logique (sécurité des systèmes d'information) et doivent être adaptées à la nature des données et aux risques présentés par le traitement.

Le non respect de cette obligation de sécurité est sanctionné de 5 ans d'emprisonnement et de 300.000 € d'amende (art. 226-17 du code pénal).

Les données à caractère personnel doivent en outre être collectées et traitées de manière loyale et licite, pour des finalités déterminées, explicites et légitimes et ne doivent pas être traitées ultérieurement de manière incompatible avec ces finalités (art. 6 de la loi Informatique et Libertés).

Le respect de ces obligations peut s'avérer complexe dans le cadre de projets "Big Data" dès lors par exemple que des données apparemment anonymisées peuvent par recoupement permettre d'identifier indirectement un individu et que les finalités des traitements évoluent au gré des nouveaux projets et marchés des entreprises. »



Hoche Avocats
Régis Carral
Avocat – Associé

DATA VISUALIZATION

Rendre clairement interprétable une masse de données en la représentant de façon simple et exhaustive sous la forme d'objets visuels (graphs, tableaux, successions de points), voilà le précepte directeur de la data visualization. Dans un cadre aussi complexe et ardu que celui du Big Data, on comprend qu'une telle ambition ait pu prendre la forme d'une panacée. Et qu'une multitude de solutions aient fait leur apparition sur le marché, promettant aux utilisateurs de rendre leurs données claires comme de l'eau de roche, grâce à la magie des images. Attention cependant de ne pas se laisser leurrer par le côté gadget de certains outils de dataviz. Pour avoir une vraie valeur, et servir véritablement les métiers, ces derniers doivent répondre à deux mots clefs : la simplicité et l'exhaustivité.

“ Nous avons lancé plusieurs POC pour trouver le bon outil de dataviz, avant de nous arrêter sur la solution éditée par Tableau Software. L'idée était d'avoir un outil accessible au plus grand nombre, capable de mettre à disposition la donnée des métiers en leur permettant de l'explorer de façon autonome, en étant le moins tributaires possibles de la DSI et de développements spécifiques. L'intérêt de la dataviz va être de montrer la valeur des données, de mettre l'accent sur certains éléments qui apparaîtront de façon claire et évidente. ”

Kiabi
Elisabeth Zehnder
Data Scientist



GARDER UN ŒIL SUR SES DONNÉES

“ Il y a deux ans, nous avons mis en place des solutions de data visualization, sur lesquelles se connectent environ 10 000 users, et représentant aujourd'hui à peu près le même volume que la BI traditionnelle. Cela constitue une offre BI complémentaire fournissant une BI agile, mais aussi une solution de prototypage. ”

Schlumberger
Olivier Brousseau
IT Business Intelligence
Strategy Manager



Enfin, même si les solutions de data visualization doivent se ranger au service de la simplicité, il ne faut pas croire que leur mise en œuvre est une promenade de santé. Pour qu'elles soient efficaces, il est nécessaire de procéder à un important travail préparatoire, comme l'indique **Mathieu Escarpit (Oney Banque Accord)** :

“ Le travail en amont de définition des KPI est une phase fondamentale pour profiter à plein de la data visualization. Le dernier outil de dataviz que nous avons mis en place a ainsi nécessité quatre mois de travail en amont sur la qualité du reporting, la définition des KPI, les ajustements après feedback... alors que le développement dans l'outil et son déploiement ont pris seulement un petit mois. ”

Oney Banque Accord | Mathieu Escarpit
Directeur Général Italie et Joias



“ Les outils de data visualization sont une nouvelle génération d'outils permettant de combler certaines lacunes des outils de Business Intelligence. Plus agiles, plus interactifs, et davantage opérables dans de multiples environnements de données, ils permettent d'aborder les tâches de fouille de données de nouvelles façons. Les données sont chargées en mémoire et la modélisation effectuée en amont facilitent les opérations de filtrage et d'agrégation. La conception des vues graphiques où la navigation est effectuée en profondeur (*deep dive* dans les données) permet une grande souplesse dans l'extraction des informations clé de pilotage.

Rapidement appréhendables pour de premières investigations, il s'avère nécessaire d'utiliser des compétences de UX design pour tirer la plus grande valeur de ces outils et des données représentées.

Grâce à ces outils, les données métiers des entreprises sont facilement analysées et les décisions business peuvent être réalisées en fonction des états d'indicateurs objectifs (*fact based*). La publication et la diffusion de rapports synthétiques, interprétables par les fonctions métiers permettent une plus grande transparence dans l'organisation. On parle d'organisation guidée par les données (*data-driven*). ”

Marc Damez-Fontaine
Senior Manager | **PwC**



MACHINE LEARNING

Ce processus d'automatisation de l'apprentissage (on parle d'ailleurs en bon français, d'apprentissage statistique) fait appel à des logiques d'intelligence artificielle pour mettre une machine en capacité d'assimiler elle-même des modèles à partir des données auxquelles elle a accès. Il ne s'agit donc plus de spécifier à l'avance un modèle de comportement, mais de laisser à des **algorithmes** le soin de construire eux mêmes ce dernier, en allant piocher dans un très large dictionnaire de modèles potentiels. Avec le machine learning, certains systèmes vont ainsi pouvoir améliorer leur performance prédictive, optimiser leur fonctionnement général, et gagner en clarté dans leur mode de représentation de la donnée.



Biométrie, prédiction des anomalies dans un système complexe, scoring, moteurs de recommandation et moteurs de recherche... Le nombre d'applications du machine learning ne cesse de croître, à mesure que la quantité de données mobilisables augmente.



Télécom-ParisTech
Stéphane Cléménçon
 Professeur et Responsable
 du Mastère Spécialisé Big Data



Se lancer dans le machine learning suppose toutefois de faire, d'une certaine façon, confiance à la machine, et de la laisser fonctionner en aveugle, sans être capable d'interpréter clairement son travail. Certains business et certaines structures d'entreprises se montrent plus propices que d'autres lorsqu'il s'agit de faire ce genre de concession, constatent **Christèle Baranco (LCL)** et **Jonathan Badoux (AXA France)** :

“ On a souvent tendance à opposer le modèle statistique et le machine learning, plus complexe et informatique. L'intelligence artificielle et tout ce que l'on peut en faire, ce n'est pas quelque chose que l'on avait l'habitude d'utiliser dans les métiers du marketing. Auparavant, on cherchait à obtenir des scores, qui soient utilisables concrètement par le métier final (scoring autour de l'appétence par exemple, sur des modèles de régression logistique). Depuis trois/

quatre ans, ce qui change, c'est la mise en place, parallèlement à cette logique, de techniques de machine learning qui supposent de faire confiance à la machine, et aux résultats qu'elle obtiendra. Maintenant que le temps réel est devenu une notion cruciale pour les entreprises, celles-ci vont de plus en plus accepter de moins comprendre sur quelles variables se font les calculs qu'opèrent la machine, pour se concentrer sur les résultats de ceux ci. ”

CES ROBOTS NOUS VEULENT-ILS DU BIEN ?

“ Le machine learning est un élément nouveau de la transformation digitale des entreprises. Accepter de laisser une machine effectuer une recommandation et donc de sortir des idées marketing préconçues et 100% maîtrisées n'est pas simple

à gérer dans un marché où chaque acteur souhaite contrôler parfaitement son discours avec ses prospects/clients.

Il faut donc passer par de l'éducation des équipes sur le fonctionnement de ces algorithmes afin que chacun puisse utiliser à bon escient les réponses proposées par ces mêmes algorithmes. ”



AXA France
Jonathan Badoux
Responsable
Outils Digitaux



LCL
Christèle Baranco
Responsable Analyse
de la Donnée Client

Rendre interprétables par l'entreprise les progrès que font, dans leur coin, les machines, voilà l'un des grands enjeux du machine learning. Dans le secteur des telecoms, l'invention du Net Promoteur Score doit justement servir ce délicat objectif :



Bouygues Telecom
Nicolas Gaude
Senior Data Scientist



Avec le machine learning, les machines apprennent, via différents outils mathématiques (réseaux de neurones, *random forest*, *gradient boosting*) à s'approcher le plus près possible de l'objectif qui leur est attribué. L'inconvénient, c'est que la façon dont on va influencer sur la mesure n'est



plus lié à un ou deux éléments clés (par exemple la satisfaction du client, le temps de réactivité avant la résolution d'un problème, bref, des métriques en interne), mais à une combinaison non linéaire de variables qui n'ont plus aucun sens explicatif (lignes de code produites, puissance consommée par le datawarehouse, etc). Voilà pourquoi, pour rattraper le management, nous sommes contraints de créer des indicateurs composites qui vont incarner la performance (un peu comme le CAC 40 reflète la santé économique de l'industrie française). Le Net Promoter Score par exemple est ainsi, dans le domaine des telecoms, un indicateur composite accepté et approprié au management en ce qu'il permet refléter la capacité qu'a une marque à être recommandée par un individu lambda.



Romain Warlop
Data Scientist
SS

plus lié à un ou deux éléments clés (par exemple la satisfaction du client, le temps de réactivité avant la résolution d'un problème, bref, des métriques en interne), mais à une combinaison non linéaire de variables qui n'ont plus aucun sens explicatif (lignes de code produites, puissance consommée par le datawarehouse, etc). Voilà pourquoi, pour rattraper le management, nous sommes contraints de créer des indicateurs composites qui vont incarner la performance (un peu comme le CAC 40 reflète la santé économique de l'industrie française). Le Net Promoter Score par exemple est ainsi, dans le domaine des telecoms, un indicateur composite accepté et approprié au management en ce qu'il permet refléter la capacité qu'a une marque à être recommandée par un individu lambda.



Des machines de plus en plus apprenantes

L'apprentissage artificiel (ou apprentissage automatique, « machine learning » en anglais) est une famille d'algorithmes dont l'objectif est la détection automatique de motifs dans un jeu de données, sans connaissance a priori sur ces données. Ces motifs forment un modèle et l'application de ce modèle à d'autres jeux de données permet de prédire un comportement. On appelle cela la capacité de généralisation du modèle d'apprentissage.

Un algorithme d'apprentissage artificiel imite l'apprentissage humain dans sa capacité à reconnaître des comportements similaires lors d'expériences successives.

Il existe deux familles d'algorithmes d'apprentissage : supervisé et non-supervisé. La première est utilisée lorsque l'algorithme construit un modèle sur une variable de sortie particulière (ex : quel est le prochain article que mon client va acheter ?) alors que la deuxième effectue une découverte sans objectif (ex : que dit-on de mon entreprise sur les réseaux sociaux ?). Un algorithme d'apprentissage artificiel sera performant si et seulement si le nombre d'expériences (de données) est important et si la description des expériences (propriétés des données) sont significatives au regard de la tâche d'apprentissage.

Une description appropriée de l'événement est un point crucial de la qualité de l'apprentissage.

Les méthodes d'apprentissages les plus modernes telles que l'apprentissage profond (*deep learning*) sont capables d'extraire automatiquement les meilleurs caractéristiques descriptives des événements (propriétés) si les données sont suffisamment nombreuses. ”

Le scoring ouvre les portes de la prédiction

Les méthodes de scoring sont un sous-ensemble des méthodes de machine learning. Bâtir un score consiste à exécuter un algorithme sur une base de données pour extraire un score de prédiction permettant de prédire un comportement futur des individus de la base. Par exemple, le score d'un client peut refléter ses intentions d'achat, ou ses intentions de quitter un service (*churn*). Les enjeux de généralisation et robustesse d'un modèle de scoring permettent de garantir que le modèle peut scorer correctement de nouveaux jeux de données ou des périodes futures d'activité. Les méthodes de scoring possèdent 2 caractéristiques particulières. La première consiste à observer la distribution des scores. Ainsi, un palier ou une chute importante du score permet de cibler la quantité d'individus susceptibles de répondre correctement au modèle prédictif. On peut ainsi estimer plus facilement la pertinence d'un budget au regard d'une campagne de communication. La deuxième caractéristique est l'ordre induit par un algorithme de scoring. En effet, les individus ayant un score plus élevé sont plus facilement prédictibles que les individus ayant un score plus faible. ”

Marc Darnez-Fontaine
Senior Manager
PwC



MAINTENANCE PRÉDICTIVE

Aussi appelée maintenance prévisionnelle, cette nouvelle façon de concevoir l'optimisation des outils industriels est l'un des cas d'usage les plus prometteurs du Big Data. Il va s'agir, comme son nom l'indique, d'anticiper les pannes et les dégradations susceptibles de survenir sur une machine pour pouvoir les gérer en amont, et donc améliorer la durée de vie de l'appareil en question, réduire ou supprimer les temps d'immobilisation pour réparation, et faire baisser les coûts d'entretien et d'intervention. De tels bénéfices vont être rendus possibles par la capacité de ces outils industriels à faire remonter une foule de données grâce à leur informatique embarquée. Et surtout, comme le souligne **Stéphane Cléménçon (Télécom-ParisTech)**, par le traitement de plus en plus fin de ces informations grâce aux technos Big Data :



Télécom-ParisTech
Stéphane Cléménçon
 Professeur et Responsable
 du Mastère Spécialisé Big Data



La maintenance prédictive est devenue l'un des grands champs d'application du Big Data, avec la possibilité, grâce à l'implémentation d'une multitude de capteurs plus ou moins intelligents dans des réseaux de machines, de monitorer le système en temps réel. Pour des entreprises industrielles qui évoluent de plus en plus vers la mise à disposition de services, c'est la possibilité d'assurer la pérennité de ce service, en rendant la maintenance intelligente. Parvenir à de tels objectifs suppose de résoudre quelques problèmes mathématiques importants : comment adresser une telle volumétrie de données ? Comment produire des prédictions efficaces en temps réel ? Comment exploiter efficacement des systèmes d'information qui sont fondamentalement distribués ? Cela demande de revisiter complètement l'algorithmie. ”

De telles perspectives ne peuvent manquer d'intéresser les grands groupes industriels, dans des secteurs aussi variés que le transport, l'aviation, l'énergie... Dans celui de l'oil & gaz, l'entrée dans cette nouvelle ère de la maintenance constitue ainsi, un véritable *step change*, comme le détaille Olivier Brousseau (Schlumberger) :



Schlumberger
Olivier Brousseau
IT Business Intelligence Strategy
Manager



Cela fait partie depuis longtemps des *best practices* de notre secteur de posséder, dans chacune de nos machines, une carte de stockage pouvant tout monitorer. Mais ce qui manquait jusqu'à présent, c'était la discipline et les process permettant de tirer de la valeur des informations dormant dans ces cartes, en les rapatriant en central pour les exploiter dans une boucle plus longue. Cette possibilité est apparue avec la démocratisation des technologies autour de la donnée (notamment l'architecture Hadoop), qui a rendu le stockage et l'exploitation de la data beaucoup plus abordables.

Nous avons lancé une première POC qui a duré trois semaines. Nous avons récupéré les logs fournis par l'électronique embarquée de nos outils (statut sur 140 mesures - températures, pressions, chocs - relevées toutes les 5 à 10 secondes). Puis avec des outils Big Data, amenés par un partenaire, nous avons commencé à analyser ces données, après avoir retiré les informations relatives au client contenues dans les logs pour ne garder que les données techniques.

Au bout de trois semaines à faire matcher cette data, les premiers résultats et les premières corrélations sont apparus, montrant clairement qu'au-delà d'une certaine température en sous-sol, le taux d'échec des outils grimpait en flèche. On a aussi constaté qu'il existait un niveau de choc particulièrement susceptible d'engendrer des défauts sur la carte électronique. C'était un enseignement intéressant, pour deux raisons :

- ce n'était pas forcément l'angle attendu, et cela apportait une nouvelle compréhension de ce qui se passait en sous-sol
- la compréhension de ce niveau de choc permettait de faire un feedback aux équipes opérationnelles pour ajuster la vitesse de sondage et optimiser la fiabilité. ”

OBJETS CONNECTÉS

La hausse exponentielle du nombre de systèmes et d'équipements branchés sur le réseau internet constitue un véritable changement de paradigme. Ces objets connectés sont aujourd'hui partout : dans nos foyers (smartphones et tablettes, bien sûr, mais aussi box, jouets, détecteurs de mouvement, de fumée, et bientôt réfrigérateurs, miroirs intelligents, et autres inventions de la domotique), dans le secteur de l'énergie, des transports, de la médecine, de la maintenance industrielle... Ils dessinent un écosystème fait de systèmes liés entre eux et qui, plus qu'une conséquence du Big Data, en est l'une des causes principales, puisqu'il va produire des quantités de plus en plus massives d'informations qui font changer d'échelle le monde de la donnée. Avec l'internet des Objets ce sont des opportunités business vertigineuses qui apparaissent pour les entrepreneurs. Mais aussi une multitude de défis pour réussir à tirer partie des flux qui s'échangent entre systèmes. C'est ce qu'explique **Tania Aydenian (Orange Technocentre)** :



Orange Technocentre

Tania Aydenian

Directrice du Programme Datavenue



Les modèles encadrant les données issues des objets connectés ne sont pas structurés. Les outils de modélisation de données seront clé pour pouvoir extraire de la valeur et appréhender les objets qui verront le jour dans le futur. L'objectif est de passer de l'objet au service. Dans notre plateforme nous adressons les objets connectés existant sur le marché, mais aussi les concepteurs de nouveaux objets. L'interopérabilité est un enjeu majeur pour répondre aux nouveaux usages. Etablir un standard, sera bien complexe. On assiste surtout à la bataille des alliances.”



Les objets connectés sont en train de prendre de plus en plus d'importance dans le champ de la médecine. Sanofi vient ainsi de s'allier avec Google dans la lutte contre le diabète, comme l'ont fait plusieurs autres concurrents.

Sanofi

Pierre-Yves Lastic



Ce n'est pas un secret, les objets connectés déferlent sur le marché B2C et vont avoir une influence importante sur les individus. Mais l'impact sur l'entreprise est aussi majeur, quel que soit le secteur d'activité. On trouve déjà des apports indéniables sur deux secteurs transverses :

- La supply chain : l'Internet des Objets permet des gains considérables sur la traçabilité et l'amélioration de la réactivité face aux incidents.
- Les unités de production industrielle : le développement des *smart factories* basé sur les objets connectés, permet des gains de productivité – grâce à l'anticipation des pannes –, de flexibilité – grâce à la reconfiguration des machines ou la simulation – et des économies d'énergie.

Mais les usages sont infinis. Le meilleur exemple concret est le véhicule connecté. Il peut être considéré comme un hyper-objet connecté qui interagit avec son environnement : c'est en même temps une station météo, une machine connectée sur laquelle on peut prédire voire réparer des pannes mécaniques et un objet multimédia. Il illustre parfaitement les nouveaux usages autour des données liées à l'Internet des Objets : revente des données à des tiers, analyse des comportements à des fins marketing ou commerciales, et interactions entre individus.”

Laurent Sergueenkoff

Analytics Platform Sales Team Leader

IBM France



OPEN DATA

Sous ce terme se cachent à la fois un type de données et une philosophie, ou tout du moins une attitude vis-à-vis de la data. Sont considérées comme open data toutes les données numériques, d'origine publique ou privée, stockées sur une plateforme accessible gratuitement par tout le monde. La tendance générale, depuis quelques années, est à l'ouverture de la donnée, soit pour des raisons légales (lorsque les collectivités, par exemple, sont contraintes de mettre à disposition des citoyens certaines informations et statistiques les concernant), soit dans le cadre d'une démarche volontaire d'Open knowledge, c'est à dire de contribution globale à la connaissance. Conséquence : la quantité de données ouvertes disponibles est en augmentation constante. Les entreprises ont bien conscience de l'intérêt qu'elles pourraient avoir à puiser dans ces nouveaux bassins d'information. Reste à inventer des usages pertinents, souligne **Christèle Baranco (LCL)**. Et à encadrer rigoureusement la façon dont ces données vont être mises à la disposition de la communauté, rappelle **Pierre-Yves Lastic (Sanofi)** :

“ Comme la plupart des banques nous disposons de données INSEE et de données de concurrence que nous n'utilisons certainement pas assez. Nous souhaiterions mettre plus en valeur ces données ouvertes, qui ont sûrement beaucoup de choses à nous apporter. Cela suppose de trouver des cas d'usage rentables pour nous, avant de stocker les données sur notre cluster Hadoop. ”

LCL

Christèle Baranco
Responsable Analyse
de la Donnée Client



**ENTRER PAR
LA BONNE
PORTE
DANS
LA DONNÉE
OUVERTE**

“ Il existe, dans les hôpitaux publics, des mines d'information permettant de mieux comprendre les maladies et de mieux les traiter. L'ouverture de telles données serait précieuse pour le monde de la santé, mais suppose évidemment une sécurité et une anonymisation totale. ”

Sanofi

Pierre-Yves Lastic
Associate Vice President,
Chief Privacy Officer



SÉCURITÉ DES DONNÉES

Comment contrôler l'intégrité de ses données, alors que celles-ci n'ont jamais été aussi nombreuses, et n'ont jamais circulé aussi librement ? Et quels outils mettre en place pour s'assurer de leur impénétrabilité, condition sine qua non pour tenir ses promesses en terme de **data privacy** ? A l'ère du Big Data, la question de la sécurité des données, qu'elles soient personnelles ou industrielles, revêt un aspect déterminant. Et a fortiori pour des entreprises qui fondent leur valeur sur leur capacité à garantir l'inviolabilité de leur système d'information. Voilà ce que détaillent **Morgane Castanier (Numericable-SFR)** et **Pierre-Yves Lastic (Sanofi)** :

« Surveillance des Etats, failles et abus de plus en plus fréquents dans la façon dont certaines entreprises traitent les data clients, et prise de conscience

du public que leurs données personnelles ont de la valeur... Le climat est en train de se tendre sur la question des données. La sécurité des data devient dès lors une problématique avec laquelle il est hors de question de transiger. »



Numericable – SFR
Morgane Castanier
Directrice Data et CRM

**ON NE
PLAISANTE
PAS AVEC
LA SÛRETÉ
DES DONNÉES**

« Une entreprise basée sur l'innovation et la recherche fonde sa valeur sur ses données, et donc sur sa capacité à les protéger. Nous

traitons énormément de données éminemment sensibles (liées aux essais cliniques, à des questions génétiques), qui ne doivent en aucun cas tomber dans de mauvaises mains. La cybersécurité est donc un enjeu crucial pour nous, à la fois pour toutes les données relevant de la propriété intellectuelle, et pour celles relatives à la santé de nos patients. »

Sanofi

Pierre-Yves Lastic
Associate Vice President,
Chief Privacy Officer



Heureusement, les Big Data ne constituent pas qu'une menace et une urgence pour les questions relatives à la sécurité des données. Elles sont aussi un formidable outil de data safety, comme tient à le souligner Aroua Biri (**Sogeti**):



Sogeti
Aroua Biri
Architecte Cybersécurité & Big Data



Le Big Data, en ce qu'il permet de traiter très rapidement des masses toujours plus énormes de données, est un enabler de sécurité. Dans tout ce qui est démarches SIEM (Security Information and Event Management) les Big Data vont servir de renfort. Avec des technologies de machine learning, et d'autres permettant d'exploiter des sources de données qui auparavant étaient beaucoup trop compliquées à analyser, on va être capables de déceler des corrélations, de détecter mathématiquement des incongruités, des anomalies, et donc de remonter des alertes qui seraient autrefois passées totalement inaperçues.”



JURIDIQUE

Hoche Avocats

« Les volumes des données traitées sont en perpétuelle augmentation et si on a pu se demander par le passé s'il y avait un intérêt à les conserver, la puissance des outils développés aujourd'hui apporte une réponse technique et opérationnelle incontestable. Le concept de "capital immatériel" ou le "patrimoine informationnel" que représentent les données d'une entreprise, est un capital pouvant être valorisé au titre d'actif incorporel.

La majorité de la capitalisation boursière des entreprises cotées est constituée d'actifs incorporels ce que confirment les transactions ou introductions en bourse récentes. À côté d'éléments incorporels tels que la marque, les brevets ou les logiciels, les données participent pour une part grandissante dans la valorisation d'une société.

La protection de cet actif devient dès lors crucial pour faire face aux cas d'intrusions délictuelles dans des systèmes d'information, pillages de données... générateurs de préjudice économique et d'image de marque.

La protection des données peut être assurée :

- Par des moyens de cryptologie, dont l'utilisation est libre en France, contrairement à leur fourniture, importation, ou exportation soumis, sauf exception, à déclaration ou à demande d'autorisation ;

- Par l'utilisation de signatures électroniques
- Et plus généralement par la voie contractuelle (obligations spécifiques mises à la charge d'un prestataire).

Des textes spécifiques peuvent imposer par ailleurs des obligations en matière de sécurité des données, notamment pour les entreprises privées ou publiques concernées par la gestion d'information liée au secret de la défense nationale (ex. procédures d'habilitation et de contrôle des personnes pouvant avoir accès au secret, les conditions d'émission, de traitement, d'échange, de conservation ou de transfert des documents classifiés).

Dans le cadre de projet Big Data, on veillera notamment à :

- définir précisément les obligations contractuelles relatives à la sécurité des données (niveaux de services, obligation de moyen/de résultat, clauses limitatives de responsabilité en cas de perte de données ou d'intrusion et ce dans les différents contrats d'hébergement, de SaaS, de Cloud...);
- s'assurer de la licéité et de l'efficacité des moyens mis en œuvre au regard des différentes législations nationales ayant vocation à s'appliquer (cryptologie, valeur de la preuve électronique et des conventions de preuve, transfert de données...).

Hoche Avocats
Régis Carral
 Avocat – Associé



SMART DATA

Pour que la mine d'or du Big Data dévoile ses ressources et livre ses promesses, encore va-t-il falloir être en mesure de l'exploiter efficacement. Ce qui est loin d'être simple. Quels sont les gisements de données les plus pertinents, ceux à même d'apporter une vraie valeur à l'entreprise ? Comment y puiser efficacement, sans se perdre dans la masse d'information qui les entourent ? Quelles stratégies adopter enfin pour valoriser les données une fois celles-ci collectées ? C'est pour répondre à ces questions qu'intervient le Smart Data, un concept qui met l'accent sur l'utilisation intelligente de la donnée. S'intéressant en priorité à la valeur effective des données pour le business, les tenants de ce modèle conseillent de substituer à l'analyse en 3V, son évolution en 5S. C'est à dire : Stratégie (définir en amont les bénéfices attendus de l'usage de la data), Sourcing (bien circonscrire les bases de données qui seront utilisées pour ne pas s'éparpiller inutilement), Sélection (trier l'information pour ne pas s'y noyer), Signifier (donner du sens à la donnée brute en la traitant ou en la faisant traiter), Symboliser (exprimer la donnée de façon claire notamment en ayant recours à de la **data visualization**). Il s'agit là bien sûr, plus que d'une théorie formelle de la donnée, d'une vision destinée à en simplifier l'approche. Elle n'en demeure pas moins une bonne base pour appuyer des projets en restant dans le concret, ce que soulignent les expériences Smart Data de **Morgane Castanier (Numericable-SFR)** et **Marie-Laure Cassé (Voyages-sncf.com)** :

“ Si la notion de Big Data sert à qualifier les technologies autour du traitement de volumes de données de plus en plus massifs, la notion de Smart Data va, quant à elle, surtout désigner la capacité à adresser un use case précis en collectant les données les plus pertinentes et celles qui seront facilement actionnables. C’est un terme qui est plus tourné vers l’efficacité du ciblage que vers l’importance de la volumétrie. Chez Voyages-sncf, nous avons été amenés à mobiliser des logiques apparentées à du Smart Data à de nombreuses occasions. Par exemple, dans le cadre de notre algorithme de recommandation de destinations, l’un des enjeux consistait à capter les bonnes données afin d’identifier la gare de départ la plus pertinente pour notre internaute, ce qui devait permettre de lui adresser, par la suite, des recommandations associées de qualité. ”



Voyages-sncf.com
Marie-Laure Cassé
Directrice
Marketing Client
& Data

INSUFFLER DE L’INTELLIGENCE DANS SES DONNÉES

“ La recherche de pertinence est un enjeu fort quand on est confronté à une grosse masse de données, le risque étant, dans ces cas là, de se perdre dans la profusion de data. Mon souci constant est de garantir l’alignement systématique de nos approches scientifiques et technologiques avec les enjeux et la stratégie business. Le Smart Data, c’est d’abord s’efforcer de rester très pragmatique ! ”

Numericable – SFR
Morgane Castanier
Directrice Data
et CRM



Attention cependant de ne pas être dupes. Derrière le terme séduisant de Smart Data se cache souvent une façon de marketer des produits et des solutions qui au final n'ont rien de révolutionnaire. Voilà contre quoi met en garde **Jean-François Marcotorchino** (**Thales Communications et Sécurité**) :



Thales Communications et Sécurité
Jean-François Marcotorchino
Vice Président et Directeur Scientifique
de Thales GBU SIX



Beaucoup d'acteurs du marché aujourd'hui dans ce domaine très « buzzy » des Big Data proposent des services et des outils d'analyse qui relèvent de ce qu'on appelait il n'y a pas si longtemps « le Business Intelligence » voire au mieux le « Data Mining » (avec comme applications vedettes dans le B2C : le CRM, la segmentation de clientèle, le Cross Selling, l'attrition etc.), ceci bien que toujours utile, n'est pas ce qu'on entend aujourd'hui par Big Data. D'ailleurs, parce qu'ils l'ont bien compris et qu'ils en sont bien conscients, ces spécialistes ou acteurs là vont utiliser le terme de « Smart Data » pour qualifier cette façon de faire du traitement statistique de données qui est en réalité la même... qu'il y a quinze ans (échantillonnage et population à analyser de taille raisonnable et non gigantesque), car beaucoup d'algorithmes utilisés dans ce contexte sont non linéaires et de fait ne sont donc pas « scalables ». ”

TEMPS RÉEL

L'une des grandes promesses du Big Data, c'est la possibilité d'exploiter la data non plus de façon statique en interrogeant des pools d'information déjà constitués, mais en traitant plutôt, quasi instantanément, des flux. Avec le real time, la donnée échappe ainsi à une vision figée pour se faire dynamique, comme le souligne **Benoît Chéroux (Groupe Argus)** :



Le temps réel est l'une des principales caractéristiques du Big Data. Avec les datawarehouses, on voit la donnée de façon figée, à un instant T, ayant pour objectif de produire le reporting. Au contraire, avec le Big Data, on capte la donnée en temps réel (notamment avec les interactions ayant lieu sur les sites web). Cette caractéristique associée avec les deux nouvelles composantes que sont l'algorithmie (text mining, indexation) et les API (qui donnent de la valeur à la donnée dans sa restitution), vont conférer à la donnée une mobilisation de plus en plus rapide, tendant vers le temps réel.



Groupe Argus
Benoît Chéroux
Responsable Données
& Modélisations



Cette évolution vers le temps réel a déjà rencontré de multiples usages, dont le **Real Time Bidding** est un bon exemple (entre la mise aux enchères d'une annonce et son achat sur un Ad-Network, il ne se déroulent que quelques millièmes de secondes). Soulignons toutefois que cette notion de temps réel ne signifie pas toujours l'instantanéité, et peut renvoyer à différentes temporalités en fonction de la réalité du business. Si mettre un script à la disposition d'un téléconseiller au fil d'une conversation devra se faire dans le dixième de seconde, l'analyse en temps réel d'une base CRM sera jugée suffisante si elle est mise en oeuvre dans la minute. Dans le cadre d'une application d'assistance aux personnes âgées, comme celle dont nous parle **Pierre-Yves Lastic (Sanofi)**, c'est la vraie instantanéité que l'on recherche :



Nous travaillons en collaboration avec divers acteurs de la santé, un domaine où le temps réel a une importance cruciale - on s'en doute puisque c'est la vie de personnes qui est en jeu ! Lorsque nous travaillons sur des applications d'assistance aux personnes âgées, par exemple, on ne peut se permettre de ne pas être en temps réel. ”

Sanofi
Pierre-Yves Lastic
Associate Vice President,
Chief Privacy Officer



Les nouvelles perspectives qu'offre le Real Time ont pu voir le jour grâce à l'évolution récente de certains outils. Ainsi le framework **Hadoop**, qui était initialement orienté *batch*, permettant des calculs distribués adaptés à des données massives, s'est équipé il y a deux ans d'une solution qui lui permet d'intervenir aussi sur le terrain du Real Time : **YARN**.

VALEUR

Rien ne sert de se lancer dans un projet de Big Data sans lui avoir assigné au préalable des objectifs précis qui se traduiront très concrètement par une génération de valeur pour l'entreprise. Cette affirmation peut sembler une évidence, mais elle a été martelée par tous les acteurs que nous avons pu interroger sur le sujet. Le risque étant de se laisser piéger par les promesses d'un buzzword, sans avoir de vision claire sur la façon de l'incarner d'un point de vue business. Les cas d'usage sont certes innombrables : améliorer sa connaissance clients, optimiser la sécurité de ses systèmes, booster ses performances marketing grâce au **RTB**, réduire ses coûts d'entretien en mettant en œuvre des logiques de **maintenance prédictive**, tirer parti de la puissance des **objets connectés**... Encore s'agit-il de trouver le bon. Pour reprendre les mots de Bill Schmarzo (CTO de EMC, et auteur de *Big Data : Understanding how data powers Big Business*) « Les entreprises n'ont pas besoin d'une stratégie pour exploiter les Big Data ; elles ont besoin d'un business plan qui intègre les données et les possibilités ouvertes par les Big Data dans un univers digital. »

Une fois acquise la certitude de l'intérêt d'un projet mettant en son cœur l'exploitation de la donnée, reste à déterminer quelle data est susceptible de générer le plus de valeur dans cet usage précis. **Max Vallejo (Air France-KLM)**, insiste par exemple sur l'importance des données de navigation et des données serveur dans le cadre d'un objectif d'amélioration de l'expérience client :



La valeur que l'on attribue à telle ou telle donnée va permettre de prioriser nos projets de capture et de stockage. Ces derniers temps, par exemple, les données de navigation et les données serveur ont pris une place très importante chez nous : elles permettent en effet d'une part de faire du retargeting (très classiquement) mais elles vont aussi permettre d'améliorer l'expérience client, en la jouant pour mieux comprendre les problèmes remontés.



Air France-KLM | Max Vallejo
Head of eCRM, Digital Department



VARIÉTÉ

Fichiers excel, bases de données clients, CRM, produits ou de gestion, d'une part. Fichiers textes, images, vidéos, ou logs de l'autre. Qu'elles soient structurées ou non structurées, les données que doivent aujourd'hui traiter au quotidien les entreprises se caractérisent par une grande hétérogénéité de formats et de sources. Cette variété est d'ailleurs l'une des premières choses qui saute aux yeux de qui veut se faire une vision globale de ses data, comme a pu le constater **Yoann Denée (Prisma Media)** :



Prisma Media
Yoann Denée
Chief Data Officer



Un des premiers objectifs pour permettre la valorisation des données chez Prisma a été de procéder à un inventaire de toutes les sources de data. Celles-ci sont très hétérogènes et viennent de natures et de business différents : base abonnés payante, base abonnés newsletters gratuites, applications et services gratuits et/ou payants, communautés, membres de sites web, et un grand nombre d'autres affluents plus petits. ”

À cette grande richesse de données déjà présentes dans le système d'information des entreprises, vient s'ajouter la diversité de celles qui peuvent être récupérées à l'extérieur, via des processus comme le **Data Mining**. Voilà de quoi complexifier encore les choses, si l'on en croit **Pascale Dulac (France Loisirs)** :



Travailler avec des données qui ne viennent plus de chez nous et de nos propres systèmes d'information, mais qui sont récupérées à l'extérieur (réseaux sociaux, chat collaboratif, réponses à des questions ouvertes adressées à nos clients), qui ne sont pas structurées de la même façon que les data internes, et qui ne rentrent donc pas forcément dans les cases que nous avons nous mêmes définies, cela implique un changement de fond dans la façon de travailler. ”

France Loisirs
Pascale Dulac

Responsable Connaissance Clients



Pour espérer tirer de la valeur de ces agrégations de data internes et externes, et exploiter efficacement la masse de plus en plus importante de données non structurées (environ 80% des données dans le monde se rangent sous cette catégorie), les méthodes traditionnelles ne suffisent plus. Ainsi, si l'on ne veut pas que la variété de la donnée devienne un obstacle, il va être nécessaire de mettre en place de nouvelles solutions empruntées au monde des Big Data :



Thales Communications et Sécurité
Jean-François Marcotorchino
Vice Président et Directeur Scientifique
de Thales GBU SIX



La question de la variété des données analysées reste un problème fondamental, et l'hétérogénéité des données, un vrai frein à leur exploitation tous azimuts. On sait pratiquer facilement la juxtaposition de données, le croisement de bases de données et de fichiers, et éventuellement la fusion à certains niveaux de cohérence mais l'exploitation simultanée et mélangée de données de types différents par des algorithmes unifiés a longtemps été un fossé à la méta-analyse. Aujourd'hui, il apparaît néanmoins malgré de gros progrès faits, qu'il y a de plus en plus une attente vis-à-vis de cette capacité à exploiter en même temps des données de nature différente. Mais cette exploitation ne se fera pas de façon similaire en fonction des différents types de données exploitables. ”

Au-delà de la mobilisation de nouveaux outils, la capacité à résoudre efficacement le problème de la variété va aussi dépendre de la capacité de l'entreprise à mettre en place une **data gouvernance** adaptée. C'est sur ce dernier point qu'insiste **Pierre-Yves Lastic (Sanofi)**:



Sanofi
Pierre-Yves Lastic
Associate Vice President,
Chief Privacy Officer



De même qu'aujourd'hui les essais nucléaires ne sont plus réalisés sur le terrain, avec des vraies bombes, mais par ordinateur, le secteur de la biologie humaine tente de mettre en place des essais cliniques virtuels. Ces simulations nécessitent de mettre en commun des données variées, venant de la recherche fondamentale en les corrélant avec des données cliniques issues du monde du soin. Les caractéristiques de ces données ne sont pas les mêmes, et les faire communiquer nécessite donc de veiller au préalable au bon respect des règles qui les encadrent, et peuvent varier. ”

VÉRACITÉ

Les 3V (Volume, Variété, Vitesse) ne peuvent se déployer dans toute leur ampleur que si la donnée qu'ils mobilisent à la base est fiable. La véracité de la donnée, sa précision, sa pertinence, vont donc revêtir une importance cruciale, invitant les entreprises à une très grande rigueur aussi bien dans la façon dont elles orchestrent la collecte des données, que dans la manière dont elles vont les recouper, les croiser, les enrichir. Cette attitude, dont va dépendre l'intégrité et la sécurité des data bases, est loin d'être nouvelle. **Pascale Dulac (France Loisirs)** souligne ainsi :



Quand on a l'habitude de manier de la donnée, la recherche de la véracité - de la fiabilité -

est un impératif ancré depuis longtemps dans les pratiques, et dont l'importance n'a pas attendu l'ère des Big Data pour prouver son évidence.



France Loisirs
Pascale Dulac
 Responsable Connaissance Clients



Mais face à la digitalisation, face à la massification des données disponibles, elle se transforme en urgence. Ne pas revoir à la baisse ses exigences en terme de véracité, voilà un des défis du Big Data que tient à souligner **Max Vallejo (Air France-KLM)** :



Air France-KLM

Max Vallejo

Head of eCRM, Digital Department



Jour après jour, les retours de données auxquels nous avons accès se font de plus en plus fins, et la frontière de plus en plus ténue entre les différentes interprétations que l'on peut en tirer. Dans de telles conditions, il est capital de continuer à interpréter correctement les données. C'est le cas par exemple avec les codes retour d'envoi. Quand on envoie une campagne il y a différents codes retour possibles : arriver à analyser et à interpréter efficacement ces informations, pour in fine, déterminer si l'on peut continuer à adresser tel ou tel client, c'est crucial. Quelle différence va-t-on faire entre un hard bounce, un soft bounce, un client qui souhaite se désabonner d'un programme en particulier...? La véracité, au-delà de l'exactitude, cela consiste à restituer fidèlement le sens d'une donnée bien précise, pour ensuite être en mesure d'agir le plus efficacement possible. ”

VITESSE / VÉLOCITÉ

Dans le modèle d'analyse en **3V**, on parle aussi de Vélocité pour désigner ce paramètre caractéristique du Big Data. La hausse des volumes de données au cours des dernières années s'est en effet accompagnée d'une intensification radicale du débit (soit la volumétrie multipliée par le laps de temps dans lequel les données évoluent). Capturer et traiter de façon la plus diligente possible ces flux qui s'accroissent, voilà un nouveau défi pour les entreprises qui ne veulent pas se contenter d'une analyse asynchrone de la donnée. Et ce a fortiori dans le cadre de processus chronosensibles (comme le traitement de fraude) où l'on ne peut se permettre de perdre la moindre minute.

Pour répondre au rythme effréné auquel est aujourd'hui générée l'information, les capacités de traitement de l'architecture Big Data et de certaines de ses technologies (**YARN**, notamment) vont offrir des vitesses d'exécution qui n'ont plus rien à voir avec les temps de traitement par lots (*batch*) caractéristiques de la Business Intelligence à l'ancienne.

En filigrane, l'adoption de ces accélérateurs du traitement de la donnée laisse apparaître la possibilité pour les entreprises de traiter leur masse de données au fil de l'eau, en **temps réel**. C'est en tout cas ce qu'espèrent Yoann Denée (**Prisma Media**) et Benoît Chéroux (**Groupe Argus**) :

EN AVANT VERS LE TEMPS RÉEL

« Jusqu'à l'année dernière, nous récupérons les annonces du marché

du véhicule de l'occasion toutes les semaines. Aujourd'hui, on procède à cette collecte de données tous les jours. Nous avons le projet de tendre vers encore plus de réactivité, pour rendre compte des fluctuations du marché de l'auto en temps réel. En arriver là supposerait une explosion des données récupérées, et donc, nécessairement, la mobilisation des technologies Big Data. »

Groupe Argus
Benoît Chéroux
Responsable Données
& Modélisations



« Lorsque nous avons acheté, il y a trois ans,

P comme Performance (une entreprise opérant sur le secteur de la monétisation de base de données), cette régie digitale procédait en moyenne à 500 millions d'opérations par jour. Aujourd'hui, elle en réalise plus d'un milliard... sauf que le temps de requête a été dans le même temps divisé par 25 000! Cela montre bien l'évolution radicale des technologies, et l'entrée dans l'ère d'une rapidité qui confine au temps réel. »

Prisma Media
Yoann Denée
Chief Data Officer



VOLUME

Dans Big Data, il y a « big ». Et en reprenant l'interprétation classique en **3V**, c'est tout naturellement la notion de Volume qui s'impose avec le plus d'évidence pour qualifier la déferlante de données qui inonde les systèmes d'information des entreprises et le web. Nous générons aujourd'hui en une journée plus de données qu'il n'en a été produit entre les débuts de l'humanité et l'an 2000. Chaque jour sur Facebook s'échangent 10 milliards de messages, et sont uploadées 350 millions de nouvelles photos. Et on ne compte plus ces monceaux de data en terabytes (10 puissance 12) mais en petabytes (10 puissance 15), voire en zettabytes (10 puissance 21). Une hausse exponentielle de la volumétrie dont toutes les entreprises françaises font aussi le constat, comme le détaille **Morgane Castanier (Numericable-SFR)** :



Pour chacun de nos clients,
nous récoltons plusieurs milliers
de données unitaires différentes.
Si l'on multiplie ce chiffre

par le nombre de clients et qu'on y ajoute
leurs diverses interactions avec nos interfaces,
on est très vite confrontés à une énorme masse
de données avec une vraie profondeur...

et qui n'a rien à envier à un Facebook !



Numericable-SFR
Morgane Castanier
Directrice Data et CRM



Un tel bouleversement fait naître de nouveaux défis : Comment collecter ces monceaux de data ? Comment les stocker efficacement ? Et surtout, comment les traiter pour en tirer de la valeur ? Quels cas d'usage, quels nouveaux services inventer pour en tirer le meilleur parti ? C'est bien souvent la prise de conscience du nouveau challenge incarné par le gigantisme de la donnée qui va pousser les entreprises, quel que soit le secteur, à se doter de solutions Big Data adéquates, comme le confirment **Jean-François Marcotorchino** (Thales Communications et Sécurité) et Pierre-Yves Lastic (Sanofi) :

“ Nous travaillons sur des bases de données de très grande taille, et excessivement peu structurées au départ, dans des domaines variés allant de la cybersécurité, à l'analyse globale de systèmes et réseaux, en passant par l'analyse des comportements passagers dans les transports ferroviaires ou urbains de surface (bus) jusqu'à l'inventaire stellaire en astronomie, etc. A titre d'exemple de problématique Big Data : la cartographie des étoiles de notre Galaxie (1 milliard d'étoiles observées) avec 10 instruments sur un satellite, chaque étoile pouvant être vue 88 fois au cours de la mission (le nombre total de mesures à traiter est d'environ 280 milliards, une mesure représentant 10Ko). Outre le stockage de telles bases, leur exploitation et analyse conduit à des approches analytiques nouvelles où l'effet de montée en charge (« scalabilité ») doit être maîtrisé, au travers du développement d'outils spécifiques. ”

**Thales Communications
et Sécurité**

Jean-François Marcotorchino
Vice Président et Directeur
Scientifique de Thales GBU SIX



FACE AU DÉFI DES MÉGADONNÉES

“ Dès que l'on entre dans la donnée en temps réel, on est soumis à une problématique d'analyse de ces données qui implique la mise en place de nouvelles méthodes. Lorsque par exemple le « journal patient » destiné aux malades chroniques est passé du support papier au support électronique, le nombre de données mobilisées a crû de façon exponentielle. Et il a fallu nécessairement adapter nos méthodes d'analyse pour traiter des volumes de données beaucoup plus considérables. ”

Sanofi
Pierre-Yves Lastic
Associate Vice
President, Chief
Privacy Officer



WEB 3.0 / WEB 4.0

À quoi ressemblera le web de demain ? Face à une telle question, il y a autant de réponses possibles que d'hypothèses élaborées par les futurologues. C'est pour tenter d'en tracer le périmètre que ces derniers ont imaginé le terme de Web 3.0, inspiré du Web 2.0 qui a servi à désigner, à partir du milieu des années 2000, la révolution du participatif et la simplification des usages numériques. Il s'agit là, plus que d'un concept unifié, d'un attrape-tout, dans lequel chacun déverse sa vision des enjeux futurs.

Quelques grandes caractéristiques reviennent pourtant plus que d'autres pour en tenter une approche théorique : le triomphe de la mobilité qui rend le web indépendant des supports, l'universalité, qui le libère de la dépendance aux systèmes d'exploitation dans un monde de plus en plus open source, l'accessibilité, et le fait aussi que le web n'est plus constitué uniquement des sites, mais aussi de solutions web (applications, base de données, etc). Pour évoquer plus spécifiquement le rapport nouveau à la donnée qui ne manquera pas de voir le jour, certains parlent aussi de Web sémantique, sorte de modèle émergent dans lequel la data circule sans contraintes pour libérer les usages et permettre la création de nouvelles connaissances.

Le Web 3.0 n'a du reste pas encore pointé le bout de ses algorithmes que certains théorisent déjà la prochaine vague, celle du Web 4.0. Plus lointain, cet autre concept offre pourtant une perspective plus claire : celle d'un monde entièrement digitalisé, où tout n'est plus que données.



The Economist
Stéphane Père
Chief Data Officer (Global)



Le web 1.0 c'était le monde de la publication, en top down.
Le 2.0, c'était l'interaction entre les lecteurs et le contenu

(participatifs, forwards, commentaires).
Le 3.0 implique lui des logiques plus transversales, la possibilité pour un contenu d'apparaître dans plusieurs publications, sur différentes applications, en suivant des logiques de syndication, de distribution nouvelles (webapp, flipboard, ...). Quant au 4.0, c'est la phase où l'univers physique devient le web, la phase où le monde est digital. ”

2. TRANSFORMATION DE L'ENTREPRISE

Rattachée plus globalement au vaste mouvement de digitalisation, l'arrivée des Big Data est elle aussi un puissant agent de transformation pour les entreprises. D'abord parce qu'il s'agit pour elles de se doter des compétences les plus à même d'en tirer parti (Data Scientist, Chief Data Officer, ...). Mais surtout parce que le traitement massif de la donnée induit de nouvelles manières de travailler.

CHIEF DATA OFFICER

La multiplication des sources de données, l'augmentation de leur volume, et surtout leur capacité à impacter de plus en plus fortement le business

même, a fait émerger le besoin d'un nouveau poste au sein des entreprises : le CDO (Chief Data Officer). Si l'intitulé du poste tombe sous le sens - c'est celui qui est responsable de tout problème relatif à la donnée - son périmètre d'action est lui beaucoup plus difficile à délimiter. Et pour cause. La donnée s'infiltrant dans toutes les strates de l'entreprise, il s'agit là d'une fonction par essence transverse qui s'accommode mal d'une vision parcellaire des choses. Plutôt que de tenter de donner une définition générale du terme, le mieux est peut être de laisser à des CDO eux mêmes le soin de décrire leur rôle. La parole donc à **Fabrice Otaño (AccorHotels)** et **Samir Amellal (Publicis Worldwide)**:

“ Il y a beaucoup d'ambiguïtés autour de la fonction de Chief Data Officer. Son rôle, selon moi, c'est de mettre en valeur l'importance de la donnée, en en faisant quelque chose de profitable à l'ensemble de l'entreprise. A ce titre, le CDO doit avoir un certain nombre de qualités : compliance et sens politique, pour faire face à un certain nombre de résistances qui ne manqueront pas d'apparaître au sein de l'entreprise; une connaissance aiguë de la data qui nécessite donc un profil proche de celui d'un data scientist; et enfin un certain pragmatisme. ”

DANS MA PEAU DE CDO



Publicis Worldwide
Samir Amellal
International Chief
Data Officer

“ Le rôle du CDO selon moi c'est d'insuffler une culture Data Driven à tous les niveaux de l'entreprise. Il va s'agir de faire comprendre aux différents business l'importance de prendre des décisions non plus selon l'expérience individuelle de chacun, mais en les appuyant sur du factuel... donc de la data. Côté Analytics, le CDO doit orienter les Business Analysts et les Data Scientists sur les bonnes méthodologies d'analyses, les bons algorithmes prédictifs sans perdre de vue la pertinence pour le business. Côté IT, le CDO va piloter la mise en place de la distribution Hadoop et des outils d'analyse. De manière plus traditionnelle, il va également veiller à ce que les *best practices* soient bien en place au niveau de l'utilisation des bases de données par le BI. Ceci nécessite un travail sur la roadmap IT BI, le Master Data Management, le BI as a Service... ”



AccorHotels group
Fabrice Otaño
SVP, Chief Data Officer

La fonction de CDO doit-elle devenir un poste pérenne au sein de l'entreprise ? La plupart des acteurs que nous avons interrogés sur la question, comme **Stéphane Père (The Economist)** et **Mathieu Escarpit (Oney Banque Accord)**, pensent qu'elle doit au contraire s'effacer une fois sa mission accomplie.

FAIRE DE SA PROPRE OBSCULESCENCE SA MISSION

“ La valeur potentielle autour de l'exploitation de la data est telle qu'il est aujourd'hui nécessaire

d'avoir cette fonction au sein de l'entreprise. Un CDO prend plus de sens au sein de grosses structures que dans nos équipes plus petites, où le coeur business c'est la donnée - Nous sommes par défaut organisés autour de la donnée.

Il me semble aussi que c'est un poste qui pourrait être créé sur une durée limitée, avec une mission précise (à la frontière entre technique, légal et commercial), et avec des objectifs bien déterminés.

Une fois ceux-ci accomplis, le poste aura probablement moins de raisons d'être, et les fonctions attribuées au CDO pourraient se dissoudre dans l'entreprise. ”

Oney Banque Accord

Mathieu Escarpit
Directeur Général
Italie et Joias



“ Chez nous, le rôle de Chief Data Officer est à la fois orienté organisationnel et

business. Il s'agit de faire éclore la transformation digitale dans toute l'entreprise, dans la plus grande harmonie possible. Se pose tout naturellement la question de l'évolution d'un tel rôle. Selon moi, ce dernier a une durée de vie limitée, puisqu'un CDO, s'il remplit efficacement sa mission, travaille en réalité à sa propre obsolescence. ”

The Economist

Stéphane Père
Chief Data
Officer (Global)





“ Le Chief Data Officer est l’incarnation humaine de la transformation digitale de l’entreprise. Son rôle est de construire une organisation et une culture qui rendent possible la réalisation de la stratégie à long terme de l’entreprise en question. La révolution data driven constitue en effet un défi organisationnel de taille pour les sociétés dites traditionnelles, et elle nécessite une Direction forte ; le CDO en est le chef d’orchestre. Réorganisation, revue des façons de collaborer et désilotisation, montée en compétence des équipes, choix des solutions technologiques et des partenaires pour accompagner la transformation, recrutement de nouveaux profils... C’est une sorte de mouton à cinq pattes qui, pour insuffler une culture de la data et de l’analytics à toutes les couches, dans tous les départements de l’organisation, doit faire preuve en vrac de : sens politique pour emporter l’adhésion de tous, compétences techniques, compréhension des enjeux métier, marketing et connaissance client, et gestion de projet pour mener à bien la transformation... c’est un véritable couteau suisse. ”

Pierre Harand
Director, Consulting
and Business Development
55



CNIL

Au milieu des années 1970,
la mise au jour d'un projet

gouvernemental visant à attribuer un numéro à chaque citoyen pour y associer ensuite l'ensemble de ses fichiers administratifs suscite un vif émoi en France. La Commission Nationale de l'Informatique et des Libertés est créée dans la foulée, pour tenter d'endiguer les dérives de ce nouveau monde de l'information qu'ouvrent les ordinateurs. Aujourd'hui, soit 40 ans plus tard, la CNIL est confrontée à des défis qui, bien que fondés sur des bases philosophiques semblables (comment protéger efficacement la vie privée de chacun à l'ère de l'information), ont pris une ampleur immense avec l'avènement des technologies Big Data.

C'est en effet à cette autorité administrative indépendante qu'incombe la lourde tâche non seulement de définir les usages relatifs à la donnée personnelle (un domaine immense et on ne peut plus mouvant!), mais aussi de sanctionner les acteurs qui ne respectent pas les règles qu'elle met en place. De nouveaux usages autour de la donnée apparaissant tous les jours, la CNIL est donc en permanence dans une position où elle défriche ce qu'il est ou non possible de faire. Ce qui nécessite un travail en collaboration avec les grands acteurs de la data... à commencer par les entreprises qui s'en servent et innovent sur le sujet.

Les acteurs que nous avons pu interroger sur la question considèrent ainsi moins la CNIL comme un obstacle à leurs ambitions, que comme un partenaire avec lequel ils co-construisent des usages autour de la donnée... dont beaucoup restent à inventer !

“ Nous travaillons de manière étroite et fréquente avec la CNIL, qui se montre tout à fait ouverte au dialogue, et dont l’objectif n’est pas de freiner l’économie française, mais de protéger les citoyens. Bien sûr, certaines contraintes imposées par la loi informatique et libertés peuvent amener à modifier nos projets, mais c’est surtout la surcharge de travail de la CNIL qui entraîne un traitement long sur certains dossiers, avec pour conséquence un ralentissement des projets. Je considère la CNIL comme un partenaire avec lequel nous travaillons de manière ouverte. ”

Sanofi

Pierre-Yves Lastic
Associate Vice President,
Chief Privacy Officer



MAIN DANS LA MAIN AVEC LA CNIL

“ La CNIL suit attentivement tous les acteurs référents de chaque secteur. En tant que numéro un de la presse, nous n’échappons pas à la règle. Il s’agit d’une collaboration intéressante, car elle nous encourage à réfléchir et progresser sur le traitement de

la donnée liée aux individus, (...) Cela nous a notamment incités à mettre en place des mesures qui ont ensuite été reprises par l’ensemble du marché, comme la révision des templates dans les campagnes email pour mettre en avant l’expéditeur par marque, la mise en place d’un *preference center*, servant de système central de gestion des consentements, ou la mise en place d’un service correspondant informatique et libertés qui répond à toutes les sollicitations de nos lecteurs qui apprécient fortement d’être entendus et pris en charge. ”

Prisma Media

Yoann Denée
Chief Data Officer



DATA DRIVEN ORGANISATION

Promouvoir une culture de la décision s'appuyant sur l'analyse des données, et non plus sur l'intuition humaine, voilà les ambitions d'une entreprise qui cherche à devenir data driven. Selon une telle vision, il s'agit de faire de la donnée un outil de pilotage de la stratégie à long terme autant qu'un arbitre des choix immédiats. L'aspiration des entreprises à mettre en œuvre un tel état d'esprit est évidente, surtout dans celles qui se montrent les plus matures en terme de digitalisation.



Dans une entreprise qui n'est pas data driven, beaucoup de choses se font

**FAIRE
DE LA DONNÉE
UN
MOTEUR**

au feeling : les marketeurs, par exemple, fonctionnent souvent à l'intuition, ou s'appuient sur des études externes dont l'intérêt peut être discutable. L'enjeu va être de transformer cette façon de penser, en faisant de plus en plus de la data la colonne vertébrale qui soutiendra toutes les actions. ”

Orange

Geoffrey Zbinden

Vice President Big Data Analytics
& Customer Base Management



Une Data Driven Company est une entreprise qui base ses orientations et ses stratégies sur l'analyse de sa data - chiffres de marché, base client, réseaux sociaux, A/B testing - et ce dans une logique de prise de décisions factuelles. Plus qu'un programme à mettre en place du jour au lendemain, une telle vision correspond bien sûr avant tout à un idéal. Dans une certaine mesure, celle-ci nous guide dans les changements à mettre en place chez Voyages-sncf.com. Nous avons ainsi connu, il y a un an, une grande réorganisation autour de la data, dont la volonté et l'ambition étaient de mettre en place des solutions concrètes prenant comme moteur la donnée. ”



Voyages-sncf.com

Marie-Laure Cassé

Directrice Marketing
Client & Data

Laisser à la data le pouvoir d'orienter le business suppose toutefois une transformation en profondeur de l'entreprise. Celle-ci va passer notamment par un désilotage en règle, et un effort de clarification majeur sur la question de la data gouvernance. Il s'agit là de deux obstacles majeurs à l'émergence d'une Data Driven Organisation, comme le détaille **Samir Amellal (Publicis Worldwide)** :



Publicis Worldwide
Samir Amellal
 International Chief Data Officer



Nous avons la conviction que la data, à partir du moment où elle n'est plus information brute, mais qu'elle a été transformée en information utile, doit permettre de piloter efficacement une organisation, et de prendre des décisions, que ce soit pour mieux adresser son marché, pour améliorer un service, etc... La data ne doit pas se trouver dans un silo en particulier, et le CDO ne doit pas être rattaché à un service particulier, mais aux services centraux. Une Data Driven Organisation se doit, avant toute chose, de casser les silos.

Mais en plus de cela, en voulant instaurer cette Data Driven Organisation, on se heurte très vite à des conflits sur les périmètres, et à des résistances importantes au travers desquelles chacun essaie de s'accaparer la donnée. Il faut être capable de faire passer la data non comme un enjeu de pouvoir, mais plutôt comme un facteur clé de succès qui peut être profitable à l'ensemble des collaborateurs. ”

Face à de tels obstacles, l'émergence d'une entreprise réellement data driven ressemble surtout à un vœu pieu. C'est en tout cas l'avis de **Tania Aydenian (Orange Technocentre)** :



Peu d'entreprises peuvent aujourd'hui prétendre qu'elles sont véritablement data driven (et tant pis si le mot est martelé à longueur d'articles!). Avant de parler de Data Driven Organisation, il va déjà falloir passer par un "mindset" data driven, ce qui est déjà un gros pas en avant. Qui dit donnée, dit partage et ouverture. Or cet état d'esprit va entrer en collision avec la façon dont la plupart des entreprises sont encore construites aujourd'hui, c'est à dire sur la base de silos.

Data Driven Organisation, c'est un beau mot, une belle ambition... Mais sa mise en oeuvre, voilà quelque chose de beaucoup moins évident !



Orange Technocentre
Tania Aydenian
Directrice du Programme Datavenue



DATA GOUVERNANCE

Dans la mesure où elle se propage désormais dans toutes les strates de l'entreprise, la donnée nécessite la mise en place d'une gestion globale et transverse. C'est là qu'intervient la data gouvernance, comme volonté de contrôler dans son ensemble la disponibilité, l'interprétabilité, l'intégrité, et la sécurité des données... et ce afin de mettre celles-ci au service du business. C'est ainsi, comme l'explique **Joël Aznar (Schneider Electric)**, de la prise de conscience de l'importance économique que constitue désormais la data pour une entreprise, que va naître le besoin d'en encadrer les usages par la mise en place de la gouvernance adéquate :



Schneider Electric

Joël Aznar

Global Purchasing - Director,
Master Data Governance



La porte d'entrée du Master Data Management, c'est souvent l'analytics qui va rapidement prouver son efficacité dès que l'on souhaite une meilleure qualité, une meilleure fiabilité de reporting grâce à l'amélioration des données brutes (matching, tables de correspondance, tables de multiplication). A partir de cette première étape on se rend toutefois vite compte que si l'on veut aller plus loin, on ne peut se satisfaire d'opérations de nettoyage et de réconciliation des données a posteriori... très rapidement on éprouve la nécessité de prendre la main sur les données opérationnelles dans les systèmes sources. On entre alors dans une démarche plus volontariste de data gouvernance, pendant laquelle on cherche à établir et faire respecter les règles de base associées à la gestion de la donnée, le plus en amont possible et tout au long de son cycle de vie - le fameux CRUD : "Create, Read, Update, Delete".

“ **Tout le monde est convaincu de l'intérêt de mettre en place une data gouvernance solide et efficace... Mais personne n'a le temps pour le faire. La difficulté c'est de parvenir à montrer l'intérêt business réel de cette nouvelle forme d'organisation.** ”



Groupe Argus
Benoît Chéroux

Une fois donnée l'impulsion initiale, il va s'agir de préciser les périmètres dévolus à la data gouvernance, en stipulant notamment la répartition des rôles qui lui seront dédiés. Voilà le point sur lequel insiste **Max Vallejo (Air France-KLM)** :

Air France-KLM

Max Vallejo

Head of eCRM, Digital Department

“ Les rôles associés à la gouvernance de la donnée sont de plus en plus explicites chez nous : data officer, qui a la responsabilité de définir les *guidelines* d'utilisation des données clients; data owners, qui, pour chaque famille de données, sont responsables de la collecte, du stockage, et de la véracité de la data; data analysts, qui s'occupent de la partie exécution. Il faut s'efforcer de trouver un équilibre le plus harmonieux possible dans l'articulation entre le rôle de data officer, et celui de data owner. ”

“ **Si la mise en place de la data gouvernance n'est pas portée et supportée par le top management, cela n'a aucune chance d'aboutir.** ”



Numericable – SFR
Morgane Castanier



“ Certains parlent du nouvel or noir. La data est devenue un élément de valorisation important de l'entreprise, elle est au cœur de sa transformation.

La quantité et la diversité des données, l'hétérogénéité des sources de données, l'utilisation transverse des informations ou encore des impératifs légaux rendent indispensable l'implémentation de la gouvernance des données. Objectif : faire que tous les acteurs de l'entreprise parlent un vocabulaire commun et fondent leurs analyses et leurs décisions sur des données qualifiées.

Ce service rendu en interne, de façon transverse, passe par la définition et la gestion d'un ensemble de règles, de procédures, d'indicateurs, de référentiels, qui permettent d'une part de décrire précisément les informations qui sont utilisées au quotidien dans l'entreprise, et d'autre part, d'assurer la cohérence, l'homogénéité, la fiabilité et la disponibilité des données.

L'un des challenges à relever est d'établir la confiance des consommateurs d'informations dans l'entreprise avec les applications IT ou métiers qu'ils utilisent. Cela se fait en leur garantissant des données propres, livrées à temps, et correspondant fonctionnellement à leurs attentes.

Utiliser une solution technologique homogène et ouverte est un prérequis au succès de l'adoption de la gouvernance des données. L'ensemble des informations est ainsi consolidé via une plateforme unique et intégrée, assurant la qualité de l'information pour, au final, une plus grande efficacité de l'entreprise.”

Dan Benouaisch
Directeur Technique Analytics
IBM France



DATA SCIENTIST

Forgée par deux ingénieurs de Facebook et LinkedIn, cette appellation ne renvoie pas à un profil professionnel aux fonctions strictement définies, mais plutôt à un ensemble de compétences au service de la création de valeur à partir de mégadonnées. Pour remplir au mieux cette mission, le data scientist doit se tenir à la zone de contact entre trois grands domaines : la science (connaissances en mathématiques et en statistiques), la technique (maîtrise du code, des applications, et des technos Big Data) et le business (sensibilité à la réalité des métiers, et aux objectifs de l'entreprise). Autant dire que ce genre de profils, à la fois polyvalents et hyper spécialisés, ne courent pas les rues, comme le constatent **Morgane Castanier (Numericable - SFR)** et **Samir Amellal (Publicis Worldwide)** :

“ Pour profiter de l'opportunité qu'offrent les Big Data, il faut d'abord résoudre un fort enjeu de compétences. Il est en effet nécessaire de mobiliser des profils

spécifiques, qui se trouvent à la frontière entre business, science pure, et technologie - ce dernier point n'étant pas une mince affaire étant donné le foisonnement des outils liés à la data. Ce profil idéal du parfait data scientist fait un peu figure de mouton à cinq pattes. ”

**TRÈS
CHÈRE
CHIMÈRE**

“ La data science c'est une fonction, une qualité même, relativement atypique. On se rend compte qu'aujourd'hui sur le marché tout le monde se prétend data scientist.

Mais le vrai profil nécessite d'être à la fois à l'aise avec l'informatique, les mathématiques, et avec le marketing (ou autre métier dans lequel il opérera). Une maîtrise du code, des technologies digitales et des technologies permettant de traiter de la donnée assez peu structurée, me semble être une nécessité. ”



Numericable-SFR
Morgane Castanier
Directrice Data et CRM



Publicis Worldwide
Samir Amellal
International Chief Data Officer

La rareté de ces profils risque de s'amplifier prochainement, les formations à la data science étant loin de couvrir les besoins du marché. Une récente étude réalisée par McKinsey estimait qu'il manquait d'ores et déjà 200 000 data scientists aux Etats-Unis, un chiffre qui dépasserait le million à l'orée 2020. Pour la France, le constat est le même d'après **Stéphane Cléménçon (Télécom-ParisTech)** :



Télécom-ParisTech
Stéphane Cléménçon
Professeur et Responsable
du Mastère Spécialisé Big Data



La possibilité de valoriser efficacement les données numériques dont disposent les entreprises passent par la mobilisation de compétences bien précises. Le besoin de formation autour de la data se fait donc tout naturellement plus criant à mesure que les entreprises veulent maîtriser de mieux en mieux leurs données. Nous nous en rendons compte, à ParisTech, avec le succès de notre master dédié à ce domaine.

Les formations autour de la donnée en France sont loin de pouvoir être considérées comme un enseignement supérieur de masse. Nos promotions regroupent une soixantaine d'élèves. Le nouveau master de l'Ecole polytechnique - «mathématiques pour la science des masses de données» - a des promos de 80 élèves. Avec de tels effectifs, nous sommes loin de subvenir aux besoins de toutes les entreprises, d'autant que ceux-ci vont sans doute continuer de croître. ”

Face à ce manque criant de data scientists, il ne reste aux entreprises que deux options pour combler leurs besoins : procéder à des recrutements en y mettant le prix, ou bien faire preuve d'imagination, en remplaçant ce type de profil par de nouvelles manières de travailler ensemble.



Aujourd'hui nous privilégions la complémentarité des personnes au sein de l'équipe plutôt que de trouver absolument les perles rares multicom pétentes. ”



AccorHotels group
Fabrice Otaño

“ Nous avons mis en place un système de recrutement différencié, qui permet de cibler d'un côté des candidats au profil plutôt mathématicien, et de l'autre des profils plus orientés business.

Ainsi, nous avons un laboratoire de R&D dans lequel on retrouve des profils hautement compétents puisqu'il s'agit de normaliens, de polytechniciens et d'universitaires et élèves de grandes écoles spécialisés dans le développement d'algorithmes spécifiques. Et par ailleurs, nous recrutons des «data scientists business», issus du milieu du «consulting» autour de compétences issues du Big Data dans ses implications concrètes et liées au business. ”



**Thales Communications
et Sécurité**

Jean-François Marcotorchino
Vice Président et Directeur
Scientifique de Thales GBU SIX

CE QUI NE S'ACHÈTE PAS S'INVENTE

“ Nous avons staffé cette année une équipe advanced analytics, composée d'une dizaine de data scientists que nous avons été cherchés presque entièrement par recrutement externe. Trouver de tels profils, c'est un gros investissement, étant donnée leur rareté. Il s'agit encore d'une compétence de niche. ”



Schlumberger
Olivier Brousseau
IT Business Intelligence
Strategy Manager

“ Dans la mesure où il est quasi impossible d'attirer des profils de data scientists réunissant en une même personne toutes les qualités requises, il faut trouver d'autres moyens pour faire efficacement de la data science. Chez Publicis, nous cherchons à recréer cette compétence dans le cadre de notre pôle Data Intelligence, qui fonctionne de manière totalement adhocratique - certes nous avons des chefs de projet, mais par exemple, le Directeur de la production pourra très bien devenir chargé d'études dans le cadre d'un projet en particulier dans lequel il aura les compétences requises. Dans le cadre d'un projet spécifique, les hiérarchies sautent, afin de globaliser les compétences. ”

**Publicis
Worldwide**
Samir Amellal
International Chief
Data Officer





“ Le Big Data a vu l’émergence de nouveaux métiers comme le Chief Data Officer, le Data Analyst. Le plus prisé d’entre eux est celui de Data Scientist. Ce profil est recherché car rare sur le marché, même si de nombreuses écoles et universités ont inclus la data science dans les cursus de formation.

Qu’est-ce qu’un bon Data Scientist ? Un scientifique avec des compétences métiers ? Un expert métier avec des connaissances informatiques ? La réponse n’est pas tranchée. Ce qui est sûr, c’est que ses connaissances sont solides en informatique et mathématiques et qu’il a une appétence pour le domaine d’application.

La data science nécessite une ouverture d’esprit et une curiosité parfois en opposition avec la rigueur mathématique car contrairement au Data Analyst qui s’intéresse souvent à une seule source de données (CRM, Supply Chain...) et ses structures, le Data Scientist doit corréler tous types de données et se concentrer sur le contenu. Il ne doit se fermer aucune porte et explorer toutes les pistes même les plus improbables. Toutefois, l’entreprise n’étant pas un centre de recherche, le Data Scientist Manager a un rôle essentiel : il fixe les limites en fonction des ROI et assure la pérennité des recherches. Grâce à l’excellence de ses mathématiciens, la France a un rôle majeur à jouer sur le développement de la data science. ”

Laurent Sergueenkoff
Analytics Platform Sales Team Leader
IBM France



DÉSILOTAGE

I déalement, au sein d'une entreprise, tous les départements s'efforcent d'œuvrer ensemble et dans une même direction. Pourtant, l'architecture verticale traditionnelle des sociétés peut pousser certains secteurs à être motivés par des intérêts divergents, voire à s'opposer. La façon dont vont se répartir les données dans le système d'information met en lumière ces divisions. Même si elle irrigue toute l'entreprise la data va ainsi se retrouver capturée dans des silos, où elle sera exploitée de façon isolée par les différents secteurs. Or pour profiter à plein des avantages et des nouvelles opportunités de croissance offertes par la donnée, il va justement falloir faire circuler de façon fluide cette dernière, et instaurer une data gouvernance transverse, à l'échelle de l'entreprise.



***La data ne doit
pas se trouver
dans un silo
en particulier
et une Data Driven
Organisation se doit
avant toute chose,
de casser les silos.***



Publicis Worldwide
Samir Amellal

De telles mesures passent nécessairement par une réduction, voire une suppression pure et simple des silos traditionnels, comme l'expliquent **Morgane Castanier (Numericable - SFR)** et **Samir Amellal (Publicis Worldwide)** :

HARO

SUR LES SILOS

“ Trouver la bonne gouvernance de la donnée, c'est loin d'être évident. Chez nous, la donnée a été, historiquement, toujours très silotée (marketing, digital, CRM, SI, service client, direction commerciale, DAF). La donnée est partout, mais traitée de façon isolée par des gens qui ne se parlent pas forcément, qui ne partagent pas ce qu'ils savent. Si l'on entend fluidifier la data, il est nécessaire d'organiser une gouvernance transverse de la donnée. ”

Numericable-SFR
Morgane Castanier
Directrice Data et CRM



“ Nous avons la conviction que la data, à partir du moment où elle n'est plus information brute, mais qu'elle a été transformée en information utile, doit permettre de piloter efficacement une organisation, et de prendre des décisions, que ce soit pour mieux adresser son marché, pour améliorer un service, etc... La data ne doit pas se trouver dans un silo en particulier, et le CDO ne doit pas être rattaché à un service particulier, mais aux services centraux. Une Data Driven Organisation se doit, avant toute chose, de casser les silos. ”

Publicis Worldwide
Samir Amellal
International Chief Data Officer



Cette ambition de briser les silos va toutefois se heurter à de nombreuses résistances. Voilà ce qu'explique **Samir Amellal (Publicis Worldwide)** :



Publicis Worldwide
Samir Amellal
International Chief Data Officer



Les silos peuvent s'avérer très résistants dans une entreprise et ce pour deux raisons principales :

- la première est d'ordre politique, car dans l'engouement autour de la data, tout le monde a l'ambition de prendre le lead, et donc de garder la main sur le sujet. Conserver sa donnée qui n'est autre que de l'information, c'est aussi, pense-t-on, conserver le pouvoir.
- la seconde est inhérente à l'organisation de l'entreprise. Lorsque celle-ci est mécanique, pyramidale, les silos se constituent naturellement. On voit apparaître aujourd'hui des entreprises digitales qui acceptent plus de porosités, utilisant la data comme un liant de toute l'entreprise.



Afin de réussir au mieux cette étape du désilotage il va donc falloir veiller à bien faire comprendre l'intérêt et les bienfaits d'une telle opération à toute l'entreprise. Ce qui passe, nous expliquent **Elisabeth Zehnder** et **Joël Aznar**, par trois étapes clés : la prise de conscience, une communication efficace en interne, et un sponsorship ferme.

“ Briser les silos, c’est le plus grand challenge de la data gouvernance. Et dans ce cadre, la première difficulté va être la prise de conscience de ce défi, sans laquelle on continuera à prêcher dans le désert. Chez nous il a fallu par exemple apprendre d’abord à améliorer la collaboration entre les fonctions Achats et Finance, pour prendre conscience qu’on avait besoin de part et d’autre d’un partage commun sur la cible à mettre en avant si l’on souhaitait relever des défis comme le “Source-to-Pay” par exemple. On ne peut pas se contenter de faire chacun de son côté la moitié du chemin. Il faut partager, intégrer les contraintes des uns et des autres, et ne pas se contenter d’imposer sa vision. Le sponsorship suit tout naturellement une fois qu’une telle prise de conscience a eu lieu. ”

Schneider Electric

Joël Aznar

Global Purchasing - Director,
Master Data Governance



OUVRIR LES YEUX, DISCUTER, ET TENIR FERMEMENT LA BARRE

“ Le sponsorship va aussi être crucial pour désiloter efficacement. Chez nous, le sponsor du projet data et connaissance client, c’est le Directeur web et marketing. Mais le DSI est aussi porteur du projet. ”



Kiabi

Elisabeth Zehnder

Data Scientist

MODE AGILE

Début 2001, des experts du monde du logiciel se réunissent aux Etats-Unis pour débattre de la meilleure façon de développer des applications informatiques au sein d'organisations confrontées aux premiers bouleversements du numérique. De leurs conversations naîtra le Manifeste agile (*Agile manifesto*), promouvant, face au modèle de développement en cascade, une méthode fondée sur quatre grandes valeurs : l'équipe (privilégier les interactions entre individus aux processus et aux outils), l'application (produire des logiciels opérationnels plutôt qu'une documentation exhaustive), la collaboration (collaborer avec les clients plutôt que négocier contractuellement) et l'acceptation du changement (s'adapter au changement plutôt que s'en tenir à un plan).

Au delà du monde de l'informatique où il a vu le jour, un tel état d'esprit trouve tout naturellement sa place dans des projets associés au Big Data. Il va non seulement promouvoir des façons de faire plus souples et rapides (test & learn, POC - proof of concept), mais aussi résoudre des problèmes de compétences (la rareté notamment des profils de data scientists) en mixant les équipes et en les incitant à collaborer étroitement. C'est sur ce dernier point qu'insistent **Christèle Baranco (LCL)** et **Morgane Castanier (Numericable-SFR)** :

LE CREDO DE LA SOUPLESSE ET DE L'INVENTIVITÉ

“ Afin de fonctionner en mode agile, et de bien faire travailler métiers et IT ensemble, nous avons mis en place des plateaux agiles qui mélangent des équipes techniques, des équipes qui font de la gestion de projet, des data scientists, et des gens du métier. Il faut pouvoir itérer en permanence, passer par des phases de sprint, montrer des avancées rapidement, en tirer des enseignements, et des usages. Nous avons actuellement une POC sur des données qui doivent nous permettre de déterminer des comportements de consommation chez nos clients. Nous la menons en mode agile, ce qui est bien perçu par nos équipes. ”



LCL
Christèle Baranco
Responsable Analyse
de la Donnée Client

“ Utiliser et généraliser les méthodes agiles, avec des core teams intégrant des gens du métier, des data scientists, des data managers et des ingénieurs, c'est capital. Nous sommes en train de mettre en place une gouvernance pour essayer d'en faire de plus en plus, car à chaque fois que nous avons eu recours à de telles méthodes sur des projets Big Data, cela s'est avéré fructueux. ”



Numericable-SFR
Morgane Castanier
Directrice Data et CRM

TEST & LEARN

Le monde du digital en général, et celui du Big Data en particulier, s'accommode mal des lourdeurs

et de l'inertie de la gestion de projet à l'ancienne. Il va au contraire exiger de la rapidité et de l'agilité dans les actions, et une capacité, aussi, à aller chercher l'innovation sans être paralysé par la peur de se tromper. Le test & learn, à la fois méthode de travail et façon d'appréhender le business très anglo-saxonne, s'accorde parfaitement à ces nouvelles exigences. Le principe : lancer un chantier à petite échelle, dont il va être possible de mesurer rapidement la pertinence et l'efficacité. Puis, dans la foulée, multiplier les retours d'expérience pour déterminer ce qui a bien marché, ce qui a moins bien marché, et ce qui n'a pas marché du tout. A partir de là, procéder touche par touche à l'amélioration du processus. La phase de test s'achève une fois que tous les enseignements ont été tirés, avec alors la possibilité soit de faire aboutir le projet en le déployant à plus large échelle, en l'industrialisant, soit de l'abandonner au profit d'un nouveau. Plus qu'une façon de faire, le test & learn constitue une disposition d'esprit, destinée, selon **Laurent Aliphat (Renault)** et **Tania Aydenian (Orange Technocentre)** à irradier dans toute l'entreprise :

“ Commencer humblement, puis itérer, réajuster, enrichir au fur et à mesure - bref, fonctionner en test & learn - nous adoptons la démarche du MVP (Minimum Viable Product) permettant de répondre aux besoins des clients. Cette approche trouve naturellement sa place au sein du Technocentre Orange. L'ambition est de tester ces nouvelles méthodes de travail à l'heure du numérique, au travers de programmes larges, complexes, et multiprofils. Cette approche a vocation à être étendue au sein des différents départements d'Orange. ”

Orange Technocentre

Tania Aydenian

Directrice du Programme
Datavenue



IN THE MOOD FOR TEST

“ La généralisation de l'approche en test & learn chez Renault est liée à la création de la Digital Factory il y a quatre ans. Déjà à l'époque, il s'agissait

d'un maître mot, qui incarnait la façon dont le management souhaitait que les équipes travaillent. Plus qu'un outil, c'est un état d'esprit, qui oppose, à des approches conservatrices, l'agilité, la mobilité, et l'envie de tester des approches innovantes. ”

Renault

Laurent Aliphat

Head of Digital
Performance and Lead
Management



Etape ultime de ce nouveau *mindset* : la dédramatisation de l'échec, considéré non plus comme une menace dans la conduite d'un projet, mais plutôt comme une opportunité de rebondir, poursuit Laurent Aliphat (Renault) :



Renault
Laurent Aliphat
 Head of Digital Performance
 and Lead Management



Quand une entreprise s'inscrit dans une démarche de transformation digitale, le test & learn est souvent

le premier maillon d'une chaîne qui très vite évolue vers le fail fast. Alors que dans le test & learn il faut toujours faire la preuve, apporter du feedback positif, le fail fast va exprimer le bénéfice de l'échec, et les apprentissages qui en découlent. Les récents exemples de succès dans l'univers des startups ou même dans les grosses entreprises qui ont réussi leur adaptation à un monde digitalisé, se sont appuyés sur ces énergies nouvelles qui apparaissent lorsqu'on supprime la peur de l'échec.





“ Les tâches d'extraction de valeur d'un jeu de données sont très diverses et variées. Parfois de qualité insatisfaisante, parfois de volume trop important, le jeu de données ne présente pas, en son sein, de tâche d'analyse à appliquer. Il est souvent nécessaire d'expérimenter plusieurs méthodes, de les confronter à la réalité du terrain, et retourner à l'expérimentation jusqu'à satisfaction du commanditaire final. Ainsi les méthodes d'analyse de données ont emprunté des méthodologies à d'autres domaines de compétences comme le développement informatique ou la création d'entreprise. Les méthodes test & learn font référence à un ensemble de pratiques abordées lors de la réalisation d'une tâche d'analyse pour un cas d'usage particulier. Ainsi, ce cas d'usage doit connaître une performance initiale qui doit être améliorée lors de la mise en production d'une nouvelle application utilisant une analyse de données. Un plan d'expérimentation doit pouvoir évaluer chaque maillon de la chaîne de traitement, et au fur et à mesure de l'amélioration des composants de la chaîne, une amélioration quantitative ou qualitative de la chaîne de traitement doit être apportée : jeu de données à hypothèse, à développement d'un test, à implémentation du test, à évaluation de l'amélioration de la performance, et ainsi de suite jusqu'à satisfaction. ”

Marc Damez-Fontaine
Senior Manager
PwC



3. ASPECTS TECHNIQUES

A/B Testing, Data warehouse, Real Time Bidding, API... Le monde du Big Data se définit d'abord par un fort degré de technicité, qui suppose de connaître et de manier un grand nombre de processus. Mais avant cela, encore faut-il pour les entreprises identifier ceux qui seront les plus à mêmes d'apporter des bénéfices concrets, et de déboucher sur des cas d'usage.

A/B TESTING

Cette méthode de test randomisé s'appuie sur un principe on ne peut plus simple : comparer les résultats

respectifs de deux variantes, la première, A, constituant la norme de l'expérience, la seconde, B, contenant un élément divergent susceptible d'avoir un impact sur la cible étudiée. Il s'agit donc d'une hypothèse de test à deux échantillons, qui va permettre d'identifier qui de A ou de B se montre statistiquement le plus performant. Utilisée initialement dans le marketing, cette technique a d'abord consisté, tout simplement, à proposer deux variantes d'un même objet différenciant en un point (le logo, la couleur d'une typo ou d'un paquet). S'étendant par la suite à une kyrielle d'autres situations, l'A/B testing est surtout devenu un incontournable de la communication en ligne et de la business intelligence, que l'on parle de campagnes d'emailing ou d'affichage de site web. Dans ce dernier cas, on va pouvoir tester sur deux groupes de visiteurs, deux versions différentes d'une même page en faisant varier un grand nombre de combinaisons (boutons, images, taille et emplacement des éléments, présence ou non de vidéos) jusqu'à élaborer la mouture la plus efficace.

En faisant dépendre un choix marketing non plus d'une intuition, mais d'un raisonnement assisté par de la statistique et de la donnée, l'A/B testing constitue un bon exemple de décision **data driven**. Même s'il ne s'agit pas à proprement parler de Big Data, sa généralisation au sein d'une entreprise est un bon indicateur de maturité digitale. Ce que soulignent **Angélique Bidault-Verliac (Voyages-sncf.com)** et **Max Vallejo (Air France – KLM)** :

“ Pour une compagnie qui se veut data driven, l’A/B testing est une vraie révolution. Avec une telle méthode il ne s’agit plus de procéder à une refonte de site du jour au lendemain sur la base d’une intuition, mais de modifier à la marge plusieurs petites choses concrètes qui amélioreront les KPI, et transformeront au fur et à mesure le site. Chez Voyages-sncf.com, nous souhaitons généraliser l’usage de l’A/B testing pour s’assurer systématiquement que les solutions qui performant le mieux seront aussi celles qui se trouveront exposées en priorité aux clients. ”

Voyages-sncf.com
Angélique Bidault-Verliac
Responsable du Pôle Data
& Webmining



“ Au moment de monter une campagne, nous allons procéder à un échantillonnage de 5% sur un en-tête A, et à un autre, de même valeur, sur un en-tête B. Celui qui scorera le mieux sera utilisé sur les 90% de la base restante. Cette logique d’A/B testing a des résultats incontestables, et c’est une méthode simple, facile à comprendre... pour peu que l’on définisse bien version A et version B, et que l’on maîtrise le concept de significativité. Pour qu’elle soit encore plus efficace, il faut être aussi capable de l’utiliser fréquemment et d’en faire baisser le coût opérationnel. ”

Air France-KLM
Max Vallejo
Head of eCRM,
Digital Department





Solocal Group - PagesJaunes
Bruno Guilbot
Responsable Smart Data
et Advanced Analytics



L'A/B testing est une manière simple de démontrer l'intérêt du Big Data pour l'entreprise, via des exemples concrets, des gains rapides et directement mesurés. C'est une très bonne première étape dans la démarche Big Data. Nous l'utilisons pour notre part en continu pour optimiser les performances de nos sites tant sur des aspects ergonomiques que sur les systèmes backoffice (algorithmes du moteur PagesJaunes par exemple). Lors de la refonte du site pagesjaunes.fr en début d'année nous nous sommes appuyés sur de nombreux tests A/B : cela nous a permis de faire évoluer très positivement le taux de clics vers nos professionnels, en changeant le wording ou des aspects graphiques (par exemple via l'ajout d'aides à la lecture). ”



Les tests A/B sont une technique qui consiste à expérimenter deux variantes d'un même objet auprès d'une même audience. Il s'agit par exemple, pour faire passer un même message, d'utiliser des visuels différents ou d'opter pour différentes stratégies en alternance – fréquence ou vélocité – avec toujours la même exécution créative. Cette technique peut également permettre de tester des créations de formats différents.

Lorsque les tests A/B sont utilisés en début de campagne, ils aident l'annonceur en lui indiquant très vite la création à laquelle l'audience répond le mieux. Cela permet d'optimiser en temps réel la campagne, avant qu'elle n'arrive à son terme, en choisissant la variante la plus fructueuse. ”

Kamal Mouhcine
Directeur Commercial en Europe du Sud
Turn



AD EXCHANGE

Cette plateforme technique qui permet de traiter et d'optimiser en temps réel les ventes et les achats programmatiques entre annonceurs et éditeurs, l'Ad Exchange constitue le cœur du RTB. Il vient ainsi apporter une réponse à deux aspects caractéristiques de la publicité display: la fragmentation et l'explosion de l'offre d'espaces d'une part. La volonté de faciliter et de mieux structurer le flux de données en tendant vers le temps réel, de l'autre. Son fonctionnement peut se résumer ainsi: l'API est chargée de pousser les impressions disponibles (et les audiences qui leur sont associées) vers les acheteurs potentiels. Après avoir pris en compte une multitude de critères de ciblage et de niveaux d'enchères définis au préalable, l'Ad Exchange fait matcher demande et offre. Cette automatisation des transactions fait que les enchères se déroulent non seulement en temps réel, mais sans qu'acheteur et éditeur n'entrent jamais en contact.

Stéphane Père (The Economist) compare un tel système aux plateformes de trading du monde de la finance, avec lesquelles il partage, outre les mécanismes de base, une certaine forme d'opacité :



Les Ad Exchange offrent la capacité de connecter l'offre et la demande en terme d'inventaires publicitaires, dans une logique de place de marché qui s'apparente au monde de la finance. Il s'agit d'une plateforme d'intermédiation et donc de trading. Il y a encore beaucoup d'intermédiaires entre offre, demande, et Ad Exchange, ce qui nécessite de se demander : qui capte la valeur ? Qui doit prendre la main ? D'autant qu'il s'agit là d'un monde en pleine mutation, qui est en train de se doter de règles d'usage qui n'existaient pas auparavant.



The Economist
Stéphane Père
Chief Data Officer (Global)



API

Les *Application Programming Interface* (interface de programmation) sont des solutions informatiques regroupant un ensemble de méthodes, de fonctionnalités, et de routines, qui vont s'intercaler entre un logiciel et d'autres logiciels, afin de permettre aux seconds (programmes consommateurs) d'utiliser les fonctionnalités du premier (programme fournisseur). Une API est ainsi, en quelque sorte, une porte qui, tout en masquant la complexité intrinsèque d'un système, ouvre l'accès à un certain nombre de ses fonctions standard. De même qu'un conducteur n'a pas besoin de connaître le fonctionnement du moteur de sa voiture pour se servir d'un volant, un développeur n'aura ainsi pas à se soucier du fonctionnement réelle d'une application distante pour l'utiliser dans un programme.

“ Pour restituer la donnée collectée ou achetée sur le marché, il faut des API. Ce sont elles qui vont permettre de s'interfacer avec des acteurs externes à l'entreprise. ”



Groupe Argus
Benoît Chéroux

Nombreuses sont les entreprises à être attirées par les promesses de simplification et de nouveaux usages offertes par les API, comme en témoignent **Benoît Chéroux (Groupe Argus)** et **Aude Launay (Bouygues Telecom)** :

DES API FEW DE PLUS EN PLUS NOMBREUX!



Un exemple d'utilisation d'API : éviter aux banques de couper les cartes bancaires à mauvais escient lors d'un paiement à l'étranger, en recoupant la localisation du pays de retrait avec celui du mobile. Nous sommes en train de réfléchir à une offre de ce genre autour d'une API en temps réel utilisée quand les banques émettent un doute sur l'utilisation frauduleuse de la carte. Actuellement elles préfèrent couper les cartes, avec les inconvénients afférents lors d'une utilisation classique pour les touristes concernés. ”

Bouygues Telecom
Aude Launay
Big Data Business Manager



Nous commençons à déployer nos premières API, ouvertes dans un premier temps à nos clients, puis au marché. Ces API permettront

d'abord de donner accès à deux types d'information :

- le référentiel véhicule (l'ensemble des véhicules commercialisés en France depuis plus de 30 ans) : liste des marques, modèles, éléments techniques... qui pour l'instant n'était livré que sous forme de fichier
- la cote Argus®, à laquelle on pourra désormais accéder via une API de valorisation contenant également nos indicateurs Valeur Argus Transactions® et Valeur Argus Annonces® (entre autres). ”

Groupe Argus
Benoît Chéroux
Responsable Données &
Modélisations



Cependant, comme le souligne **Nicolas Gaude (Bouygues Telecom)**, malgré ce fort intérêt pour les API, le marché a encore besoin de gagner en maturité pour pouvoir profiter à plein de leur efficacité :



Pour l'instant, les offres Big Data offertes aux entreprises sont plutôt packagées sous la forme de services professionnels que sous la forme de données pures à proprement parler. A terme cependant, lorsque le marché sera plus mûr, on se mettra à acheter de la donnée enrichie. C'est dans ce cadre que les API, au sens SaaS, pourront aider à fluidifier les échanges. Aujourd'hui, certes, l'appétence qu'a le marché pour les API est forte, mais dans les faits, lorsqu'elles sont mises à disposition, les entreprises ne savent plus quoi en faire et requièrent une prestation de conseil associée.



Bouygues Telecom
Nicolas Gaude
 Senior Data Scientist



CLOUD DATA SERVICES

En dématérialisant l'usage qui est fait des données, les Cloud Data Services constituent pour l'architecture informatique des entreprises l'opportunité d'une évolution vers plus de flexibilité. Outre cet impact sur la structure même des systèmes d'information, ils vont aussi se révéler une formidable opportunité business pour celles et ceux qui sauront les utiliser à bon escient. L'intérêt croissant que suscite ce *mind changer* n'est du reste pas prêt de se démentir. D'autant qu'il constitue une façon idéale d'aborder, pour la première fois, le vaste territoire des Big Data.



Les Cloud Data Services permettent de se familiariser avec des traitements nouveaux de la donnée, et de mettre un premier pied dans les Big Data. Au début, on va commencer par un sandbox, un POC. Puis, on va passer au cloud, sur lequel il ne sera pas nécessaire d'investir un budget trop important. Et enfin, on opérera une transition vers des solutions plus hybrides. En somme, les Cloud Data Services sont une bonne option pour les PME qui n'ont pas la possibilité d'avoir leurs propres infrastructures. Pour les sociétés du CAC 40, ça va être surtout un bon début, mais elles ne pourront, à terme, s'en contenter.



Sogeti

Aroua Biri

Architecte Cybersécurité & Big Data



SNCF

Maguelonne Chandesris

Responsable de l'équipe Innovation

& Recherche «Statistique, Econométrie et Datamining»



On a l'impression que le cloud, c'est la dématérialisation de la donnée. Mais l'hébergement de la donnée dans des serveurs physiques, c'est quelque chose qui est très concret, et qui a, par exemple, un vrai impact écologique. On ne se pose pas aujourd'hui la question de l'économie globale autour de la donnée, car on est encore dans une phase d'abondance, et pas d'efficacité.





JURIDIQUE

Hoche Avocats



La notion de “cloud computing” recouvre des services différents selon les prestataires et les contrats proposés laissent parfois le client dans le brouillard...

Une définition “officielle” a été publiée au Journal Officiel du 6 juin 2010 : *“Le cloud computing est une forme particulière de gérance de l’informatique, dans laquelle l’emplacement et le fonctionnement du nuage ne sont pas portés à la connaissance du client”.*

En pratique, on constate cinq caractéristiques essentielles au Cloud Computing.

- Le **“self-service à la demande”**
(c’est le client qui détermine ses besoins en capacité de calcul, de stockage, etc., le service lui est rendu, sans intervention humaine, de manière automatique,
- Le **“large accès au réseau”**
via une multiplicité d’appareils permettant de se connecter à l’internet (PC, Mac, tablettes, smartphones...),
- La **“mise en commun de ressources”**
qui permet de servir plusieurs clients à partir d’une installation unique. Les ressources physiques et virtuelles sont attribuées de manière dynamique en fonction de la demande. Le client ignore la localisation des ressources mises à sa disposition, mais peut prévoir une localisation dans un pays ou un data center spécifique.

- La **“grande souplesse”**

permettant au client de demander, à tout moment, toute “quantité” en termes de puissance informatique, sans limitation, de sorte à l’adapter, à la hausse comme à la baisse à ses besoins,

- La **“mesure des services”**

qui permet une transparence en termes de “quantité” et de “qualité” de service.

Il existe 3 modèles principaux de fourniture de service (“as a Service”) du Cloud Computing :

- Infrastructure as a Service (**IaaS**),
- Platform as a Service (**PaaS**),
- et Software as a Service (**SaaS**).

Le plus souvent les offres de services “cloud” sont proposées par le prestataire sous forme de contrat d’adhésion (contrat en principe non négociable).

L’explication réside dans le fait que le “Service” est modélisé pour le plus grand nombre et que tant la construction technique qu’économique de l’offre est fondée sur ce principe.

La capacité de négociation de tels contrats dépend donc le plus souvent de la taille du prestataire... Le client, s’il ne peut négocier, pourra toujours comparer les conditions contractuelles proposées par les différents prestataires. En effet, les engagements d’un prestataire peuvent être plus ou moins adaptés à ses besoins.

Le client veillera plus particulièrement aux clauses relatives aux niveaux de services (le plus souvent regroupés au sein d’une convention de services ou “SLA”), aux conditions de réversibilité, à la limitation de responsabilité du prestataire et aux modalités de détermination du prix.

Les enjeux d'un contrat de SaaS

Le SaaS ne fait pas l'objet d'une définition légale et peut selon les prestataires revêtir différentes formes. On comprend dès lors l'intérêt d'une rédaction précise des droits et obligations de chaque partie dans le contrat qui va les lier.

Le service sous mode SaaS consiste à fournir à un client la possibilité d'utiliser via l'internet, sur une infrastructure de type "cloud", des applications ou logiciels mis à sa disposition par le prestataire.

Les applications sont accessibles sur les différents équipements du client soit par le biais d'une interface client, en usant d'un navigateur web (par exemple, pour le cas d'une messagerie électronique), soit par le biais de l'interface d'un programme. L'utilisateur ne gère pas ou ne contrôle pas l'infrastructure cloud sous-jacente, incluant le réseau, les serveurs, les systèmes d'exploitation, les systèmes de stockage et même les capacités de chacune des applications, sauf dans le cas où l'application fait l'objet d'une limitation quant au nombre d'utilisateurs, en raison de configurations spécifiques.

L'offre SaaS peut impliquer l'intervention de plusieurs prestataires (le prestataire principal qui conclut avec le client, l'éditeur qui fournit le logiciel ou l'application, un hébergeur, un prestataire assurant les sauvegardes, un fournisseur d'accès à internet...) ce qui génère des enjeux juridiques différents pour le prestataire de solution SaaS et le client.

Le client veillera à avoir pour seul interlocuteur contractuel le prestataire de services SaaS (et selon les cas le fournisseur d'accès à internet).

C'est avec celui-ci qu'il va négocier les éléments principaux du contrat :

- disponibilité du service (temps d'intervention et de résolution des anomalies, pénalités applicables),
- performance du service (temps de réponse, pénalités applicables),
- conditions d'évolution du service,
- prix (modalités de détermination et de paiement),
- hébergement des données (dans certains cas le client souhaitera que ses données soient hébergées en France ou dans l'Union Européenne)
- sécurité des données (confidentialité, cryptage, intégrité, disponibilité),
- garantie d'éviction quant à l'utilisation des logiciels ou applicatifs,
- responsabilité en cas de perte de données (limitation de responsabilité, assurance),
- réversibilité (procédure de réversibilité et mise à jour, prix).

Le prestataire de la solution SaaS veillera quant à lui à répercuter a minima sur ses différents prestataires ou sous-traitants les obligations qu'il aura lui-même souscrites envers son client. ”



Hoche Avocats
Régis Carral
Avocat – Associé

DATA MINING

Aussi appelé exploration ou fouille de données, le data mining consiste à extraire de la connaissance et

des apprentissages dans les monceaux d'informations stockées par les systèmes informatiques. Grâce à un ensemble d'**algorithmes** issus du monde de la statistique et de l'intelligence artificielle, cette phase d'exploration va permettre de tirer des enseignements de la donnée, et, in fine, de la valeur. Pour le monde des entreprises, il s'agit là d'une aubaine qui intéressera aussi bien le secteur de la connaissance client (optimisation des sites web et des parcours utilisateurs), que celui de la sécurité (renforcement des dispositifs de **data safety**) ou l'industrie (nouvelles opportunités offertes par la **maintenance prédictive**).

Comme le fait remarquer **Pascale Dulac (France Loisirs)**, le data mining n'est toutefois pas une discipline nouvelle, mais plutôt un champ qui va trouver une ampleur nouvelle à l'ère du Big Data :



France Loisirs
Pascale Dulac
Responsable Connaissance Clients



Nous avons une équipe de data mining quasiment depuis une éternité ! Les nouveaux usages vont tourner autour de l'enrichissement de l'information présente dans nos bases, rechercher, étape par étape, de nouvelles sources pour affiner ces dernières. L'arrivée du Big Data va se traduire par un changement progressif de ces équipes de data mining pour tenir compte des nouvelles exigences technologiques, et surtout de la nouvelle façon d'appréhender la donnée dans son ensemble. ”

Le data mining regroupe plusieurs sous-disciplines d'extraction de données, comme la fouille de textes (**text mining**), de sites internet (web data mining), d'images (image mining) ou de flot de données (data stream mining). Il va également constituer une étape cruciale dans certaines disciplines data driven, à commencer par le **machine learning** comme l'explique Nicolas Gaudé (**Bouygues Telecom**).

“ Le data mining est une étape capitale pour extraire les bonnes données, et éviter que les machines, via le machine learning, se retrouvent à apprendre du bruit. Il est pour l’instant nécessaire d’avoir une barrière à l’entrée, un être humain qui va sélectionner les données pour éviter que la machine ne se perde. ”

Bouygues Telecom
Nicolas Gaudé
Senior Data Scientist



DATA WAREHOUSE

Les entrepôts de données sont des bases dans lesquelles vont être stockées une partie des données

fonctionnelles d'une entreprise en vue de leur utilisation pour des usages précis. L'information qui entre dans les data warehouses est issue de sources hétérogènes, ce qui va nécessiter de les homogénéiser pour permettre de les qualifier et de les intégrer. Ce n'est ainsi qu'une fois que les données auront été structurées qu'elles pourront être mises en rayon. On y aura alors recours pour des analyses précises, et récurrentes, en suivant des routines clairement définies. Dans ce sens le data warehouse a une forte connotation silo – il va stocker un certain type de données qui seront structurées en fonction d'un certain type d'usage – contrairement au **data lake** qui gardera la donnée dans son format natif, permettant de l'interroger par la suite dans le cadre d'analyses très variées. Ces deux fonctions ne s'opposent pas, et sont au contraire complémentaires. Le data warehouse se montrant notamment bien plus performant pour procéder à des analyses répétitives.



Voyages-sncf.com
Angélique Bidault-Verliac
Responsable du Pôle Data & Webmining



Chez nous, la notion de data warehouse est historiquement connectée à de la donnée « froide » collectée à j+1 (achats, éléments clients) même si on y injecte des données de navigation sous forme d'agrégats.

Ces data warehouses traditionnels ont été chamboulés par l'arrivée d'Hadoop. Le nôtre, qui a une dizaine d'années, s'appuie sur une donnée nettoyée et structurée, sur laquelle nous produisons directement tous nos reportings utilisés pour le pilotage business. La coexistence de cet environnement ancien, fort d'une longue expérience, avec les nouveaux environnements plus orientés Big Data, est un défi parfois compliqué à tenir, et qui nous fait nous poser plusieurs questions, dont la principale n'est pas la plus simple à trancher : doit-on faire évoluer notre data warehouse actuel ou bien le remplacer purement et simplement par de nouvelles solutions technologiques permettant le passage au temps réel et susceptibles de bousculer nos méthodes de reporting ? ”

LOOK-ALIKE MODELING

Comment dénicher, dans l'immense masse indéterminée des internautes qui se connectent au site d'une entreprise, les profils de ceux qui s'avéreront les plus intéressants pour cette dernière ? C'est à cette question que sont censés répondre les modèles de look-alike. La méthode permet d'assimiler, grâce à son cookie de navigation, un individu dont on ne sait a priori rien, à un type de comportement déjà bien connu (parce que clairement identifié dans sa **DMP**) et qui a été étiqueté comme porteur de valeur. Cette recherche de jumeaux statistiques va ainsi accroître l'audience qualifiée qui sera ensuite visée par des campagnes marketing.

“ *Le look-alike modeling, cela ressemble beaucoup à du prédictif appuyé sur du scoring. C'est un produit de l'A/B testing auquel nous avons beaucoup recours pour analyser des comportements post achat.* ”

GrandVision
Pierre-Marie Desbazeille



La simplicité théorique de ce modèle de recherche de prospects à haut potentiel attire de nombreuses entreprises... qui commencent déjà à en récolter les fruits, comme le confirment **Pascale Dulac (France Loisirs)** et **Jonathan Badoux (AXA France)** :

CHACUN CHERCHE SES JUMEUX STATISTIQUES

“ Dans nos campagnes de recrutement sur internet, nous avons commencé à mettre en place, au printemps, des logiques de recherche de jumeaux. Il s’agissait par exemple de rechercher des profils de gros lecteurs, pour pouvoir cibler plus tard plus facilement en amont les gens susceptibles d’être intéressés par certaines de nos offres. Les résultats se sont avérés plutôt bons, mais pour qu’ils soient encore meilleurs, il va nous falloir affiner le processus. ”

France Loisirs
Pascale Dulac
Responsable
Connaissance Clients



“ Le look-alike modeling est un sujet qui a extrêmement bien marché chez nous. Sur nos parcours e-business sur site, nous cherchons à identifier via les informations indiquées par les répondants s’ils constituent des prospects à forte valeur ou non. Pour cela, nous allons par exemple, dans le secteur de l’automobile, utiliser des critères comme le type de véhicule, la durée de détention, l’ancienneté de permis, la sinistralité, le coefficient de réduction, etc. Grâce à ça, on est en mesure dans un premier temps d’établir des scores de valeur. Puis le look-alike modeling va permettre de modéliser, dans un *bucket* de profils inconnus, ceux qui sont les plus proches des profils connus détenteurs des plus hauts scores. On va pouvoir dès lors les cibler en média, et vérifier la pertinence du score. Par rapport à un taux de prospects à forte valeur naturelle, le taux des prospects ciblés après ce travail en look-alike modeling a vu sa valeur multipliée par deux. ”

AXA France
Jonathan Badoux
Responsable Outils Digitaux





The Economist
Stéphane Père
Chief Data Officer (Global)



Le look-alike modeling permet souvent de se rendre compte qu'il n'existe en réalité pas réellement d'attribut décisif pour définir un profil type. Mais plutôt une somme d'attributs. Alors qu'auparavant le media planing traditionnel reposait sur des critères précis (âge, sexe, éducation, revenus, centres d'intérêts), nous avons tendance aujourd'hui à identifier nos prospects en partant de nos abonnés. Nous utilisons le look-alike pour les cibler et avons une stratégie qui va adapter les créas au centre d'intérêt ainsi qu'au contexte de diffusion.

Les profils, vont être une somme de tous les critères accumulés par la DMP, si bien qu'au final, nous nous affranchissons de la logique catégorielle. Le ciblage des profils pertinents fonctionne un peu comme une black box, mais permet pourtant une vraie hausse du taux de transfo. ”



Le grand potentiel du look-alike modeling aujourd'hui repose sur l'émergence récente d'acteurs ouvrant des bassins d'audience gigantesques à la publicité, comme Facebook ou Amazon. Les dernières évolutions technologiques et statistiques ont révolutionné les façons d'acheter la publicité : plutôt que de cibler des segments descriptifs sur la base d'intuitions et de préconceptions (ex : mon produit A est conçu à destination des hommes de moins de 35 ans vivant en milieu urbain, je vais donc cibler ce segment), on peut désormais s'affranchir de la recherche de caractéristiques descriptives pour qualifier une cible. Adieu la ménagère de moins de 50 ans ! On peut désormais par exemple, à partir d'une liste d'individus connus dont le seul point commun identifié par l'humain sera d'avoir fait 3 achats dans les 6 derniers mois sur un site, trouver des individus inconnus, dont on prédit qu'ils en feront de même s'ils sont amenés sur le site. Les machines peuvent en effet prendre en compte des combinaisons de variables que l'esprit humain ne pourrait synthétiser en concepts, et les analyser en quantités bien supérieures. Les larges bassins d'audience qualifiés des grands acteurs publicitaires cités plus haut permettent alors de trouver des profils jumeaux de façon très fine. ”

Lan Anh Vu Hong
Marketing Lead

55



MASTER DATA MANAGEMENT

La Gestion des Données de Référence (GDR, mais l'on utilisera plus communément l'acronyme anglais MDM pour Master Data Management) peut être définie comme un ensemble de processus délimitant le cadre dans lequel les données référentielles d'une entreprise devront être utilisées. Des « données maîtres » qui peuvent être schématiquement divisées en trois grands ensemble visés par cette gestion interne : données financières, données clients, et données produits. En réalité, leur nature peut varier d'une entreprise à l'autre en fonction du cœur de métier.



Schneider Electric

Joël Aznar

Global Purchasing - Director, Master Data Governance



Chez Schneider Electric, au sein du périmètre des achats, nous avons défini cinq domaines Master Data :

- le référentiel fournisseur : pour tout ce qui concerne les achats externes (hors groupe)
- le référentiel « materials/products » : relatif aux composants, biens et services que nous achetons et pour lesquels nous gérons certains attributs
- les contrats : les conditions d'achats dont notamment les prix
- les acteurs de la fonction achats : cela inclut la gestion des accès, des rôles et responsabilités, droits et autorisations dans un soucis de "Governance Risk Compliance" (GRC)
- les données liées au domaine finance et mises en œuvre dans les processus : pour assurer un haut niveau de coordination cross-fonctionnelle entre ces deux métiers.



La MDM introduit une vision globale des données maîtres, qui va à l'encontre des logiques d'utilisation traditionnelle en silo. Une logique centralisatrice mise en avant par les différents acteurs que nous avons pu interroger sur la question :

“ Notre MDM aujourd’hui, c’est un référentiel client unique qui sert de pivot à toute la connaissance client, et communique avec l’ensemble de nos applicatifs (gestion fidélité, gestion de campagne marketing, ...) On peut ainsi gérer toute la data client en un seul endroit, sans être tributaire d’un autre système. ”

Kiabi
Elisabeth Zehnder
Data Scientist



“ Pour le résumer brièvement, le Master Data Management recouvre la capacité, indépendamment des systèmes techniques sous-jacents, à gérer efficacement des données de références qui peuvent être de plusieurs types (clients, produits,...), de manière à ce que celles-ci soient complètes, cohérentes et exactes. Il a été nécessaire, dès la fin des années 90, d’avoir une approche globale de ces questions, en raison de l’introduction des normes Bâle II. Il a fallu rapatrier les informations sur les crédits et les avoirs des

clients dans le monde entier, ce qui a supposé de centraliser l’information sur ces clients au niveau global.

“ Le Master Data ne s’accommode pas de modèles locaux. Il faut une approche globale, et très intégrée si l’on veut en profiter à plein. On ne peut pas partir du principe que l’on va faire communiquer toute la diversité de points de vue de chaque BU, de chaque ERP. À un moment donné, il faut mettre de l’ordre, et de la rigueur. ”

LES EFFETS UNIFICATEURS DU MDM

Nous avons construit au tournant des années 2000 un premier référentiel au niveau mondial, d’abord pour les gros avoirs (16 millions de clients sur 80 au total). Ce référentiel est actuellement complété pour couvrir la totalité des 80 millions de clients. ”



Schneider Electric
Joël Aznar
Global Purchasing -
Director, Master Data
Governance

Directeur MDM
d’un grand groupe bancaire



Dans les entreprises et les organisations, les données se sont accumulées en silos. Les sources se sont multipliées et souvent, elles sont restées indépendantes les unes des autres, donnant lieu à des incohérences, des duplications ou des temps de traitement longs.

A l'heure du multicanal, il est primordial de disposer d'une vue 360° du client, c'est-à-dire une vue exhaustive, transverse et cohérente des informations. Le MDM en est la clé d'entrée.

Le MDM est une initiative stratégique pour l'entreprise. C'est un pilier fondateur de l'entreprise, qu'il s'agisse de clients, de produits, d'équipements... De plus, dans le contexte des data lakes, le MDM devient l'étape préalable incontournable pour disposer d'un référentiel unique à toutes les informations structurées et non structurées qui sont déversées dans ces nouveaux réservoirs.

Si l'état de l'art oriente les architectures vers des référentiels transactionnels, il est évident que toutes les organisations ne sont pas prêtes à cela, ni techniquement, ni psychologiquement. Les référentiels virtuels constituent alors une alternative. Ils permettent la mise en place très rapide de projets tactiques. Ils offrent un excellent moyen de démarrer sa transformation en offrant une implémentation facile et légère sans aucun impact sur les systèmes sources. C'est un excellent moyen de créer immédiatement de la valeur ajoutée à partir des données perdues dans l'éclatement des silos.”

Dan Benouaisch
Directeur Technique Analytics
IBM France



MODÈLES D'ATTRIBUTION

En autorisant une lecture à la fois plus fine et plus globale des leviers marketing ayant contribué à une vente ou à une conversion, les nouveaux outils d'analyse de la donnée invitent le marketing à repenser ses modèles d'attribution. Quelle importance donner aux impressions par rapport au clic ? Combien de temps peut-on considérer qu'une publicité vue, ou bien un clic, a encore un impact sur un prospect ? Comment évaluer la valeur de tel canal par rapport à tel autre ? Si le modèle d'attribution au last click reste aujourd'hui ultra-majoritaire (79% des entreprises n'utiliseraient que lui, selon une étude de l'IFOP), ses limites sont bien connues de la plupart des acteurs. En ne prenant en compte que le dernier clic avant la vente, il évacue tous les autres points de contact, dont certains peuvent avoir eu pourtant un rôle déterminant (par exemple, le premier clic qui initie le rapport entre l'internaute et la marque). Certains modes d'achat comme le **RTB** dont le taux de conversion est bien plus faible que d'autres, vont se retrouver de facto marginalisés dans une approche ROIste pure. D'où l'apparition de nouveaux modèles qui tentent de rendre leur importance relative aux autres points de contact en amont du chemin de vente : attribution linéaire qui donne à chaque point une valeur identique, dépréciation temporelle, qui donne de plus en plus d'importance à tel point à mesure qu'il se rapproche de la conversion, ou modèle en U qui attribue plus d'importance aux premiers et derniers contacts, sans pour autant effacer entièrement l'importance des intermédiaires.

L'idée d'un schéma idéal valant pour toutes les entreprises est de toute façon à exclure. En matière d'attribution, les modèles doivent se construire au cas par cas, et être suffisamment souples pour évoluer en permanence. Chez **Renault**, de nouveaux modèles d'attribution multitouch sont ainsi testés actuellement sur les marchés les plus avancés du groupe... avec des retours très positifs, explique **Laurent Aliphat** :



Renault
Laurent Aliphat
 Head of Digital Performance and Lead Management



La question du modèle d'attribution est une problématique récurrente dans le monde du marketing. Le modèle d'attribution à la dernière touche (c'est à dire le fait d'attribuer

la conversion au dernier élément de la chaîne qui va la susciter) est de loin le plus répandu : outre qu'il est simple à comprendre, il permet de structurer dans un premier temps sa pensée dans une approche ROIste des investissements à la performance. C'est un mode d'attribution qui montre toutefois très vite ses limites, les outils délivrant cette mesure se révélant souvent juge et partie, et ayant tendance à privilégier des solutions publicitaires connexes. Chez nous les marchés les plus avancés commencent donc à se diriger vers de l'attribution multitouch, qui permet de créditer chacun des points de contact en fonction de la contribution qu'ils ont aussi bien sur l'engagement que sur la conversion. Nous n'avons pas encore généralisé ce mode d'attribution, mais les résultats sont intéressants, et permettent de challenger les équipes en bout de chaîne chargées des investissements média. ”





Dans le monde de la publicité digitale, l'attribution est une technique qui permet d'identifier la ou les publicités qui ont poussé un consommateur à effectuer l'action désirée, notamment l'acte d'achat. Au lieu d'imputer la réussite exclusivement à la dernière publicité vue par une personne avant sa conversion – ce qui confère en général une grande importance aux activités situées à la base de l'entonnoir telles que le reciblage et les requêtes –, l'attribution multi-touch permet de créditer plusieurs publicités en fonction de leurs contributions correspondantes.

L'attribution multi-touch est une problématique majeure pour la publicité digitale, puisqu'un grand nombre de canaux sont concernés – le search, display, réseaux sociaux, mobile et vidéo. En lançant des campagnes médias sur une seule plateforme, puis en superposant les résultats de ces campagnes avec les données propriétaires («first party data») relatives à la conversion des clients, les annonceurs sont davantage en mesure d'évaluer les résultats afin de comprendre le chevauchement entre appareils/canaux, la livraison par appareil, l'attribution et les performances globales de la campagne. ”

Kamal Mouhcine
Directeur Commercial en Europe du Sud
Turn



OPT-IN

La collecte des données personnelles (et notamment celle d'adresses électroniques) passe par l'obtention, en amont, du consentement de l'internaute. Cet opt-in peut revêtir plusieurs formes : opt-in passif par lequel l'internaute doit cocher volontairement une case pour permettre l'utilisation ultérieures de ses données ; l'opt-in passif, lorsque la case est pré-cochée ; l'opt-out actif, qui contraint l'internaute à cocher une case pour, cette fois, ne pas être ciblé ; et l'opt-out passif, où il est inscrit d'office, et devra par la suite procéder à des démarches pour obtenir sa désinscription. Dans ce domaine qui touche directement à la data privacy, et à la confiance des utilisateurs en une marque, les entreprises n'ont d'autre choix que de définir une politique claire, et adaptée à leur cas particulier, ainsi qu'à leur implantation géographique – les contraintes légales encadrant l'opt-in variant grandement entre les pays. D'où des modèles d'opt-in variant d'une société à l'autre. En voici quelques exemples :

“ Les commerciaux ont souvent plus une démarche qui va dans le sens de l'opt-out.

CHACUN SON OPT-IN,...

Mais dans le domaine de la recherche, c'est l'opt-in qui domine, toutes les règles régissant la recherche biomédicale impliquent le consentement éclairé de toutes les personnes participant aux recherches. L'opt-in est le standard pour tout ce qui concerne la recherche médicale. On se tourne dans une minorité des cas vers l'opt-out par la suite, si l'on est confronté à des données massives sans possibilité d'avoir accès facilement aux personnes. ”

Sanofi
Pierre-Yves Lastic
Associate Vice President, Chief Privacy Officer



“ Notre position est simple : le consommateur est propriétaire de sa donnée. Il doit donc donner explicitement son consentement pour que l’on puisse la partager. En sachant qu’il se montre en général plutôt ouvert à ce consentement s’il obtient en contrepartie un service digne de ce nom et une bonne connaissance de l’usage qui sera fait de sa data.

Créer un tel cercle vertueux autour du consentement suppose donc à la fois un rapport gagnant gagnant, et une grande transparence. ”



Orange Technocentre
Tania Aydenian
Directrice du Programme Datavenue

...CHACUN SON CHEMIN

“ Il n’y a pas un opt-in mais plusieurs opt-ins, en fonction du contexte du client. Il va ainsi y avoir une différence entre les communications commerciales où l’opt-in va être indispensable, avec possibilité de se rétracter et facilité de désabonnement, et les notifications opérationnelles liées au voyage : dans ce cas-là, évidemment, on n’attend pas le consentement du client pour lui envoyer le billet qu’il vient d’acheter, ou des notifications importantes sur son vol. On va également proposer aux clients de notre site un cycle de newsletters orchestrées qui s’arrêtera après le voyage, communication que l’on utilisera comme une opportunité de cross selling. ”

Air France-KLM
Max Vallejo
Head of eCRM, Digital Department



“ En tant qu’organisme de santé, le flou juridique sur certaines questions autour de la donnée est un vrai problème pour nous. La collecte d’un opt-in clair auprès de nos clients en magasin revêt donc une dimension centrale. Dans l’un de nos magasins pilotes, nous avons développé un service de wireless charging en échange d’un consentement. A partir de ce moment là, on va pouvoir réconcilier une Mac Adress, un dispositif mobile, avec un individu... Ce qui permettra à notre plan de tagging d’aller jusqu’au bout de sa démarche. Il faut donc obtenir un double opt-in : l’opt-in classique sur notre site, et celui récolté en magasin par lequel le client va se rendre compte du fait qu’il a été tracé. ”

GrandVision
Pierre-Marie Desbazeille
Directeur CRM & Digital



On le voit au travers de ces exemples, il n'existe pas, en matière d'opt-in, de modèle idéal et univoque. C'est au contraire un sujet complexe, auquel il faut accorder le temps d'une vraie réflexion, comme le souligne **Stéphane Père (The Economist)** :



De manière intuitive, il semble évident de demander un opt-in à n'importe quel consommateur visitant un site. Mais la distinction service versus marketing promotionnel n'est pas toujours évidente. Se pose aussi la question de savoir ce qu'est un vrai opt-in, entre opt-in explicite et implicite, ou un opt-in dont les conditions d'utilisation ne sont pas claires. Quand un opt-in devient par exemple une condition sine qua non d'accès au service, c'est un problème!

Autre difficulté : la valeur de la donnée vient d'autres usages que celle pour laquelle on la collecte initialement. Par exemple, les usages inventés autour des données géolocalisées qui vont permettre de prédire le trafic, ce qui ne gêne personne. Il faut commencer à réfléchir plus loin, à penser déjà en terme d'équité de comportement responsable en tant que marketeur, plutôt que de se cacher derrière une case à cocher.



The Economist
Stéphane Père
 Chief Data Officer (Global)



RTB*

** Real Time
Bidding*

Apparu au cours de l'année 2010, ce nouveau mode d'achat a chamboulé le paysage du marketing. Alors que la publicité digitale traditionnelle reposait sur un modèle de vente et d'achat d'espaces de gré à gré - l'annonceur, en fonction de ses besoins d'affichage, négociait avec les éditeurs la mise à disposition d'emplacement - le Real Time Bidding (ou enchères en temps réel) a automatisé ce processus, permettant de piloter les campagnes en direct, grâce à la data. Le principe est simple : à chaque fois qu'un visiteur arrive sur une page équipée de bannières publicitaires RTB, son profil est instantanément mis en vente sur une plateforme d'enchères en ligne (les [Ad Exchange](#)). Les annonceurs intéressés par ce profil placent alors leurs mises, et le plus offrant remporte le droit d'afficher sa publicité sur la bannière proposée. L'ensemble du processus se déroule en un dixième de seconde.

Une telle évolution a des conséquences qui vont bien au-delà de la simple automatisation des achats médias. Avec le RTB, il ne s'agit plus de choisir un emplacement publicitaire (visible par toutes personnes connectées sur le site), mais de cibler des audiences (qui seront les seules à voir la publicité s'afficher). Plus besoin par exemple pour le marketing de présupposer qu'une bannière pour une paire de talons hauts sera plus susceptible de faire mouche sur le site d'un magazine féminin que sur un forum de fans de football. Sans a priori, en analysant les profils des visiteurs (renseignés grâce à des cookies fournissant sur chaque internaute, informations socio-démographiques, affinités avec tels produits, ou tels champs d'intérêt), un algorithme se charge d'aller chercher lui même l'audience qualifiée... quel que soit l'endroit où celle-ci se trouve !

Ce mode d'achat trouve de plus en plus sa place au sein du plan média des entreprises, et représente aujourd'hui, en France, près de 24% des ventes totales d'inventaire en display (Observatoire de l'e-pub SRI 2015). Certains secteurs en sont particulièrement friands, alors que d'autres peinent à y voir pour l'instant de l'intérêt, comme le confirment **Fabrice Otaño (AccorHotels)** et **Jonathan Badoux (AXA France)** :

RTB, UN ENGOUEMENT À DEUX VITESSES

“ Dans le métier de l'hôtellerie (tout du moins dans la partie distribution) 60% des réservations se font via des canaux digitaux (web, mobile, call centers...). La bagarre de l'acquisition du client va donc avoir lieu sur le search et le display, face à des acteurs très puissants comme Booking.com, capables d'investir plus d'un milliard d'euros dans Google. Nous investissons donc nous mêmes beaucoup sur le search, mais aussi sur le RTB qui permet de suivre, via des bannières, nos futurs clients lorsque ceux-ci changent de site. Cet outil d'enchères en temps réel prend d'ailleurs une proportion de plus en plus grande dans notre marketing. ”



AccorHotels group
Fabrice Otaño
SVP, Chief Data Officer

“ Certains acteurs comme AXA France, fortement dépendants au search et à l'affiliation, ne trouveront pas forcément une rentabilité immédiate en utilisant le RTB et ce malgré l'impact du ciblage data et des algorithmes tels que le look-alike. Tout du moins en utilisant des indicateurs aussi court-terme que le post-click. L'analyse du cycle de vie client et des data pertinentes pour signifier l'intention d'achat sont très importantes pour appréhender l'utilisation de ce canal, et évaluer sa performance à l'aune d'indicateurs plus composites (click & view). ”



AXA France
Jonathan Badoux
Responsable Outils
Digitaux

En plus d'une hausse quantitative des usages, le RTB connaît depuis quelques temps une amélioration qualitative des inventaires qu'il propose à la vente. Alors qu'à l'origine, il était surtout utilisé pour valoriser des espaces invendables autrement – d'où une forte connotation low cost de ce mode d'achat – il est de plus en plus compatible avec le premium. C'est ce que constatent en tout cas de plus en plus d'éditeurs, à l'image de **Mickaële Angeletti (Prisma Media Solutions)** :



Au début, nous pensions limiter le RTB à des inventaires display non qualifiés, par exemple à des invendus de bas de page. Mais aujourd'hui, on se rend de plus en plus compte que ce display doit être qualifié, avec un bon indice de visibilité, même s'il est vendu via des Ad Exchange. Le programmatique apparaît dès lors comme un outil compatible avec la vente d'inventaires plus premium, incluant des partenariats ad hoc (deal ID). ”

Prisma Media Solutions

Mickaële Angeletti

Directrice Recherche & Développement



Marketing programmatique



Le marketing programmatique, c'est la possibilité d'automatiser des actions marketing via l'utilisation de logiciels et d'algorithmes, en programmant la réalisation de certaines actions à l'avance, mais sous réserve que des critères bien spécifiques soient réunis. La décision de réaliser l'action se fait en "temps réel". La caractéristique principale du marketing programmatique par rapport au marketing traditionnel, c'est qu'il est moins engageant, dans la mesure où il est dynamique et s'adapte à une situation donnée, à l'instant de diffuser le message marketing pour maximiser l'efficacité de ce dernier. Ainsi, plutôt que de présenter le même site web à tous les visiteurs, on peut personnaliser les contenus des pages en fonction de leurs actions sur le site. En publicité, plutôt que d'acheter une campagne d'affichage sur des abribus ou sur un site média six mois à l'avance en réservant les emplacements, on peut aujourd'hui, sur les supports digitaux et digitalisés, reporter la décision d'achat au moment même où l'impression se produit, et acheter chaque impression une par une. Tout cela n'est utile que parce qu'on a la capacité aujourd'hui de connaître assez de caractéristiques de l'individu exposé à l'impression publicitaire en amont, et ainsi, de décider s'il constitue une cible intéressante pour soi. C'est la promesse, encore balbutiante, d'un marketing mieux adapté à l'individu en face, et au contexte.

Hugo Lorient

Director, Media Technologies | 55





Enchères en temps réel

“ Lors de l’achat classique de supports digitaux, l’annonceur (ou son agence) achète des inventaires sur le site web d’un média spécifique et tombe d’accord quant au nombre d’impressions à un taux de CPM fixe avant le lancement d’une campagne.

Les technologies programmatiques évaluent chaque impression par rapport au profil de l’internaute, rendu anonyme, qui voit la publicité. Elles prennent une décision en temps réel concernant le montant de l’enchère à envisager pour pouvoir présenter une publicité à cette personne. L’audience est devenue l’élément moteur, ce qui signifie que la qualité des données et des informations concernant ce public est essentielle. Tant dans le cas de la réponse directe (performance) que des métriques de marque, le succès réside dans la capacité à toucher l’audience ciblée et à l’engager à l’aide d’informations qualifiées, mais aussi dans celle d’exploiter ces dernières en temps réel.

En évaluant chaque impression à l’aide d’une technologie programmatique, les annonceurs ont les moyens de réduire les pertes induites par des profils inadéquats en évitant de leur servir les publicités. Ils peuvent ainsi attribuer une valeur distincte à chaque segment d’audience, ou encore optimiser / ordonner dynamiquement leur message créatif en fonction de facteurs tels que la valeur d’un client ou son récent comportement en ligne.

Kamal Mouhcine
Directeur Commercial en Europe du Sud
Turn



SCRAPING

Le web scraping ou web harvesting est un procédé par lequel l'on extrait, à l'aide d'un programme, les contenus d'une multitude de sites web, avant d'utiliser ceux-ci ultérieurement. Il s'agit d'une technique qui n'a pas bonne réputation (elle s'appuie, après tout, sur une forme de pillage...), et si elle n'est pas à proprement parler illégale, l'entre-deux juridique dans laquelle elle évolue invite à la circonspection, comme le confirme **Benoît Chéroux (Groupe Argus)** :



Le scraping représente pour moi l'une des seules méthodes accessibles pour collecter de la donnée en gros volumes (hormis les GAFA ou NATU, peu d'autres entreprises génèrent de gros volumes de données). Il existe un vide juridique en France autour du scraping : à qui appartient réellement l'annonce pour une voiture d'occasion publiée sur un site internet ? À la plateforme ? À celui qui l'a créé ? À tout le monde ? Il y a peu de jurisprudence en France sur la question, et il nous paraît donc nécessaire de prendre son temps, d'attendre de voir comment les choses vont évoluer.



Groupe Argus
Benoît Chéroux
Responsable Données & Modélisations

TEXT MINING

C'est l'une des applications les plus répandues du **data mining**. La fouille de texte (son appellation si l'on souhaite éviter l'anglicisme) regroupe un ensemble de traitements informatiques dont l'objectif est d'extraire de la connaissance et des apprentissages potentiellement porteurs de valeur au sein de données textuelles produites par des humains et à destination d'autres humains : corpus d'articles, contenus de sites internet, discussions sous forme de chat récupérées sur les réseaux sociaux, scripts d'appels, etc... Toutes ces sources potentielles de données vont être traitées en deux temps. D'abord on va analyser le contenu à proprement parler des textes, en mettant en œuvre notamment des logiques de traitement automatique du langage naturel. Puis l'on procède à une interprétation des résultats obtenus, afin d'en tirer un enseignement.

Le text mining peut revêtir un intérêt pour des business très variés, comme en témoignent **Benoît Chéroux (Groupe Argus)** et **Christian Phan Trong (Swiss Life)** :

LES BIENFAITS DE L'EXPLICATION DE TEXTE

“ Au sein du groupe Argus, nous exploitons en grande majorité des données alphanumériques dans le cadre de la production d'informations sur le marché automobile. Nous devons être capables d'identifier, de reconnaître à partir des informations textuelles que l'on capte autour d'un événement, soit le produit qui se cache derrière, soit l'individu. Cet enjeu va devenir d'autant plus fort que l'on travaille de plus en plus avec des sociétés éditant des applications et des logiciels sur des voitures connectées, de plus en plus en temps réel, ce qui exclut toute capacité humaine de traitement. Il faudra que des machines se chargent de reconnaître et de segmenter automatiquement l'information qui leur parviendra. ”



Groupe Argus
Benoît Chéroux
Responsable Données
& Modélisations

“ L'exploitation des données structurées est assez naturelle dans le monde de l'assurance. Mais nous sommes aujourd'hui confrontés à des masses de données non structurées qui nécessitent de mettre en place d'autres logiques si l'on veut en tirer parti. Le text mining est l'une de ces logiques qui doivent permettre d'apporter une nouvelle valeur. Le résultat des analyses de text mining va permettre d'alimenter les algorithmes de data science avec de nouvelles dimensions d'analyse pour améliorer la connaissance client, le marketing mais aussi la détection des fraudes, l'optimisation du service au client... ”



Swiss Life
Christian Phan Trong
Directeur
de l'Architecture

Chez **Orange**, le text mining a notamment été utilisé dans le cadre d'un projet d'optimisation des campagnes digitales que détaille **Geoffrey Zbinden** :



Orange
Geoffrey Zbinden
 Vice President Big Data Analytics
 & Customer Base Management



Avec les réseaux sociaux, et avec le recueil d'interactions clients, nous nous retrouvons en possession d'une quantité de verbatims de plus en plus importante... ceux-ci étant en général peu, voire pas du tout exploités. Pour tenter d'en tirer de la valeur, nous avons lancé récemment un pilote. Il s'agissait de récolter tous les tweets parlant de la 4G, puis de nettoyer ceux rédigés par des initiés (journalistes, spécialistes, ...) afin de se focaliser uniquement sur ceux émanant du grand public et ce pour déceler s'il existait un langage naturel autour de la 4G au sein de nos bases clients. Nous avons ainsi identifié les mots qui étaient les plus parlants, qui qualifiaient le mieux la 4G dans l'esprit des clients - mots qui se sont avérés bien différents de ceux qu'utilisent des spécialistes ! Parler de roaming 4G au grand public, ça n'a par exemple aucun impact. Par la suite, nous avons remplacé dans nos communications online ces mots trop jargonnants par ce nouveau vocabulaire identifié comme le plus susceptible de plaire et d'être compris, et nous avons constaté une augmentation des taux de conversion et des taux de clics de plus de 30%.”



THIRD PARTY DATA / FIRST PARTY DATA

Dans le monde du marketing et de la publicité digitale, le terme “third party data” désigne l’ensemble des données fournies par des sociétés tierces. Vendues sous forme agrégée par des acteurs spécialisés (en général des régies publicitaires, ou lors de deals sur des data marketplaces), ces third party data vont permettre à un annonceur d’optimiser ses campagnes en consolidant sa connaissance client, et en optimisant sa segmentation :



L’avantage de la third party data c’est qu’elle offre l’accès à un pool de données très large. Mais on peut se poser la question de la qualité réelle de ces données vendues par des tierces parties. On peut aussi faire appel à de la third party data pour pallier un manque de données internes, ou la croiser de façon efficace avec sa first party data, pour une segmentation plus fine.



The Economist
Stéphane Père
Chief Data Officer
(Global)



L'objectif principal attribué à ce type de données est de venir compléter d'éventuels «vides» au sein des bases de données internes d'une entreprise, comme l'explique **Jonathan Badoux (AXA France)** :



AXA France
Jonathan Badoux
Responsable Outils Digitaux



Le croisement des données first et third party data au sein d'une DMP présente plusieurs intérêts :

- enrichissement des données first party
exemple : un client automobile détecté au moment de changer de véhicule par de la data tierce
- vérification de la pertinence des signaux (first ou third)
exemple : un client MRH scoré comme sans risque de déménagement dans nos SI mais qui serait détecté comme en cours de déménagement par de la data tierce. ”

La first party data désigne quant à elle l'ensemble des données déjà présentes dans les systèmes d'information de l'entreprise. Tout l'enjeu va consister à valoriser ces gisements, bien souvent en sommeil, en trouvant les bons cas d'usage qui permettront leur exploitation.



Historiquement, l'achat média s'appuie sur des données third party permettant de cibler en fonction de critères socio-démographiques et d'intérêt. Ceux-ci reposent sur la compilation et l'analyse de données déclarées et observées à partir d'une multitude d'audiences. Aujourd'hui, la situation change, car les données first party, propres à l'audience spécifique d'un annonceur, souvent plus précises et fiables ne serait-ce que parce qu'il en connaît l'origine et maîtrise leur durabilité, sont plus riches et accessibles, grâce aux évolutions de l'adtech. Il y a un changement d'approche et une prise de conscience concernant leur potentiel pour améliorer la communication marque/utilisateur. 55 accompagne les annonceurs dans ce changement des façons de faire et de penser : mise en place d'un tracking fiable, choix et implémentation de DMP quand cela fait sens... En tant qu'agence data & média, nous privilégions la donnée first party et sensibilisons les marques à la nécessité de constituer un capital data durable, mais nous avons une approche pragmatique qui consiste à utiliser la meilleure donnée en fonction de l'usage et des contraintes. On assimile souvent *reach* à third party et qualité à first party mais c'est une vision très grossière. De nombreux acteurs, *trading desks* en premier, proposent de la donnée third party de qualité et accessible à un coût moindre que la donnée first party.

Globalement il y a un mouvement d'assainissement de la donnée sur le marché. On n'est plus coincé entre agrégateurs de données opaques et données first party rares et difficiles à obtenir. D'ailleurs, des entre-deux apparaissent : échanges exclusifs entre partenaires via de la donnée "second party" (la donnée first party d'un partenaire), ou des formes de coopératives de données privées. ”

Hugo Lorient
Director, Media Technologies

55





Données propriétaires (first party data)

Les marques disposent de données de CRM transactionnelles relatives aux personnes qui ont fait des achats dans des commerces physiques ou sur votre site d'e-commerce – ces données proviennent des leads commerciaux et des personnes qui ont interagi avec votre centre d'appels. Vous pouvez également collecter des données concernant votre site web et les performances de vos campagnes via les canaux suivants : mails, display, vidéo, mobile, publicité directe, TV, print, etc. Ces données maison – vos first party data – sont le point de départ pour obtenir des informations sur votre audience idéale.

Il est indispensable de s'équiper d'une solution fiable de collecte de ces données propriétaires obtenues à l'aide de pixels en temps réel (tag management) ainsi que de fichiers *batch*. Une fois ces données regroupées au sein d'une plateforme DMP, le système permet à un marketeur de transformer les informations en segmentant les valeurs des transactions d'un panier d'achat puis en les répartissant dans un ensemble de compartiments définis par ses soins. L'action de transformer des données entrantes permet d'accélérer et de simplifier les phases ultérieures de segmentation et de ciblage de l'audience. En effet, le processus de standardisation des données brutes collectées permet d'en faire des informations davantage exploitables en amont de vos campagnes.

Données émanant de tierces parties (third party data)

La valeur des données propriétaires augmente considérablement une fois celles-ci mêlées aux données sur l'audience émanant de fournisseurs tiers. Une plateforme de gestion des données vous permet d'exploiter vos données « maison » dans le but d'identifier les clients présentant la plus grande valeur, puis de superposer les données anonymes fournies par des tiers afin d'obtenir un panorama complet de leurs attributs, de leurs comportements et de leur consommation de contenus. Commencez par exemple avec les personnes qui naviguent sur les pages de vos sites web. Une DMP vous montrera ainsi, à partir des données de votre site, quels visiteurs ont fait des achats ou ont été convertis et comment, à partir des données de tiers, ces conversions ont été biaisées par des facteurs économiques, de hiérarchie familiale, d'étape de vie et de préférences liées au style de vie. Vous pourrez alors découper les données en fonction de l'étape de votre visiteur au sein du cycle de vie client. ”

Kamal Mouhcine
Directeur Commercial en Europe du Sud
Turn



TRACKING

Parcours de navigation sur un site internet, réaction aux bannières publicitaires ou à la réception d'un email, propension à l'achat sur une application mobile... Le tracking permet d'observer le comportement des internautes pour en tirer des enseignements au service de l'entreprise, et en particulier de son marketing. Ses usages les plus fréquents gravitent autour de la question de l'amélioration de la connaissance client : enrichissement d'un fichier prospects à fort potentiel, alimentation du CRM, optimisation des campagnes de recrutement de trafic s'appuyant sur une meilleure compréhension de la cible, etc... Pas étonnant dès lors que le tracking ait pris son envol, en tant que sujet d'intérêt majeur, d'abord dans le domaine de la vente en ligne.



Voyages-sncf.com

Marie-Laure Cassé

Directrice Marketing Client & Data



La collecte des données de navigation est devenue un enjeu très fort pour tous les e-commerçants. Nous avons pris l'habitude de définir, en amont de chaque projet, une stratégie de collecte de la « bonne data », c'est à dire celle la plus susceptible de répondre aux besoins des métiers. Nous devons solliciter des experts de la data compétents, polyvalents et capables de s'adapter à des outils et des technologies qui évoluent en permanence sur de nombreux domaines : site centric, ad-centric ou customer centric, web et mobile... ”

L'idée de poser des tags pour récolter de l'information au service de la connaissance client a trouvé de formidables opportunités dans l'avènement du Big Data, dont les technologies vont permettre de récolter, de stocker, et d'exploiter l'information de plus en plus facilement, et à des tarifs de plus en plus intéressants. Elle s'est étendue progressivement à bien d'autres domaines qu'à celui du e-commerce. Dans le secteur de la banque, par exemple, le tracking va offrir de nouvelles opportunités commerciales... A condition d'être très clair avec les utilisateurs sur la façon dont sont utilisés leurs cookies.



Dans la banque, le tracking va permettre de bien connaître ce que font nos clients et de fluidifier les parcours de navigation, ... Plus on a d'informations pour comprendre comment le client a converti, plus on va pouvoir être pertinents dans notre approche commerciale. Le tracking suppose toutefois de bien informer le client de ce qu'on va tracker, pour ne pas entraîner de défiance de sa part. Cela nécessite donc une bonne politique de *cookie consent*.



LCL
Christèle Baranco
 Responsable Analyse
 de la Donnée Client

TRAITEMENT AUTOMATIQUE DU LANGAGE NATUREL

Les fondements théoriques de l'ingénierie linguistique, c'est-à-dire de la mise en œuvre de techniques informatiques dans le champ du langage humain, n'ont pas attendu l'ère du Big Data pour faire leur apparition. Dès les années 1950, alors que l'ordinateur n'est encore qu'un concept balbutiant, le mathématicien Alan Turing imagine un test (le fameux test de Turing) destiné à évaluer l'intelligence artificielle d'une machine au travers d'une confrontation verbale avec un être humain : si ce dernier ne s'avère pas capable de déterminer s'il est en train de discuter avec un programme ou un semblable, la machine aura fait la preuve de son intelligence.

S'il n'est pas une invention récente, le traitement automatique du langage naturel (TALN) a toutefois trouvé dans les nouvelles technologies de la donnée un formidable catalyseur. Process de plus en plus rapides, amélioration des outils de statistiques et d'intelligence artificielle permettant une reconnaissance automatique de plus en plus fine des éléments de langage...

Discipline à mi chemin entre linguistique, informatique, et intelligence artificielle, le TALN n'est pas longtemps resté cantonné au domaine de la recherche pure, et intéresse une multitude d'entreprises qui y puisent la réponse à une multitude de questions autour de la connaissance client. A la **SNCF**, il va permettre, par exemple, de mieux évaluer l'image de marque :



SNCF

Maguelonne Chandesris

Responsable de l'équipe Innovation
& Recherche «Statistique, Économétrie
et Datamining»



Les réseaux sociaux ont suscité un regain d'intérêt pour les problématiques liées au traitement automatique du langage. Très classiquement, beaucoup de choses se font sur l'analyse de l'image de marque via cette matière. Plus spécifiquement, nous nous intéressons aussi à la façon dont les gens parlent de leurs voyages, de leur mobilité en général. Notre enjeu est de voir si nous allons être capables d'analyser automatiquement ces corpus, de manière anonyme, pour en tirer quelque chose de concret. Pour cela, il est nécessaire de comprendre une sémantique complexe, ce qui nécessite de mobiliser des équipes de recherche et les compétences pointues dans le domaine. ”

Dans le secteur de l'hôtellerie, on va aussi avoir recours au TALN pour essayer de réagir le plus rapidement possible à des alertes émanant de la clientèle, comme l'explique **Fabrice Otaño (AccorHotels)** :



Chez AccorHotels, nous avons un système d'écoute et de satisfaction client très développé, dans lequel le *natural langage processing* va trouver tout naturellement sa place. Les avis et les commentaires qui nous sont remontés sont déversés dans notre datalake, pour que nous les analysions avec des algorithmes de NLP avant de déterminer le sentiment qui se cache dans la phrase. On parlait avant d'analyse sémantique (quelle est, par exemple, la différence entre « satisfait » et « pas satisfait » ?). Aujourd'hui, chaque mot est un vecteur qui porte plusieurs attributs, et qui une fois groupé avec d'autres mots et d'autres vecteurs va permettre des interprétations de plus en plus sensibles. Cela ouvre la possibilité de déclencher des actions lorsque l'on repère des alertes autour de la satisfaction client.



AccorHotels group
Fabrice Otaño
SVP, Chief Data Officer



4. OUTILS

La vague du Big Data n'a été rendue possible que par une démocratisation des outils rendant de plus en plus accessible le traitement massif de données. Dans cette jungle toujours plus touffue de solutions logicielles et de langages de programmation, il n'est pas toujours évident de s'y retrouver. Sont regroupés ici les plus populaires, de l'incontournable Hadoop au récent Spark.

ARBRE DE DÉCISION

Cet outil d'aide à la décision s'appuie sur un modèle ramifié, dans lequel

chaque «branche» représente un chemin possible, et chaque extrémité une des différentes décisions qui en résultent. Cette forme de représentation en arbre le rend calculable facilement et automatiquement par des algorithmes d'apprentissage, d'où sa popularité dans le champ de l'exploration de données. Déjà communément utilisé en statistiques et en informatique décisionnelle, les arbres de décisions entrent, avec les Big Data, dans une nouvelle dimension, comme le confirment **Stéphane Cléménçon (Télécom-ParisTech)** et **Pascale Dulac (France Loisirs)** :

PROMENONS-NOUS DANS LES FORÊTS ALÉATOIRES

Les approches reposant sur des arbres de décision - ou des agrégations d'arbres de décisions, comme les forêts aléatoires, les algorithmes de type boosting - ont l'avantage de bénéficier d'une bonne interprétabilité. C'est ce qui explique leur succès dans certains types d'applications qui ne peuvent pas s'accommoder du côté boîte noire des réseaux de neurones.

Télécom-ParisTech

Stéphane Cléménçon
Professeur et Responsable
du Mastère Spécialisé
Big Data



Nous utilisons déjà régulièrement les arbres de décision dans des

logiques de segmentation, ou pour certains travaux exploratoires. Mais avec le traitement massif des données, ceux-ci se complexifient considérablement... avec le risque parfois d'un trop plein d'information.

France Loisirs

Pascale Dulac
Responsable
Connaissance Clients



Même si le fonctionnement des arbres de décision est plus facilement interprétable que celui des **réseaux de neurones**, leur complexification nécessite de laisser aux machines le soin de leur traitement. D'où un sentiment de perte de contrôle qu'il faut savoir accepter, explique **Christèle Baranco (LCL)** :



Avec le temps réel, et le besoin de calcul rapide, on accepte de moins comprendre les variables sur lesquelles les machines vont opérer leurs calculs. Avec des méthodes comme Random Forest (forêt d'arbres décisionnels), on obtient de bonnes performances même s'il est plus difficile de décrire ce qui se passe et quelles sont les variables explicatives. Nous testons ce type de méthodologies sur des scores que nous avons jusqu'aujourd'hui l'habitude de traiter en régression logistique, pour voir si elles s'avèrent plus performantes.



LCL

Christèle Baranco
Responsable Analyse
de la Donnée Client



CLUSTER

Emprunté au monde de la physique et de la chimie, où il ren-

voie à un agrégat d'atomes, ce terme a commencé à être utilisé en informatique à la fin des années 1980, lorsque des ingénieurs ont commencé à développer des « multi-ordinateurs ». Le mot cluster (grappe de serveurs, ou ferme de calcul en français) a dès lors servi à désigner une technique de regroupement de plusieurs serveurs indépendants. Cette mutualisation des efforts va se traduire par une montée en puissance, et de plus grandes capacités de stockage et de mémoire vive qui vont permettre le calcul distribué. Le framework **Hadoop** a contribué à populariser les clusters, puisqu'il s'appuie entièrement sur cette technologie, comme l'explique Maguelonne Chandesris (SNCF) :



Si l'on part du principe que les Big Data sont une mine, on peut concevoir deux manières d'en extraire le précieux minerai. Soit on se fait fabriquer un

énorme extracteur sur mesure. Soit on utilise plutôt une grande quantité de petits extracteurs standards. Pour filer la métaphore, Hadoop, fonctionne plutôt comme une agrégation de plusieurs petits extracteurs, en l'occurrence des clusters.



SNCF

Maguelonne Chandesris

Responsable de l'équipe Innovation
& Recherche « Statistique, Économétrie
et Datamining »



Aujourd'hui, le terme cluster est tellement entré dans le langage en informatique qu'il est difficile de délimiter ses usages. Il désigne en tout cas une importante ressource de calculs fondée sur un regroupement de composants.

Intel

Marie-Christine Sawley



DATA LAKE

Où déverser le flot de données qui inonde les systèmes d'information de l'entreprise ? Dans un immense réservoir prévu à cet effet ! Voilà à quoi doit servir le data lake, qui contrairement à un **data warehouse** stockant les données en les classant en fichiers, va recevoir celles-ci tous azimuts et dans leur format natif. L'information n'étant ainsi plus structurée et divisée en silos, elle va pouvoir garder une neutralité totale en attendant que lui soit attribué un usage. Cet intérêt est d'autant plus fort qu'avec des technologies comme **Hadoop**, on stocke des quantités de plus en plus importantes de données dont la structure varie, et sans toujours savoir à l'avance comment on pourra les utiliser et les analyser.

“ **L'avenir, ce n'est plus le datamart, mais le datalake, qui permettra un désilotage en règle.** ”



Orange
Geoffrey Zbinden

L'architecture plate des lacs de données convient ainsi parfaitement à des données qu'on souhaite mettre en attente pour des besoins ultérieurs qu'on devine sans pour autant être capable de les définir. La structure permettant l'analyse sera créée *in situ*, une fois le moment venu. Dans le cadre de données structurées utilisées dans des analyses répétitives, le data lake sera en revanche contre productif car il devra recréer une structure pour chaque analyse, consommant ainsi des ressources machines. Dans ces cas là, le data warehouse reste le mieux adapté, ce qui en fait une solution complémentaire au data lake, et pas nécessairement exclusive.



Bouygues Telecom
Nicolas Gaudé
Senior Data Scientist



Aujourd'hui, il existe une sorte d'antichambre au stockage de la donnée, avant le data warehouse classique, que les pro Big Data vont appeler le data lake et que les vendeurs de solutions propriétaires préfèrent désigner par le terme de «marécage de données». Dans tous les cas son but est le même : servir de déversoir pur et simple à des données non structurées. On va simplement s'attacher à avoir au moins une clé (texte, log, image, binaire) pour accéder au fragment. ”

En centralisant dans un même réservoir l'ensemble des données de l'entreprise, le data lake va avoir un effet désilotant et nécessiter du même coup, une réflexion importante sur la data gouvernance si l'on veut garantir une bonne harmonie dans ses usages. Cela étant acquis, il pourra servir de base commune dans laquelle viendront picorer les data scientists pour leurs projets, comme l'explique Christian Phan Trong (Swiss Life) :



Swiss Life
Christian Phan Trong
 Directeur de l'Architecture



Le data lake est un concept issu du décisionnel qui passe en version 2.0 avec l'avènement du Big Data. Auparavant, on déposait une multitude de données à l'intention du décisionnel dans des zones de dépôt, pour une mise à disposition, après chargement, retraitement, formatage consommateur en délai, dans les datamarts. Avec le data lake on va généraliser les zones de dépôt en les pérennisant. Cela va permettre d'accéder à l'ensemble des données brutes historisées de l'entreprise, de façon à ce que les data scientists puissent, en fonction de la question qui leur est posée, piocher dans le bon gisement de données. Au final, le data lake permet donc une agilisation du travail des data scientists. ”



“ Le data lake a pour vocation de stocker de manière quasi exhaustive les données métiers d’une organisation. Par rapport aux architectures analytiques antérieures fondées sur un data warehouse et/ou des datamarts, il ne repose pas sur une modélisation préalable des données. De ce fait, le data lake présente plusieurs avantages. D’une part, il peut stocker tous types de données, structurées et non structurées. D’autre part, il permet d’intégrer des données sans nécessairement passer par un processus ETL. Il permet donc d’accueillir très rapidement des données dans leurs formats natifs et de les rendre immédiatement disponibles pour l’analyse. C’est ensuite, au moment de l’utilisation, que les données sont interprétées dans leur structure.

Du fait de la grande variété de données hébergées, la gouvernance du data lake constitue un enjeu important. Il convient de s’assurer que les utilisateurs comprennent les données qu’ils manipulent.

Le data lake s’est démocratisé avec l’émergence des solutions tel que Hadoop qui permettent de stocker et d’analyser de grands volumes d’informations à des coûts maîtrisables. ”

Jacques Milman
Architecte Senior Analytics
IBM



DMP*

* *Data Management
Plateform*

La plateforme de gestion d'audience (ou DMP, pour Data Management Platforms) est une technologie qui permet d'unifier des données consommateurs en segmentant des cookies (aussi bien first que third party) et à des fins d'optimisation du marketing. Utilisées initialement comme des solutions dédiées à l'achat de publicité display, les DMP sont rapidement devenues, avec l'apparition de nouveaux modes d'achats (RTB notamment), des technologies indispensables pour enrichir sa connaissance client, et piloter les campagnes publicitaires tous leviers. Elles s'adressent du reste essentiellement à deux types d'acteurs : les agences (auxquelles elles vont permettre de centraliser les données clients issues de sources multiples, et de contrôler toute la chaîne des actions marketing) et les annonceurs, qui vont pouvoir, grâce à elles, mieux cibler leurs audiences en les segmentant efficacement.



Cette idée de segmentation selon une multitude de critères - données tierces, externes, internes, socio-démographiques, comportementales, etc - se trouve au service d'une activation de la donnée à deux niveaux :

- soit en mode campagne en visant un segment spécifique
- soit en mode « on-going », en associant des règles d'activation marketing à chaque segment pour mener des actions en temps réel.



The Economist
Stéphane Père
Chief Data Officer (Global)



La DMP est souvent l'un des premiers projets que vont implémenter les entreprises pour tenter de tirer parti du Big Data. En témoignent ces récentes expériences menés chez **Renault** et **The Economist** :

RÉINVENTER LA CONNAISSANCE CLIENTS GRÂCE AUX DMP

“ Nous sommes en train de tester un outil DMP avec des résultats positifs très significatifs (gain sur les conversions, baisse des coûts sur les leads,...) Ces premiers tests nous ont notamment convaincu de l'intérêt de multiplier les sources de données pour affiner la segmentation. Ils ont aussi introduit une dimension de temps réel qui n'existait pas auparavant, et qui contribue à une augmentation de l'efficacité de notre marketing. ”

Renault
Laurent Aliphat
Head of Digital
Performance and
Lead Management



“ La DMP, que nous utilisons principalement dans une logique d'acquisition, a révolutionné notre manière de faire de la pub. Avant, nous travaillions avec des agences, auxquelles nous fournissions un profil type, et en restant finalement dans les clous du media planning traditionnel. Aujourd'hui nous allons nous pencher de plus en plus sur qui est véritablement notre client...Et surtout sur la meilleure façon d'aller chercher des profils similaires à celui-ci. ”

The Economist
Stéphane Père
Chief Data Officer
(Global)



Malgré la popularité grandissante de cette solution et la prise de conscience des intérêts qu'elle représente, s'équiper d'une DMP ne constitue pas une évolution mineure pour une entreprise. Pour être sûr de transformer l'essai, il faut savoir s'armer de patience, et trouver la solution correspondant le mieux à son cas particulier. C'est en tout cas ce que mettent en avant **Jonathan Badoux (AXA France)** et **Yoann Denée (Prisma Media)** :



Prisma Media
Yoann Denée
Chief Data Officer



“ Nous sommes équipés d'un écosystème de DMP propriétaire qui sert de socle interne de données, dans une logique patrimoniale et de contrôle de la sécurité et des prestataires externes. Parallèlement, nous utilisons des DMP métier que nous contrôlons, mais dont la donnée anonymisée est hébergée à l'extérieur. ”



AXA France
Jonathan Badoux
Responsable Outils Digitaux



“ La DMP est un sujet complexe qui demande du temps pour être appréhendé avec efficacité. En effet, ce type de projet implique la participation de tous les services de l'entreprise et ce dès le début de l'élaboration des use cases. Use cases qui devront être abordés en mode test and learn afin de déceler les “pépites” qu'ils peuvent révéler et ainsi lancer l'industrialisation. Sans oublier l'intégration technique avec les systèmes d'information des différents annonceurs. ”



“ Ce qui se joue actuellement avec l'équipement des annonceurs en Data Management Platform, ce sont principalement trois choses : la digitalisation, la souveraineté sur son patrimoine client, et enfin l'agilité. La digitalisation parce qu'une DMP permet de réconcilier tout type de données : données issues du digital comme du monde physique, du back-office comme de fournisseurs tiers. L'enjeu de souveraineté, c'est ce qu'on entend par avoir une approche “patrimoniale” de la donnée, considérée comme un actif de la marque. Il s'agit de rapatrier la connaissance client chez soi, plutôt que de l'héberger chez un ou plusieurs prestataire(s) - agence ou fournisseur technologique. Enfin, contrairement à une base de données classique ou aux entrepôts de données (data warehouses), la DMP est une solution au service de l'agilité, dont le but premier est de faire communiquer différents systèmes simplement, en acheminant les bonnes données aux plateformes d'activation dans les délais voulus (temps “réel”). Plus qu'une base, c'est une sorte de hub de données intelligent. ”

Pierre Harand
Director, Consulting
and Business Development
55



DPI*

* *Deep Packet Inspection*

Cet acronyme renvoie au Deep Packet Inspection, une méthode informatique consistant à analyser dans le détail - c'est à dire en ne s'arrêtant plus à son en-tête - le contenu d'un paquet réseau. De cette façon, il va être possible non seulement de filtrer plus efficacement les paquets, de détecter (et de bloquer) ceux qui sont assimilables à du spam, ou peuvent constituer une menace d'intrusion, mais aussi d'en tirer des insights en les analysant, et en faisant tourner des outils de statistique. Cet affinage dans la compréhension des paquets est rendue possible par les technologies de traitement massif de la donnée, comme l'explique **Aroua Biri (Sogeti)**.



Sogeti

Aroua Biri

Architecte Cybersécurité & Big Data



De plus en plus, on va exploiter la possibilité de pouvoir traiter très rapidement de grandes quantités de données. Auparavant, avec les firewalls, le gros problème c'était d'empêcher le paquet de rester trop longtemps au niveau de l'équipement réseau. Du coup, on était obligé de s'arrêter à l'en-tête, parce qu'il fallait trouver un compromis entre le délai de traitement du paquet, et sa bonne circulation. Avec le Big Data, en utilisant Spark notamment, on va pouvoir traiter les paquets qui passent de manière très rapide, et donc inspecter plus profondément ces derniers, ne plus s'arrêter sur l'en-tête. Le Big Data permet ainsi de démocratiser le « Deep Packet Inspection »... reste à prendre en compte les aspects réglementaires relatifs à ce sujet ! ”

ETL *

* *Extract-Transform-Load*

Aussi connu sous le nom de datapumping, l'ETL (acronyme pour Extract-Transform-Load) est un processus opéré au sein d'une database, et qui va permettre la migration et la synchronisation des données d'une base vers une autre. Comme son nom l'indique, l'opération consiste d'abord à extraire la data depuis des sources homogènes ou hétérogènes, puis à la transformer dans un format qui permettra de l'analyser et de la soumettre à des requêtes, et enfin de la charger vers sa destination cible. Pour expliquer plus concrètement les objectifs de l'ETL, **Maguelonne Chandesris (SNCF)** convoque une métaphore... Culinaire !



Lorsque l'on fait du traitement massif de données, le départ, c'est la source, ou plutôt, la multitude de sources.

La première étape va être de collecter ces données multi-sources (extract) pour les mettre ensemble (transform) avant des les charger (load) pour permettre ensuite les analyses. Pour prendre une image, l'ETL, c'est donc ce travail préparatoire, similaire à celui qui consiste à préparer tous les ingrédients qui permettront ensuite d'exécuter une recette de cuisine. C'est donc la pierre angulaire d'énormément de systèmes.



SNCF

Maguelonne Chandesris
Responsable de l'équipe Innovation
& Recherche «Statistique,
Econométrie et Datamining»



Un tel travail préparatoire existe de longue date. Sa démocratisation et sa généralisation, en revanche, sont récentes, et vont stimuler de plus en plus de cas concrets d'usage. Comme celui que présente Pierre-Marie Desbazeille (**GrandVision**).



GrandVision
 Pierre-Marie Desbazeille
 Directeur CRM & Digital



“ Nous allons pour notre part y avoir recours pour un cas pratique qui ne peut fonctionner qu’avec de la transformation rapide de flux : il s’agit, sur un dispositif mobile vendeur, de faire appel à deux bases complètement différentes (bases mutuelle connectées en EDI, et notre base de verres). Développons : nos vendeurs vont utiliser en magasins une application permettant de faire la meilleure offre verres au client qu’ils sont en train de servir, en tenant compte de nombreux paramètres (pathologie, usage, mutuelle, style de vie). Le résultat est obtenu en une seconde. Sans ETL, ce serait tout bonnement impossible, car il aura fallu, pour obtenir la recommandation, interroger la base mutuelle, la base verres, et émettre une proposition unique adaptée à la pathologie. Avant les ETL... on passait par le fax! ”

HADOOP

À l'origine, c'était le petit nom d'un éléphant en peluche, celui du fils de Doug Cutting, un ingénieur employé chez Yahoo. Depuis, c'est devenu l'appellation d'un framework Java développé par la fondation Apache, qui s'est choisi un pachyderme comme logo, et s'est surtout imposé, depuis sa première release en décembre 2011, comme le poids lourd de la révolution Big Data. Auto-riquant, grâce à son architecture distribuée en **clusters** (HDFS pour Hadoop Distributed File System) le stockage de très gros volumes, il permet à des applications de travailler sur des pétaoctets de données. Initialement orienté batch, il s'est équipé depuis 2013, avec **YARN**, d'une solution qui lui permet aussi, en plus du traitement massif de données, de faire du streaming et du temps réel. Ces atouts ont convaincu des géants comme Facebook, Yahoo ! ou Microsoft, qui se sont tous équipés de solutions Hadoop. Les entreprises françaises, elles, même si elles peuvent parfois hésiter devant le caractère open source d'une telle solution, sont de plus en plus nombreuses à franchir le pas, comme le confirment **Elisabeth Zehnder (Kiabi)**, **Olivier Brousseau (Schlumberger)** et **Christèle Baranco (LCL)** :

“ Le caractère volatile des technos utilisées dans le cadre d'Hadoop nous a d'abord fait hésiter. Il faut dire que nous ne voulions pas mettre en place un tel système pour de la R&D, mais pour des usages de production... d'où certaines hésitations légitimes. Au final, nous avons décidé de nous jeter à l'eau. Nous avons donc décidé de mettre en place du Hadoop il y a un an. C'est rapidement devenu le cœur du sujet technique côté IT : sans Hadoop rien n'aurait été possible. ”

Kiabi

Elisabeth Zehnder
Data Scientist



UN ÉLÉPHANT QUI COMPTE ÉNORMÉMENT

“ Hadoop a rendu possible l'exploitation des machines data, en permettant d'exploiter des volumes d'informations conséquents à des prix d'exploitation raisonnables.

C'est une technologie en flux permanent, qui se consolide au fur et à mesure. Le fait qu'Hadoop soit en permanence en mode lab, c'est loin d'être dérangeant pour nous, car c'est aussi notre façon d'aborder l'utilisation de la data pour ces cas d'utilisation. ”



Schlumberger

Olivier Brousseau
IT Business Intelligence
Strategy Manager

“ C'est le premier mot que l'on associe instinctivement à la notion de Big Data. Grâce à Hadoop,

on va moins se poser la question, comme cela pouvait être le cas avant dans le cadre d'une architecture physique structurée autour de bases de données relationnelles, de réfléchir en amont au stockage de la donnée. Désormais, on va stocker ces data sans trop de contraintes. ”

LCL

Christèle Baranco

Responsable
Analyse de la
Donnée Client



Premier pas vers le Big Data, l'arrivée d'Hadoop au sein de l'entreprise est souvent vécu, explique **Yoann Denée (Prisma Media)** comme un bouleversement :



L'arrivée des technologies de traitement massif de la donnée au sein de notre

entreprise, quand bien même elles ne sont pas pour l'heure utilisées pour des usages de Big Data *stricto sensu*, a été pour nous une vraie lame de fond. Les tests sur Hadoop réalisés depuis deux ans, et le recours à MongoDB, qui a l'avantage d'être compatible Hadoop et permet d'avoir des performances en phase à la fois avec les besoins métiers et la gestion des coûts, ont pris l'apparence d'une révolution.



Prisma Media

Yoann Denée

Chief Data Officer





La plateforme open source Hadoop est devenue synonyme de Big Data. Hadoop peut être considérée comme une petite révolution dans le monde des technologies, quel que soit le regard qu'on y porte :

- **Technologie** : Elle donne des perspectives qu'on n'imaginait pas avant : des capacités de traitement qui s'appliquent sur des volumes quasi-illimités, une prédictibilité dans les temps de réponse et des langages de manipulation et de traitement adaptés aux usages.
- **Coût** : des logiciels basés sur du code open source installés sur du matériel de commodité.
- **Ecosystème hyperactif** : les grandes entreprises IT d'une part, les projets Apache de l'autre, stimulent la communauté des développeurs qui participent activement au développement du Big Data.

Hadoop est un ensemble de composants adressant chacun un besoin spécifique. Cela devient complexe lorsque des choix technologiques sont à faire, c'est pourquoi des initiatives comme odpi.org garantissent aux entreprises la compatibilité entre ces composants.

De ce foisonnement technologique résulte un vrai changement dans les organisations et les modes de fonctionnement des DSI vis-à-vis des métiers car le monde Hadoop évolue vite : un composant peut devenir obsolète en quelques mois (cf. MapReduce vs Spark). Cela impacte les processus de formation des ingénieurs et leur recrutement, les cycles de développement applicatif ou les modes de mise en production. C'est au prix de ces changements que les DSI continueront à être un support au développement des métiers. ”

Laurent Sergueenkoff
Analytics Platform Sales Team Leader
IBM France



LANGAGE R

Ce logiciel libre de traitement des données et d'analyse statistiques est devenu, avec **Python**, l'un des langages de programmation de référence pour le Big Data. Développé au début des années 1990 par Ross Ihaka et Robert Gentleman (deux universitaires nord-américains), il s'est rapidement implanté dans les universités et le monde de la recherche en général. Mais le monde des entreprises s'y intéresse de plus en plus, et nombreux sont aujourd'hui les statisticiens à abandonner les anciens langages pour adopter R.



Les entreprises étaient initialement très orientées SAS. R, qui propose beaucoup de choses similaires à

SAS, mais avec une nouvelle vision des choses, remporte un succès grandissant.



LCL

Christèle Baranco

Responsable Analyse de la Donnée Client

L'arme de séduction massive de R auprès des entreprises, c'est son caractère Open Source. Nombreux sont ainsi les acteurs à le mettre au banc d'essai dans une logique de maîtrise des coûts, comme l'explique **Elisabeth Zehnder (Kiabi)** :



Kiabi

Elisabeth Zehnder

Data Scientist



R nous permet de travailler nos algos avec un langage Open Source, et donc de réduire nos coûts. Quand je suis arrivée chez Kiabi, il n'y avait pas d'outils de stats à proprement parler. Nous avons vu

plusieurs éditeurs, qui ne maîtrisaient pas toujours leurs coûts, ce qui peut faire peur. Tant que R répond à nos besoins, il nous semble judicieux et avantageux de l'utiliser.





De la même façon que les logiciels, les langages de développement informatique ont largement évolué ces dernières années. Les communautés scientifiques, les hackers et les métiers technologiques ont ainsi développé une nouvelle génération de langage, appelé langage de 4^e génération, qui permet de synthétiser les principales instructions d'un code d'un programme. Ces langages ne recherchent pas de performance computationnelle mais se focalisent davantage sur une souplesse de manipulation et une lecture facilement interprétable. Ce sont généralement des langages exécutables dans des environnements interactifs où chaque instruction de code produit un résultat (REPL). Ils sont souvent utilisés pour proposer des interfaces de programmation riches (API) permettant d'encapsuler un programme codé dans un autre langage aux performances plus élevées. Ainsi les langages R et Python sont les langages de programmation plébiscités par la communauté des data scientists car ils offrent une grande rapidité de prise en main et encapsulent facilement des programmes codés dans d'autres langages. ”

Marc Damez-Fontaine
Senior Manager
PwC



MAPREDUCE

Popularisé par Google, MapReduce est un modèle d'architecture et de développement informatique qui permet de procéder à des calculs parallèles sur des masses de données. En distribuant celles-ci dans un **cluster** de machines, il va permettre le traitement de grosses volumétries (supérieures à 1 téraoctet).



Intel
Marie-Christine Sawley
Exascale Lab Director



C'est un algorithme qui s'appuie sur une idée simple : traiter localement des données qui ont été au préalable séparées en petits morceaux, avant de les faire remonter pour avoir une vision d'ensemble sur une masse bien plus importante.

Une telle vision a permis le démarrage du Big Data en général, en offrant des nouvelles solutions de traitement des données massives. ”

MapReduce a entraîné la naissance de nombreux frameworks, dont le plus connu est **Hadoop**. Les deux termes sont encore aujourd'hui intimement liés, comme le rappellent **Christèle Baranco (LCL)** et **Maguelonne Chandesris (SNCF)** :



MapReduce, c'est une manière de faire des calculs adaptée au système Hadoop. Il permet la distribution des tâches au sein de cette architecture distribuée, et la répartition des calculs pour permettre de remonter progressivement les résultats. ”

SNCF

Maguelonne Chandesris

Responsable de l'équipe Innovation & Recherche
« Statistique, Économétrie et Datamining »



LCL
Christèle Baranco
Responsable Analyse de la Donnée Client



Le MapReduce, c'est la manière dont on va désormais coder pour effectuer des calculs parallèles permettant d'attaquer plus efficacement de gros volumes de données. Les données sont découpées en entrées et dans un premier temps il s'agit de les « mapper » noeud par noeud. Puis ensuite de les agréger et ainsi de réduire ces données. Il est nécessaire de coder différemment pour utiliser toute la puissance du calcul distribué à laquelle donne notamment accès Hadoop. ”

PYTHON

Ce langage de programmation orienté objet s'est imposé comme un outil essentiel du Big Data. Inventé à la fin des années 1989 par Guido van Rossum (un développeur néerlandais, fan des Monty Python à ses heures perdues), Python a d'abord été largement utilisé dans le domaine scientifique (on lui doit notamment le traitement des images spatiales récoltées par le télescope Hubble et le modèle expérimental ayant permis la découverte du Boson de Higgs). Flexible, puissant, facile à apprendre et à utiliser, et présentant l'immense avantage d'être en open source, il a investi ensuite le champ de la donnée, permettant sa manipulation et son analyse, et s'imposant comme un apprentissage indispensable dans le savoir-faire des **data scientists**. Ces derniers sont aujourd'hui systématiquement formés à Python, explique **Marie-Christine Sawley (Intel)** :



Je fais partie de la génération des informaticiens qui n'ont pas appris Python, et cela se voit ! C'est un langage qui a pris ses marques dans la formation ou il est devenu incontournable, car « multiforme », applicable du PC à la tablette et au téléphone. Les générations « Python » sont maintenant bien installées dans le monde du travail et trouvent chaque jour de nouvelles manières de l'utiliser, notamment comme langage de scripting. Python joue un rôle important, par sa richesse et sa versatilité, aussi bien dans l'enseignement qu'en production.



Intel
Marie-Christine Sawley
Exascale Lab Director



Python est souvent opposé, ou mis en concurrence avec un autre langage de programmation, qui s'est imposé lui aussi dans le monde du Big Data au cours des dernières années : **R**. Si ces deux solutions sont effectivement, à la base, utilisées par des communautés différentes, leur usage est en réalité assez similaire, et les possibilités qu'elles offrent, presque les mêmes. C'est en tout cas l'avis de **Maguelonne Chandesris (SNCF)** :



SNCF

Maguelonne Chandesris

Responsable de l'équipe Innovation
& Recherche «Statistique,
Econométrie et Datamining»



Historiquement, deux communautés scientifiques différentes se sont lancées à l'assaut du Big Data : d'un côté des gens faisant surtout

de l'algorithmie, de l'autre ceux qui faisaient essentiellement de la statistique. Les premiers utilisent Python, les seconds, R. Aujourd'hui ces communautés sont amenées à se mélanger de plus en plus, ce qui a nécessité de faire évoluer ces langages initiaux. Cela reste deux langages différents, mais leurs fonctionnalités sont aujourd'hui en réalité assez semblables. ”

RÉSEAU DE NEURONES

Ce modèle de mathématiques paramétriques s'inspire de la transmission synaptique (et donc de la biologie) en déployant un réseau constitué d'une multitude de nœuds et au sein duquel l'information va se propager jusqu'à atteindre la couche finale. Utilisés initialement pour résoudre des problèmes d'ordre statistique (la classification automatique des codes postaux par exemple), les réseaux de neurones ont aussi investi le champ de l'intelligence artificielle, grâce à leur mécanisme perceptif indépendant des idées de celui qui l'implémente et qui va permettre un apprentissage autonome. Cette forme de liberté de fonctionnement rend toutefois leur compréhension ardue, ce qui peut décourager certaines entreprises qui ont besoin d'une grande lisibilité. Voilà ce qu'explique **Stéphan Cléménçon (Télécom-ParisTech)** :



Télécom-ParisTech
Stéphan Cléménçon
 Professeur et Responsable
 du Mastère Spécialisé Big Data



“ Dans les années 80-90, les réseaux de neurones ont eu du mal à s'imposer, en raison de la difficulté à les rendre interprétables. Aujourd'hui, ils reviennent à la mode, parce que dans les applications liées au domaine internet, l'interprétabilité a une moindre importance, et que le côté boîte noire des technologies faisant appel à des algorithmes n'est pas conçu comme un facteur limitant. Pour les entreprises plus traditionnelles, en revanche, la nécessité d'interpréter physiquement les modèles rend le recours aux réseaux de neurones moins évident. ”

Le recours efficace aux réseaux de neurones constitue donc, pour le moment, surtout un enjeu d'avenir pour les entreprises. Si certaines ont déjà lancé des projets concrets ayant recours à cette forme d'intelligence artificielle, la plupart sont en attente de cas concrets d'utilisation... Et les promesses sont nombreuses, reconnaissent notamment **Nicolas Gaudé (Bouygues Telecom)** et **Samir Amellal (Publicis Worldwide)** :

“ Un jour, peut être, d’ici cinq à dix ans, les réseaux de neurones (deep learning) auront la capacité de faire du feature engineering, d’aller construire d’eux mêmes à partir des données brutes des features importantes en se passant du raisonnement humain. ”

Bouygues Telecom
Nicolas Gaudé



Publicis Worldwide
Samir Amellal
International Chief Data Officer



“ Les approches en deep learning qu’ont menées Facebook et Google nous ont inspirés pour plusieurs projets. Nous avons ainsi déployé une approche deep learning pour un client : il s’agissait de décomposer leur problématique globale, complexe, en plusieurs sous-problématiques que nous avons confiées à des réseaux de neurones. Chaque résolution de sous-problème, allait alimenter une couche inférieure, permettant d’être de plus en plus performant sur la résolution de la problématique d’ensemble. L’intelligence artificielle (c’est à dire pour moi, le système intelligent, et non la conscience artificielle), commence à devenir une solution très intéressante, puisqu’elle va permettre de résoudre de plus en plus des problématiques auxquelles nous n’avions aucun accès précédemment. ”

SPARK

Développé initialement au sein de l'AMP Lab de l'université de Berkeley (Californie), ce projet de framework open source a rejoint en 2013 l'incubateur Apache. Depuis la release de sa première version, en mai 2014, Spark n'en finit plus de grandir, avec un écosystème d'outils permettant à la fois le traitement de batch, l'analyse en continu de flux de données, le machine learning, le calcul de graphes, et l'interrogation de données en SQL-like. Avec son modèle de programmation souvent jugé plus simple que celui d'**Hadoop**, et qui fait appel non pas au **MapReduce** sur disques, mais à de l'in-memory, il autorise des temps d'exécution beaucoup plus courts (jusqu'à 100 fois). De telles caractéristiques font de Spark un outil tout trouvé pour la mise en place d'applications novatrices, explique **Aroua Biri (Sogeti)** :



Sogeti
Aroua Biri

Architecte Cybersécurité & Big Data



Hormis le fait qu'il est un vrai enabler, Spark offre surtout la possibilité de créer très rapidement des applications innovantes. On remarque sur internet de plus en plus de flux de données. Auparavant, nous n'avions pas la capacité de traiter ces données circulant tous azimuts dans les data centers. Pour parvenir à exploiter cette puissance là, il va falloir mettre en œuvre des applications, des services efficaces. Spark, dans sa capacité à traiter très rapidement de gros volumes, de gros flux, est l'outil idéal pour mettre en œuvre ces applications. Reste à trouver les bons cas d'usage !



Autre avantage : Spark s'intègre facilement dans l'écosystème Hadoop, avec lequel il est entièrement compatible, et permet par exemple d'utiliser le gestionnaire de cluster YARN.

“ **Capable de répondre à tous les besoins de la chaîne de transformation et d'exploitation de la donnée, Spark est un peu le couteau suisse du data learning.** ”



Solocal Group - PagesJaunes
Bruno Guilbot

Avec de tels arguments, le framework est en train de séduire de plus en plus d'entreprises françaises, qui n'hésitent plus à le faire passer sur le banc d'essai. Voici quelques retours d'expérience, chez **AccorHotels**, **Bouygues Telecom**, ou encore **Kiabi** :

QUAND SPARK FAIT DES ÉTINCELLES

“ Nous commençons tout juste à travailler avec Spark. Parmi tous les outils qui sont à disposition, et qui sont pour la plupart très volatiles, c'est celui qui semble émerger comme étant le plus stable, le plus évident... Celui en tout cas à côté duquel on ne pourra pas passer. Je suis convaincue de son intérêt, mais nous sommes en train de voir s'il correspond bien, très pragmatiquement à nos attentes, en y développant un cas d'usage. ”

Kiabi
Elisabeth Zehnder
Data Scientist



“ Spark c'est l'outil qu'on utilise quand Python et R ne suffisent plus. Pour traiter efficacement les données, il faut être capable de les stocker dans la mémoire des indicateurs. Or au delà de 128 Gigaoctets, pour un ordinateur même performant, cela ne passe plus en mémoire. Spark va alors permettre de passer à l'échelle en distribuant les calculs auprès des données. Spark est à Python ou à R ce que Hadoop est au file system classique. ”

Bouygues Telecom
Nicolas Gaude
Senior Data Scientist



“ Spark constitue le cadre architectural idéal pour le traitement de données massives et les applications analytiques. Sur le plan des performances, son architecture de traitement en mémoire permet d’effectuer des calculs complexes à très grande vitesse sur des clusters de taille quasi-illimitée. Son architecture est parfaitement adaptée aux algorithmes itératifs tel que le machine learning. Avec Spark, ces algorithmes peuvent être jusqu’à 100 fois plus rapides qu’avec son prédécesseur MapReduce.

Du fait de son support de langages de haut niveau et de sa grande richesse fonctionnelle, Spark simplifie significativement le développement d’applications Big Data, en particulier avec Hadoop. Spark supporte les langages Java, Scala et Python. Il intègre un moteur SQL et supporte les traitements en mode streaming. Il permet, avec très peu de lignes de code, d’écrire des applications Big Data très sophistiquées. Il est devenu depuis peu l’outil de travail de prédilection du Data Scientist.

Couplé à Hadoop, Spark constitue aujourd’hui une architecture Big Data de référence dont on anticipe qu’elle va s’imposer dans les mois et années à venir. ”

Jacques Milman
Architecte Senior Analytics
IBM



“ Spark accélère le time to market de nos algorithmes, tout en optimisant leur fonctionnement. Auparavant les data scientists trouvaient un algorithme grâce à leurs outils (Python ou R), puis livraient ensuite une série de formules mathématiques que l’informatique se chargeait de coder en SQL. Cela prenait du temps et cela dégradait (souvent presque de moitié) la pertinence de l’algorithme. Aujourd’hui, au contraire on va coder directement les algorithmes dans Spark, sans passer par une couche de recodage. Les algorithmes sont donc mis en place beaucoup plus rapidement. Qui plus est, les data scientists vont pouvoir penser en amont à la mise en production tout en travaillant à leurs algorithmes. ”



AccorHotels group
Fabrice Otaño
SVP, Chief Data Officer

TAG MANAGEMENT SYSTEM

Cet outil web de gestion des tags permet de contrôler aisément les différents systèmes d'analyse, de test et de marketing - en somme toute technologie s'appuyant sur du tagging. Les Tags Management Systems (TMS) vont agir comme une conciergerie du site web d'une entreprise : lorsqu'un utilisateur se connectera à certaines pages, ou opéreront certaines actions, ils déclencheront différents pixels de tracking, et passeront le message aux différents outils analytiques et canaux marketing (paid search, affiliation, display, email) que quelque chose de positif ou de négatif vient de se produire. Alors que des mesures de campagne de ce type requièrent habituellement la gestion, par des développeurs, d'une multitude de fragments de javascript dispersés dans différents sites, les TMS vont centraliser ces scripts, et simplifier le tracking.

Au-delà de ces aspects classiques orientés contrôle du site internet et du chemin de conversion, **Pierre-Marie Desbazeille (GrandVision)** voit aussi dans les TMS un outil au service du drive-to-store :



GrandVision
Pierre-Marie Desbazeille
 Directeur CRM & Digital



“ Nous nous sommes équipés d'un Tag Management System il y a un peu plus d'un an maintenant. Nous avons construit une plateforme pour le monde de l'optique, avec une déclinaison par pays. Le déploiement s'est fait pour l'instant en France, en Chine, et est en cours au Bénélux et en Allemagne. L'enjeu à terme va être de faire de ce TMS un outil de commerce en drive-to-store. Le e-commerce ne sera pas, dans les années à venir, quelque chose de significatif en termes de volume dans le monde de l'opt-in. La notion de tag va donc être importante chez nous pour évaluer le drive-to-store. Il faut que cela soit un outil de tracking puissant, qui pourra être remergé avec le comportement client dans son ensemble, et pas simplement une vision du site internet, et du tunnel de conversion. ”

La mise en place d'un TMS pose aussi la question du rapport qu'entretient l'entreprise avec la valorisation des tags : doit-elle confier leur gestion à un prestataire extérieur ? Et en interne, qui doit s'occuper de ce domaine ? Pour **Laurent Aliphat (Renault)**, **Bruno Guilbot (Solocal Group - PagesJaunes)** et **Jonathan Badoux (AXA France)** deux maître mots : contrôle et autonomie.

“ Cela fait quatre ans que nous utilisons des outils de Tag Management System. Nous avons acquis très vite la conviction qu’il était nécessaire de reprendre une certaine forme d’autonomie par rapport à des intégrateurs, ou à une Direction informatique. Aujourd’hui, l’usage du TMS est généralisé chez Renault, et les métiers utilisateurs sont très familiers de l’outil. Vue la volumétrie des tags médias

chez nous, il était capital de donner l’autonomie à chaque pays de faire ce qu’il veut, quand il veut, et sans dépendre d’un planing commun. ”



Renault
Laurent Aliphat
Head of Digital
Performance and Lead
Management

NE PAS LAISSER SES TAGS DANS LA NATURE

“ Afin de mieux contrôler l’ensemble des flux de données issus de nos sites internet, nous avons décidé d’internaliser le tag management anciennement aux mains de nos agences média. Nous avons donc le contrôle sur l’ensemble des étapes clés du Tag Management pour chacun des tags :

- Validation technique des tags
- Définition des paramètres envoyés
- Définition des règles de déclenchement
- Contrôle des appels en cascade
- Intégration dans le TMS
- Maintenance

Ce contrôle nous a permis d’optimiser les performances de chargement de pages de nos sites internet ainsi que la lecture des résultats de campagne média. ”



AXA France
Jonathan Badoux
Responsable Outils Digitaux

“ Le TMS est aujourd’hui un outil indispensable sur les sites et les applis. Il permet de gagner en agilité, en réactivité et en cohérence, et d’être très rapide sur la mise en production de modifications du plan de marquage. Plutôt que d’utiliser une des solutions de TMS disponible sur le marché, nous avons développé notre solution “maison”, que nous avons mis en place en 2012. Cela est satisfaisant pour un site comme PagesJaunes sur lequel on ne fait pas beaucoup de campagnes d’acquisition. ”



**Solocal Group -
PagesJaunes**
Bruno Guilbot
Responsable Smart
Data et Advanced
Analytics

YARN

Sous l'acronyme en forme de clin d'oeil (Yet-Another-Resource-Negotiator) se cache l'une des évolutions architecturales majeures caractéristiques de la nouvelle génération d'Hadoop. Apparue en octobre 2013, et aussi baptisée MapReduce 2.0, YARN est une plateforme de gestion des ressources, qui va permettre à Hadoop d'offrir un plus large éventail d'applications et de processus qu'auparavant. Grâce à lui, le framework d'Apache va ainsi être capable, par exemple, de faire tourner, en même temps que des travaux classiques de MapReduce sur des batchs, des requêtes interactives, et des flux de données. En séparant de la sorte la gestion à proprement parler des ressources des clusters et le traitement des données, YARN rend, au final, possible le temps réel sur Hadoop. Ce que confirme **Fabrice Otaño (AccorHotels)** :




Au départ, les distributions Hadoop n'étaient pas capables de faire du real time, en raison de leur structure même, en clusters. C'est YARN qui, en accélérant radicalement le processus, en calculant des algorithmes à la volée, va permettre de plus en plus de se servir des systèmes d'information en temps réel.



AccorHotels group
Fabrice Otaño
SVP, Chief Data Officer








Au terme de cette liste de mots, certains de nos lecteurs auront sûrement constaté quelques absences, quelques notions qui auraient assurément mérité, elles aussi, de figurer dans ce petit dictionnaire. La raison est simple :

nous avons dû faire des choix. Le vocabulaire du Big Data est, à l'image du secteur qu'il met en mots, en pleine expansion. Alors que les termes les plus fréquents bénéficient d'un éclairage qui les rend de plus en plus compréhensibles y compris pour le grand public, la partie immergée de l'iceberg, elle, continue de grossir en inventant sa propre langue, son propre jargon, compris seulement des techniciens du sujet. Rendre intelligible par le plus grand nombre cette novlangue, qui dans les faits, rend ce secteur opaque pour les non-initiés, voilà un des nombreux défis auquel est confronté le secteur du Big Data sur le chemin de sa démocratisation.



The background is a solid black field with several thin, white, intersecting lines that create a series of overlapping, irregular polygons. These lines are oriented diagonally, giving the composition a sense of dynamic movement and depth. The central focus is the word 'CONTRIBUTEURS' in a bold, white, sans-serif font.

CONTRIBUTEURS



AccorHotels group

Fabrice Otaño

SVP, Chief Data Officer

Fabrice est responsable de la Data pour le groupe AccorHotels qui inclut l'ensemble des ressources BI & Data Science pour la finance, la distribution (Web, Sales, Customer Loyalty, Marketing) et le Revenue Management (Yield, Pricing, Channels) ainsi que les ressources IT du centre de compétences technologiques. Cette Direction anime un réseau de 2000 Business Analysts et Revenue Managers sur l'ensemble du groupe. Après une première expérience chez AT Kearney dans le conseil en stratégie, Il rejoint Softcomputing, startup spécialisée dans la Data science puis prend en charge les équipes de Business Technology Consulting France chez Capgemini. Fabrice est diplômé de l'ESCP (87) et de l'université d'Orsay Paris XI (BSc en Mathématiques).



Air France-KLM

Max Vallejo

Head of eCRM, Digital Department

Max est responsable eCRM au sein de la Direction Digitale Air France-KLM depuis 2011. Il est en charge de la personnalisation du parcours client en ligne, du développement du compte client et de l'outil de gestion de campagnes. Après une première expérience au sein du cabinet Deloitte, il rejoint Air France en 2004, d'abord comme responsable de la synthèse économique du groupe Air France, puis comme Senior Manager en charge du développement du réseau Amérique, Caraïbes et Océan Indien. Il est diplômé de l'école Polytechnique (X99) et de l'Ecole Nationale de la Statistique et de l'Administration Economique.



Groupe Argus

Benoît Chéroux

Responsable Données & Modélisations

Benoît est Responsable Données & Modélisations au sein du groupe Argus, (re)connu notamment pour sa Cote Argus Personnalisée® et ses hors-séries trimestriels Véhicules d'Occasion. Durant une décennie, il a travaillé au sein du Groupe Business & Décision, sur la mise en place de système d'information décisionnel (Moulinex, Virbac, Les Mousquetaires) mais aussi sur la mise en place de systèmes d'élaboration budgétaire ou de consolidation de trésorerie (BNP Paribas, Technip, Lafarge). Il est ensuite entré au sein de la DSI du groupe Argus (en tant que chef de projet Décisionnel) avant d'évoluer sur le poste de responsable Données & Modélisations, avec pour vocation de capter le maximum de données pour produire les indicateurs & les études de marché proposées aux clients du groupe Argus. Benoît est diplômé de l'Ecole Internationale des Sciences du Traitement de l'Information (EISTI, 98).



AXA France

Jonathan Badoux

Responsable Outils Digitaux

Jonathan est responsable de l'intégration des outils digitaux d'AXA France. Après une première expérience chez Johnson & Johnson dans un poste de chef de projet digital transverse car mélangeant achat média, refonte de site web et programme CRM, il travaille depuis un an sur l'implémentation des outils tels que la Data Management Platform, l'adserver et l'outil de recommandation pour AXA France à destination des équipes achat média et webmarketing. Jonathan est diplômé du MBA E-Business de l'Ecole Supérieure de Gestion de Paris (2012).



Bouygues Telecom

Aude Launay

Big Data Business Manager

Aude est Responsable de l'activité Big Data au sein du département Marketing de Bouygues Telecom, avec pour objectif de définir les offres, le go-to-market et d'assurer la commercialisation d'Etudes agrégées et anonymisées à des clients majoritairement B2B. Diplômée de l'ESIEE Paris, elle a débuté sa carrière en 1997 chez Nortel avant de devenir ingénieur avant-vente. En 2002, elle a intégré la Direction Marketing de SPIE Communications, qui lui a confié le lancement des partenariats avec Siemens, puis Microsoft. Elle a ensuite rejoint Dimension Data où elle a dirigé l'équipe marketing et avant-vente sur les solutions de communications unifiées, tout en définissant les offres, les partenaires et la stratégie marketing associées. Aude a ensuite intégré Bouygues Telecom fin 2008, avec la charge successivement du marché PME puis de la stratégie Marketing Entreprises.



Bouygues Telecom

Nicolas Gaude

Senior Data Scientist, Head of Big Data Lab

Senior Data Scientist, Nicolas dirige le Big Data Lab au sein du département Innovation de Bouygues Telecom. A la croisée des chemins entre Big Data et Machine Learning, le Big Data Lab construit des modèles prédictifs à usage de services internes, fraude, attrition, achat... et développe à l'externe des offres B2B de données issues de l'activité du réseau télécom. Ingénieur Physicien diplômé de l'INPG, il a débuté sa carrière en 2000 dans les médias numériques chez Canal Plus puis Technicolor. En 2006 il a rejoint la Direction innovation de NDS-Cisco en qualité d'expert système embarqué. En 2011, Bouygues Telecom lui a confié les équipes logicielles en charge du développement de la BBox Sensation. En 2014 Nicolas a démarré l'activité de valorisation externe des Big Data Bouygues Telecom, mission étendue depuis aux services internes.



France Loisirs

Pascale Dulac

Responsable Connaissance Clients

Pascale est Responsable du département Connaissance Clients de France Loisirs qui inclut notamment les Etudes Datamining, Etudes Marketing et le Data management /gestion opérationnelle de la BDD. Après différentes expériences dans le domaine du conseil et des études, elle a rejoint la société France Loisirs pour prendre en charge le département Connaissance Clients au sein de la Direction Marketing. Pascale est diplômée de l'Ecole des Mines/Paris XIII (D.E.A. Organisation Industrielle, Innovation et Stratégies Internationales).



GrandVision

Pierre-Marie Desbazeille

Directeur CRM & Digital

Directeur CRM & Digital, Pierre-Marie Desbazeille et son équipe sont en charge de la transformation digitale au sein de GrandVision France (GrandOptical et Générale d'optique), leader de l'optique mondial. Refonte des plateformes relationnelles, digitalisation des parcours client : lancement des sites e-commerce/déploiement de dispositifs « drive to store », et mobiles in store, DMP et scoring de réachat sont les principaux challenges relevés ces derniers mois. Entrepreneur dans l'âme, Pierre-Marie a créé sa première agence digitale en Espagne à 27 ans et après de nombreuses années passées en agences spécialisées dans le CRM & Digital, il apporte toute son expertise IT et marketing au sein du Groupe GrandVision NV pour développer une plateforme omnichannel internationale dans 43 pays.



Hoche Société d'Avocats

Régis Carral

Avocat – Associé

Régis est avocat associé responsable du département Propriété Intellectuelle & Technologies de l'Information (IP/IT) au sein de Hoche Société d'Avocats. Régis a auparavant créé et animé pendant plus de 15 ans le département IP/IT du Cabinet PwC Avocats (anciennement Landwell & Associés). Il a développé des compétences spécifiques en matière d'assistance juridique des problématiques NTIC, e-commerce, télécom dans le cadre de projets informatiques et internet (contrats d'intégration d'ERP, licence de progiciels, création de plateformes e-commerce, maintenance, externalisation, dématérialisation, projets Big Data et Cloud Computing, problématiques « privacy » et CNIL, jeux et paris en ligne, etc.). Il anime et participe à de nombreux séminaires et conférences en France et à l'étranger (Les Echos, Legiteam, Cerist à Alger, ...) et est chargé de cours à l'Ecole Nationale Supérieure des Mines de Paris, Master Spécialisé en Management des Systèmes d'Information et des Technologies.



Intel Corporation France

Marie-Christine Sawley

Exascale Lab Director

Marie-Christine Sawley dirige depuis 2010 l'Intel Exascale Lab de Paris. Diplômée de l'EPFL en physique et titulaire d'une thèse en Physique des Plasmas, son expérience du HPC et de l'analyse de données massives s'est constituée au fil de la direction de projets : notamment en tant que Directrice du Centre de Calcul National en Suisse de 2003 à 2008 mais aussi comme l'une des fondatrices en 2002 du centre Vital-IT à Lausanne dédié à la bioinformatique et biosimulation, comme partenaire de EGEE de 2005 à 2007, et en tant que senior scientist sur l'expérience CMS au CERN de 2008 à 2010.


Kiabi
Elisabeth Zehnder
Data scientist

Elisabeth est en charge du projet Big Data - Connaissance Client pour les utilisateurs métier Kiabi. Après un parcours d'analyse de données, conception de systèmes de décision et outils statistiques dans le risque de crédit et le marketing, essentiellement dans le milieu bancaire, Elisabeth a intégré Kiabi pour mettre en place le référentiel Client Unique avant d'enchaîner avec la mise en place du projet Connaissance Client coté métier.


LCL
Christèle Baranco
Responsable Analyse de la Donnée Client

Christèle est responsable du pôle Analyse de la Donnée Client au sein de la Direction du Management de la Donnée et de la Relation Client de LCL. Elle a en charge une équipe d'une quinzaine de personnes regroupant le centre de service de la donnée, le datamining, le géomarketing et le Big Data. Depuis 13 ans au sein du groupe Crédit Agricole, elle a commencé sa carrière comme ingénieur d'études statistiques à la fois dans le domaine marketing et risque, avant de participer au projet de lancement de BforBank, banque en ligne du groupe avec notamment la mise en place de l'équipe Connaissance Client. Christèle est diplômée de l'Ecole Nationale de la Statistique et de l'Analyse de l'Information (ENSAI – promotion 2002).



Groupe Numericable-SFR

Morgane Castanier

Directrice Data et CRM

Morgane Castanier est diplômée de l'Ecole Supérieure de Commerce de Grenoble et a débuté sa carrière aux Editions Play Bac en 1997. Elle a ensuite rejoint le groupe Hebdomag France en 1999 pour prendre la responsabilité du Minitel et de l'Internet, et a été nommée Responsable Marketing online et e-business en novembre 2002. Début 2005, Morgane a rejoint le Groupe Manutan, en qualité de Directrice Marketing et Commerciale. Fin 2006, elle a créé, en association avec le PDG de Netbooster, une agence de conseil en e-marketing, spécialisée dans l'accompagnement et la transformation digitale des entreprises. Début 2008, après une longue mission d'accompagnement en régie au sein du Groupe Sud Ouest, on lui confie la Direction des Nouveaux Media de la filiale S3G. Fin 2010, Morgane a rejoint SFR pour prendre la Direction du Marketing Internet. Début 2015, elle a pris la Direction de la Data et du CRM du nouvel ensemble Numericable-SFR-Virgin avec pour objectif de mettre le digital et les nouveaux outils de traitement et d'activation de la données au cœur des dispositifs et de la stratégie omnicanale.



Oney Banque Accord

Mathieu Escarpit

Directeur Général Italie et Joias

Mathieu est Directeur Général de deux « Data Company » : Oney située à Milan et Joias située à Lisbonne. Ces 2 entreprises sont spécialisées dans le Data Analytics (Big Data, CRM, etc.) pour le retail. Après avoir débuté dans le monde digital des startups, il rentre chez Oney Banque Accord (Groupe Auchan) en 2004 comme Responsable du digital où il y créera notamment l'activité e-commerce. Il rejoint ensuite Nectar (création du plus grand programme de fidélité) en Italie comme Directeur Marketing puis devient Directeur Général de Oney Banque Accord en Italie où il lance la nouvelle activité de Data Analytics. Depuis 2014 il est aussi Directeur Général de Joias. Mathieu est titulaire d'un DESS de Marketing Direct de l'IAE de Lille.



Orange

Geoffrey Zbinden

**Vice President Big Data Analytics
& Customer Base Management**

Geoffrey Zbinden est Vice President Big Data Analytics & Customer Base Management au sein du groupe Orange. Son département est en charge de la stratégie et du déploiement des outils de business intelligence pour les filiales Orange en Europe, Afrique et Moyen-Orient. Geoffrey est en charge de l'utilisation du Big Data pour augmenter la fidélité des clients, l'adoption des nouveaux usages digitaux et la croissance des revenus à travers une centaine de « use cases ». Précédemment, Geoffrey a été Directeur Financier du marché Entreprises d'Orange France, puis Directeur du programme « Machine-to-Machine » d'Orange. Il a également travaillé aux Etats-Unis. En 2010, il a publié un livre intitulé « L'internet des objets, une réponse au réchauffement climatique » aux éditions du Cygne.



Orange Technocentre

Tania Aydenian

Directrice du programme Datavenue

Tania pilote le programme Datavenue, une solution du groupe Orange à la croisée de l'Internet des Objets et de la Data. Datavenue vise à répondre aux enjeux de transformation digitale des entreprises en fournissant un ensemble de solutions et services autour de la donnée et des objets connectés. Après une première expérience en avant-ventes, Tania a poursuivi sa carrière dans la division des achats du groupe où elle a mené des opérations d'outsourcing dans les différentes filiales Orange. Elle a ensuite basculé dans le digital en tant que responsable de partenariats stratégiques dans l'univers de l'Internet et du mobile où elle a établi des accords-cadres avec des acteurs du web et des équipementiers. Tania a une formation d'Ingénieur Telecom au Liban, suivie d'un Mastère en Conception et Architecture de Réseaux à Telecom ParisTech.



Prisma Media Solutions

Mickaële Angeletti

Directrice Recherche & Développement

Mickaële Angeletti a intégré Prisma Media en 2000, d'abord comme Directrice de publicité de VSD, poste qu'elle a occupé pendant près de 4 ans, puis comme Directrice Service Clients jusqu'en 2005. Elle a ensuite évolué vers le poste de Directrice Etudes Publicitaires et Service Clients puis Directrice Media Solutions avant de devenir Directrice Recherche et Développement. Elle se charge notamment de la veille internationale, de l'analyse de marchés avec identification de potentiel de chiffre d'affaires publicitaire (Presse et Digital) et du développement d'offres stratégiques. En parallèle, elle coordonne le projet Media du Futur.



Groupe Prisma Media

Yoann Denée

Chief Data Officer

Yoann Denée a exercé des fonctions de Direction Générale entre 2007 et 2012 au sein de groupes technologiques tels que Directinet-Netcollections, NP6. Il a rejoint Prisma Media en 2012 pour prendre la Direction de la filiale performance «p-comme-performance» dont il restructure l'offre, son positionnement et procède à son intégration. En parallèle, depuis 2013, il prend en charge le projet d'entreprise PrismaData. Depuis 2015, Yoann Denée est Chief Data Officer de Prisma Media et assure également la fonction de Correspondant Informatique et Libertés.



Publicis Worldwide

Samir Amellal

International Chief Data Officer

Après des débuts à La Redoute, puis plusieurs années chez Buongiorno, filiale de l'opérateur télécom japonais NTT Docomo sur des projets R&D, Samir Amellal a rejoint l'agence Publicis ETO en tant que Directeur de compte Data avant de prendre la Direction de son pôle Data Science. Depuis peu Samir est le Chief Data Officer de Publicis WW et a pour mission de rendre la donnée plus accessible et mieux exploitée dans l'ensemble du réseau Publicis WW.



Groupe Renault

Laurent Aliphat

**Head of Digital Performance
and Lead Management**

Laurent est manager de l'activité Performance au sein de la Digital Factory au siège international de Renault. La finalité principale est d'aider les équipes à valoriser la contribution aux ventes et de les animer dans une logique de tests et de progrès permanent. L'utilisation de la data est au cœur des leviers d'optimisation paid, owned et earned media. Il a rejoint le groupe il y a quatre ans, après une précédente expérience de responsable de la publicité, des médias et du digital pour les marques Fiat, Lancia et Alfa Romeo. Laurent est diplômé de NEOMA – Sup de Co Reims (51).



Sanofi

Pierre-Yves Lastic

Associate Vice President, Chief Privacy Officer

Pierre-Yves est le responsable mondial de la protection des données personnelles de Sanofi. Il a étudié la biologie, les langues et l'informatique en France et en Allemagne, et est titulaire d'un doctorat ès sciences de l'université de Bayreuth. Après un premier poste universitaire, il a fait l'essentiel de sa carrière au sein de la R&D pharmaceutique, où il a occupé depuis 25 ans différentes fonctions de management, en particulier en gestion de données, biostatistique, gestion des études cliniques, gestion de l'information et protection des données. Il exerce également plusieurs mandats au sein de différents consortiums : *Chairman of the Board of Directors of the Clinical Data Interchange Standards Consortium (CDISC)*, *member of the Board of Directors of the International Pharmaceutical Privacy Consortium (IPPC)* et *member of the Executive Advisory Board of Safe BioPharma*. Enfin, il participe en tant qu'expert à l'*EudraVigilance Expert Working Group* et au *Telematics Implementation Group* de l'Agence Européenne du Médicament (EMA) et enseigne le Data Management à l'*European Centre of Pharmaceutical Medicine (ECPM)* à Bâle.



Schlumberger

Olivier Brousseau

IT Business Intelligence Strategy Manager

Olivier est responsable de la stratégie Business Intelligence pour Schlumberger. Après une première expérience en R&D télécom et intégration de système, il a rejoint Schlumberger pour piloter la cellule d'Enterprise Architecture, puis a pris la responsabilité opérationnelle de la plateforme BI globale à l'entreprise. Olivier est diplômé de l'ICAM (96) et Supélec (97).



Schneider Electric

Joël Aznar

**Global Purchasing - Director,
Master Data Governance**

Joël Aznar est Directeur de la Gouvernance des Master Data pour la fonction Achats du groupe Schneider Electric. Cette organisation globale est en charge de la gestion des référentiels Achats dans le but de faciliter la mise à disposition de ces données, de garantir leur cohérence, leur validité et leur précision, afin d'améliorer la prise de décision ainsi que l'efficacité globale de la fonction. Depuis plus de 19 ans chez Schneider Electric, Joël a débuté sa carrière en tant que manager Achats au sein de la filiale Schneider Electric Espagne, puis responsable des systèmes d'information Achats France, Europe et EMEAS avant de rejoindre la Direction Achats groupe. Joël Aznar est également professeur partenaire de Grenoble Ecole de Management (GEM - ESC) depuis 2006 dans le cadre du Master en Management des Achats. Il enseigne par ailleurs à l'ESIAC/ESCA (Maroc), à MDI (Algérie) et en France à l'EHESP (Ecole des Hautes Etudes de la Santé Publique). Enfin il intervient comme membre du comité de pilotage de l'Institut de Recherche et d'Innovation en Management des Achats «IRIMA» en tant qu'expert en SRM, e-procurement et P2P. En charge des enjeux Master Data depuis bientôt 3 ans, son approche est essentiellement pragmatique et centrée sur les résultats et l'efficacité du métier.



SNCF

Maguelonne Chandesris

**Responsable de l'équipe Innovation & Recherche
«Statistique, Econométrie et Datamining»**

Maguelonne Chandesris est responsable de la thématique Innovation & Recherche «Data, Mobilité et Territoires» pour la SNCF. Elle est également en charge de l'équipe «Statistique, Econométrie et Datamining» qui développe des solutions de traitements statistiques avancées et de visualisation d'importants volumes de données au service de différentes activités du groupe SNCF. Diplômée de l'Ecole Nationale de la Statistique et de l'Analyse de l'Information (ENSAI), elle est également titulaire d'un doctorat de Paris VI en mathématiques.



Sogeti

Aroua Biri

Architecte Cybersécurité & Big Data

Aroua Biri est architecte en cybersécurité et Big Data chez Sogeti. Elle travaille depuis 2006 pour le compte de grands consortiums européens et nationaux ainsi que pour le compte de grands groupes du CAC 40 (Société Générale, Engie, ERDF, Total etc.). Elle fait également partie des 150 expertes du numérique recensées en France par GirlInWeb. Ce projet d'annuaire est soutenu par Google for Entrepreneurs, NUMA et le Women's Forum. Par ailleurs, elle travaille actuellement sur les impacts de la transformation digitale sur les business models ainsi que sur la sécurisation des architectures Big Data et la supervision métier des objets connectés. Aroua est ingénieur informatique diplômée d'un doctorat en cybersécurité de Télécom SudParis et de l'UPMC ainsi que d'un Master en Réseaux Informatiques de l'UPMC.



Solocal Group - PagesJaunes

Bruno Guilbot

Responsable Smart Data et Advanced Analytics

Bruno est responsable des analyses et de l'exploitation des données digitales de Solocal Group, qui comprend notamment les marques PagesJaunes, Mappy, Ooreka et A Vendre à Louer. Il travaille sur les problématiques Big Data, sur l'exploitation et la valorisation des données via la data science et la data visualization. Après une première expérience de Dataminer en agence marketing (Draft Paris), il s'est orienté vers le digital en travaillant d'abord sur l'email marketing (chez Directinet) puis en agence CRM et Digital (Ogilvy One) sur du conseil data-marketing. Il a rejoint le groupe Solocal en 2011 pour travailler sur la connaissance et la fidélité des utilisateurs des services PagesJaunes et exploite aujourd'hui l'ensemble des données digitales pour optimiser les services et démontrer le ROI des produits publicitaires du groupe. Bruno est diplômé de l'Ecole Nationale de la Statistique et de l'Analyse de l'Information (ENSAI 2003).



Swiss Life France

Christian Phan Trong
Directeur de l'Architecture

Christian est Directeur de l'Architecture au sein de la DSI de Swiss Life. Il est en charge de définir les orientations d'évolution du SI et d'accompagner les projets dans leur concrétisation, ce qui implique un rôle de conseil et d'anticipation par rapport aux évolutions liées au digital, dont les usages Big Data. Christian est diplômé de l'Ecole Centrale de Lyon et a exercé pendant 13 ans en société de services informatique, notamment chez Lyon Consultants et IBM Global Services avant de rejoindre Sanofi Aventis, puis en 2007 AXA France où il a œuvré comme Architecte d'Entreprise sur le périmètre Distribution, Internet et Marketing. Il a intégré Swiss Life France en 2012.



Télécom-ParisTech, Institut Mines-Télécom

Stéphane Cléménçon
Professeur et Responsable
du Mastère Spécialisé Big Data

Stéphane Cléménçon est Professeur à Télécom-ParisTech, Institut Mines-Télécom, au sein du Département TSI et anime le groupe de recherche STA. Il effectue ses travaux de recherche en mathématiques appliquées au LTCI UMR Télécom ParisTech/CNRS No. 5141. Ses thématiques de recherche se situent principalement dans les domaines du machine-learning, des probabilités et des statistiques. Il est responsable du Mastère Spécialisé Big Data à Télécom Paris-Tech et titulaire de la chaire industrielle « Machine-Learning for Big Data ».



Thales Communications et Sécurité

Jean-François Marcotorchino
Vice Président et Directeur Scientifique
de Thales GBU SIX

Jean-François Marcotorchino est actuellement et depuis 10 ans Vice Président, Directeur Scientifique de Thales GBU SIX, et « Thales Technical Fellow ». Parallèlement à son activité Thales, Jean-François Marcotorchino est titulaire du titre de Professeur des Universités (Directeur de Recherche au Labo de Statistique Théorique et Appliquée LSTA de Paris VI). Il a auparavant été pendant 30 ans membre d'IBM France et d'IBM EMEA, et en particulier pendant 10 ans, Directeur du Centre Scientifique IBM de Paris et de l'« *European Centre for Applied Mathematics (ECAM)* » d'IBM EMEA.



The Economist

Stéphane Père
Chief Data Officer (Global)

Stéphane Père est Chief Data Officer (Global) chez The Economist. Sa mission est de promouvoir les données au rang d'actif stratégique de l'entreprise, de les protéger en tant que tel ; mais aussi d'utiliser le traitement des données pour soutenir la croissance des revenus de la diffusion et de la publicité, ainsi qu'explorer les nouvelles perspectives offertes par les Big Data. Il a rejoint The Economist dans ses bureaux à Paris en 2007 dans le but de gérer les ventes de publicité en ligne pour l'Europe Continentale, le Moyen-Orient et l'Afrique. En 2010, il s'installe à New York pour lancer *Ideas People Channel* (un réseau publicitaire). A partir de 2012, il était aussi le Directeur Commercial de The Economist pour les Agences et la publicité digitale de la région Amériques. Avant de rejoindre The Economist, Stéphane Père a eu une carrière variée dans le secteur de la publicité : en ligne chez Yahoo!, télévision pour Bloomberg et aussi animation commerciale d'un réseau d'agents pour Canal+.



Voyages-sncf.com

Angélique Bidault-Verliac

Responsable du Pôle Data & Webmining

Angélique a débuté sa carrière en tant que Consultant Data dans une web-agency sur des problématiques CRM & web analytiques. Chez Voyages-sncf.com, elle est responsable du Pôle Data & Webmining dont l'un des enjeux est de développer la connaissance client, en s'appuyant notamment sur les nouvelles opportunités du Big Data. Angélique est diplômée d'un DEA de Mathématiques à l'Université Pierre et Marie-Curie et elle a obtenu un Mastère Spécialisé en Marketing Management à l'ESSEC.




Voyages-sncf.com

Marie-Laure Cassé

Directrice Marketing Client & Data

Chez Voyages-sncf.com depuis 2010, Marie-Laure Cassé a occupé la fonction de Directrice Marketing Digital avant de prendre la responsabilité depuis un an du « Big Data client » dont les missions consistent, grâce à l'exploitation de la data à développer la connaissance clients, à implémenter des solutions pour mieux personnaliser l'expérience utilisateur, à booster la performance du marketing digital etc. Auparavant, elle a exercé plusieurs fonctions au sein du marketing de La Fnac. Marie-Laure Cassé est diplômée de l'ESCP Europe.



PARTENAIRES

55 the data agency

fifty-five accompagne les entreprises dans l'exploitation de leurs données au service d'un marketing et un achat-média plus performants. Partenaire des annonceurs de la collecte à l'activation des données, l'agence aide les organisations à devenir de véritables entités omnicanales, maîtrisant l'efficacité de leur écosystème digital et ses synergies avec le monde physique. Reconnue « Jeune Entreprise Innovante » et membre du réseau Bpifrance Excellence, **fifty-five** propose des prestations associant conseil, services et technologie et compte aujourd'hui 3 bureaux à Paris, Londres et Hong Kong.

Son offre s'articule autour de quatre piliers stratégiques :



Collecte
de données



Connaissance-client
et engagement



Efficacité
média



Stratégie data
& digitale

- La première agence à l'ADN 100 % data
- Plus de 20 partenariats avec les leaders technologiques mondiaux : Google, Facebook, Adobe, Oracle, Tableau Software, Baidu...
- Plus de 80 clients actifs, dont 40 % du CAC 40
- 10 labels ou prix d'excellence et d'innovation
- L'équivalent de 15 % des effectifs investis en R&D
- 3 bureaux : Paris, Londres, Hong Kong
- Une approche holistique de l'activité digitale
- Des clients dans tous les secteurs, du Travel au Luxe, du FMCG à l'Entertainment

Avec le développement d'Internet et des usages mobiles et cross-canaux, la quantité de données disponibles explose, et le marketing devient de plus en plus technologique. Ces données représentent une énorme opportunité pour les Directions Marketing pour mieux connaître leurs cibles, segmenter leurs audiences et avoir une communication plus efficace. Mais c'est aussi un défi considérable d'un point de vue technologique, organisationnel et méthodologique, de collecter, analyser et exploiter ces données.

Née de ce constat, fifty-five a pour vocation de mettre la donnée au service du marketing et de l'expérience-client, grâce à l'alliance native de ces différentes expertises. Proposant une approche holistique du marketing, fifty-five intervient sur la globalité de la chaîne de valeur de la data, de la collecte à l'activation, en passant par toutes les étapes du travail de la donnée qui lui confère sa valeur : réconciliation, fiabilisation, organisation, mining, scoring, etc. Pionnière dans le secteur, fifty-five est une nouvelle forme d'agence, à la confluence de l'achat-média, du conseil, de l'analytics et de l'ingénierie.

Partenaire des solutions les plus innovantes et les plus robustes du marché, dont Google, Facebook, Adobe, Oracle, Acxiom, ou encore Baidu, fifty-five est agnostique sur le plan technologique. Cela lui permet de mettre sa connaissance fine des différents écosystèmes digitaux et technologiques ("stacks") au service de ses clients, pour les accompagner dans le choix et l'implémentation des solutions les mieux adaptées à leurs besoins.

Ce positionnement original, alliant expertise technique, vision stratégique et excellence opérationnelle, fait de fifty-five un pure player disruptif sur le marché de l'achat média et du conseil, catalyseur d'innovation pour les marques.

fifty-five

4, place de l'Opéra
75002 Paris
contact@fifty-five.com
+33 1 76 21 91 37

Nicolas Beauchesne, Co-fondateur, DG

Plus de dix ans d'expérience dans le web ont rompu Nicolas aux nouveaux formats publicitaires et aux problématiques e-commerce. Diplômé d'ESCP Europe, il fait ses premières armes au sein du groupe Vivendi Universal, avant de rejoindre Photoways.com en tant que DG-adjoint. Chez Google, il travaille d'abord au déploiement de l'offre Adwords dans le secteur Media & Entertainment, jusqu'au lancement de l'offre YouTube et Google Display dont il devient Directeur. Chez fifty-five, il est en charge du développement commercial et du staffing.

Alan Boydell, Co-fondateur, Directeur Data Insight & Analytics

De nombreuses années chez Google comme responsable Google Analytics pour l'Europe du Sud ont fait d'Alan un expert européen en webanalyse et en testing. Auteur du blog «The Analytics Factor», cet universitaire écossais détenteur de deux Masters of Arts a également co-écrit le premier manuel d'utilisation francophone sur Google Analytics, paru chez Pearson en 2010. Il quitte Google pour l'agence Keyade, avant de co-fonder fifty-five.

Mats Carduner, CEO et co-fondateur

Mats Carduner débute sa carrière au marketing chez L'Oréal en 1992 avant d'entrer rapidement dans le secteur d'Internet, en 1995. Il entre chez le fournisseur d'accès Infonie, puis atterrit chez Havas où il est chargé de trouver des débouchés numériques aux contenus, jusqu'en 1998. Il devient ensuite Directeur Général de Monster, qu'il développe en France pendant cinq ans, avant de tout quitter pour créer, avec deux amis, son réseau social professionnel. En 2004, il prend les rênes de Google France, puis Europe du Sud. Six ans plus tard, il crée la data agency fifty-five.

Arnaud Massonnie, Co-fondateur, DG

Diplômé de l'EDHEC, Arnaud est un entrepreneur dans l'âme, avec à son actif un brevet et trois startups Internet, dont un réseau social cédé au Figaro. Après avoir débuté chez Havas Interactive, il rejoint Monster.com comme Directeur Marketing France. Il monte ensuite la division e-learning de Atlas. Il entre enfin chez Google en 2005, où il prend la Direction des opérations pour l'Europe du Sud, puis co-fonde fifty-five.

Jean Neltner, Co-fondateur, DG

Diplômé de l'EM Lyon, Jean Neltner est spécialiste du business développement sur Internet. Son expertise porte sur tous les secteurs : finance, technologie, CPG, B2B. Il participe à la croissance rapide du secteur de l'Internet d'abord en tant que Directeur Commercial chez Infonie, puis comme Directeur du Business Development chez Lycos et EGG. Avant de co-fonder fifty-five en 2010, Jean Neltner passe par Google pour gérer les partenariats stratégiques.



BIG DATA & ANALYTICS

IBM considère la data comme une matière première très précieuse, au cœur de la transformation des entreprises. Sur un marché concurrentiel accru par l'arrivée de nouveaux acteurs, les entreprises ont plus que jamais besoin de transformer des données brutes en informations pertinentes pour aider à la prise de décision.

Aider les entreprises à être plus réactives et à prendre les meilleures décisions possibles

Dans ce contexte, IBM aide les entreprises à valoriser les données – internes et externes, structurées et non structurées – pour prendre les meilleures décisions possibles sur des sujets tels que :

- Améliorer le pilotage de la performance
- Choisir l'implantation des points de vente
- Disposer d'une vision 360° d'un client ou d'un produit
- Analyser les interactions des marques avec les clients via les réseaux sociaux
- Développer l'intimité client
- Créer des expériences clients personnalisées, etc.
- Optimiser les stocks et le réassort des produits

IBM, Partenaire de la transformation numérique des entreprises

IBM est un acteur international majeur dans le domaine des services et solutions analytiques et Big Data. Nous accompagnons les entreprises de toutes tailles et de tous secteurs depuis la phase de cadrage jusqu'à la mise en œuvre de leurs projets autour de la donnée et les aidons à créer de nouveaux modèles économiques. Nous nous appuyons sur une expertise IT et métier reconnue, des technologies innovantes et ouvertes et une approche agile.

De plus, afin de permettre aux entreprises de corrélérer leurs données internes avec des informations issues de l'extérieur pour en tirer plus de valeur, IBM a noué des partenariats stratégiques, avec Twitter par exemple, et a acquis des actifs de The Weather Company, spécialiste américain de la météorologie. Enfin, IBM investit de manière importante dans l'Internet des Objets et l'informatique cognitive avec Watson.

Un large portefeuille d'offres pour collecter, stocker, traiter et valoriser la donnée

Les offres d'IBM sont disponibles « on premise » et/ou en mode SaaS. En complément de ses solutions propriétaires, IBM se positionne sur les technologies open source avec son offre BigInsights for Apache Hadoop et est un acteur majeur de la communauté Apache Spark. Signe de son engagement fort dans l'open source, IBM est membre fondateur du consortium Open Data Platform (ODPi.org).

- **BigInsights for Apache Hadoop :**
Traiter et analyser tous types de données sur des clusters de serveurs
- **Stream computing (Streams) :**
Analyser en temps réel, sur des flux de tous types, des volumes massifs de données
- **Solutions de Data Warehousing :**
en mode appliance (PureData for Analytics), Software (DB2 BLU) ou en mode Cloud (dashDB)
Effectuer des analyses poussées « in database »
- **Data visualization**
(Watson Explorer, Watson Analytics et Cognos Analytics) :
Chercher, découvrir et visualiser des données quels que soient leur source ou format
- **Intégration et gouvernance des données (InfoSphere) :**
Comprendre, créer, gérer, transformer et distribuer des données de qualité
- **Business Intelligence (Cognos) :**
Accéder et analyser les informations nécessaires à la prise de décisions
- **Analyse prédictive (SPSS) :**
Découvrir des tendances non visibles et anticiper avec précision les résultats
- **Cloud Data Services (Cloudant, dashDB) :**
Collecter, traiter et analyser la donnée dans le Cloud IBM

Pour en savoir plus,
consultez notre site Internet :
www.ibm.com/software/fr/data/bigdata/

IBM

17 avenue de l'Europe,
92275 Bois Colombes
France
+33 (0)1 58 75 00 00
www.ibm.com/fr

Contact

Aline Michel

Portfolio Marketing Manager – Big Data & Analytics
IBM France
+33 (0)6 08 88 37 06
aline.michel@fr.ibm.com

Experts IBM cités dans cet ouvrage :

Laurent Sergueenkoff

[Analytics Platform Sales Team Leader](#)
IBM France



Laurent Sergueenkoff est en charge de la vente des offres IBM Analytics Platform (gestion de la donnée) auprès des grands clients français. Après un DEA d'informatique à l'université de Paris VII Denis Diderot, il travaille pendant 10 ans sur des projets autour des bases données. Il rejoint ensuite les entités commerciales Sun puis Oracle. Depuis 2011 chez IBM, il développe les activités logicielles autour du Datawarehouse et du Big Data. A ce titre, et fort de nombreux retours d'expérience clients, il participe régulièrement à des communications et événements liés au Big Data en France et aux Etats-Unis.

Jacques Milman

Architecte Senior Analytics

IBM France



Jacques Milman est consultant architecte senior avec une très grande expérience des solutions Big Data & Analytics. Il a mené de grands projets de Datawarehouse et de Big Data dans le monde entier et se consacre quasi exclusivement depuis quatre ans aux projets Big Data. Jacques Milman a

débuté comme consultant dans le monde du conseil et des sociétés de service pour ensuite évoluer vers le monde des éditeurs. Il occupe actuellement le rôle d'architecte leader sur les solutions Big Data & Analytics pour IBM France. Auparavant, il a travaillé deux ans en Asie et avait la responsabilité de l'animation et du coaching de la communauté des architectes IBM dans le domaine Big Data.

Dan Benouaisch

Directeur Technique Analytics

IBM France



Après un double diplôme franco-britannique en management, Dan Benouaisch réalise sa première expérience professionnelle aux Etats-Unis dans un groupe industriel et consolide son parcours en effectuant une évolution de carrière progressive chez IBM ; il débute comme consultant dans les

systèmes d'information. Depuis 2011, Dan Benouaisch est Directeur Technique dans l'entité Analytics d'IBM France. Son rôle est de conseiller et de proposer des solutions en matière d'intégration de données, de Master Data Management et de Content Management pour répondre aux besoins de gouvernance des entreprises.



PwC développe en France et dans les pays francophones d'Afrique des missions d'audit, d'expertise comptable et de conseil créatrices de valeur pour ses clients, privilégiant des approches sectorielles.

La raison d'être de PwC est de renforcer la confiance au sein de la société et d'apporter des solutions aux enjeux stratégiques de ses clients. Plus de 208 000 personnes dans 157 pays à travers le réseau PwC partagent idées, expertises et perspectives innovantes au bénéfice de la qualité de service pour leurs clients et partenaires.

Les entités françaises et des pays francophones d'Afrique membres de PwC rassemblent 5 000 personnes couvrant 23 pays.

PwC accompagne les entreprises françaises et internationales à travers ses trois activités de conseil :

- **Conseil en stratégie**
- **Conseil en en management & organisation**
- **Conseil en transactions**

PwC
France & Afrique francophone
toutes activités confondues
a enregistré

810
MILLIONS d'€
de chiffre
d'affaires

L'activité
CONSULTING
réalise

+15%
de chiffre
d'affaires

sur l'année 2014-2015

Aujourd'hui, pour gagner des parts de marché, il ne suffit pas d'avoir des stratégies bien pensées. Il faut aussi qu'elles soient bien exécutées. C'est pourquoi nous accompagnons nos clients sur l'ensemble de la chaîne de valeur, de la vision à l'action.

L'activité Consulting de PwC France réalise ainsi + 15 %, soit un taux de croissance nettement au-dessus du marché. Cette performance s'explique par notre stratégie de croissance externe et de développement de nouvelles compétences, de nouvelles offres et de nouveaux outils.

Le conseil en stratégie reste pour PwC un axe majeur d'investissement. Nous avons finalisé l'intégration des équipes de Strategy& au sein de PwC avec un pôle significatif de 130 consultants en stratégie. Nous avons ainsi la volonté de proposer un continuum de services entre la stratégie et sa mise en œuvre opérationnelle, en abordant les projets de transformation le plus en amont possible, tout en ayant ensuite la capacité de mettre en place les outils les plus adaptés. Nous avons ainsi développé de fortes expertises dans le domaine des nouvelles technologies, qui nous permettent d'accompagner nos clients jusqu'à la mise en œuvre effective de leur transformation.

Tous les grands groupes se posent aujourd'hui des questions sur la transition numérique et ses impacts sur leur stratégie. Alors que l'expertise de Strategy& est reconnue dans le domaine de la transformation digitale, nous avons décidé de pousser notre logique de continuum de services très loin dans l'exécution. Nous venons ainsi d'acquérir Nealite, une agence digitale de 40 personnes, leader français du « design de services » et de l'expérience utilisateur, qui propose une méthodologie innovante alliant conseil et réalisation et permet d'imaginer et de concevoir des services multicanaux et digitaux toujours plus innovants.

L'avalanche de données constitue également un moteur profond de transformation pour les entreprises. Nous investissons donc sur la donnée pour accompagner les entreprises vers des organisations « data driven » et avons créé un laboratoire « Data Analytics » dès 2013.

Si le marché du conseil est stimulé par la transformation digitale de nos clients, nous nous transformons aussi. Chez PwC, nous développons, en mode laboratoire, des approches expérimentales qui préfigurent le conseil de demain. Nous nous imprégnons de l'esprit startup pour changer nos méthodes de travail. A titre d'exemple, nous investissons dans l'open innovation en nous appuyant sur de jeunes consultants, qui apportent des idées de nouveaux services ou imaginent de nouveaux modes de fonctionnement. Les consultants doivent être agiles, proposer à leurs clients de travailler en cycles courts, cibler rapidement et de façon objective les enjeux clés et délivrer des résultats dès les premières étapes.

PwC

63 Rue de Villiers
92208 Neuilly-sur-Seine
France
+33 (0)1 56 57 58 59

www.pwc.fr

Marc Damez-Fontaine

Senior Manager

PwC



Marc Damez-Fontaine est Docteur en informatique avec une spécialité en intelligence artificielle et en machine learning de l'Université Pierre et Marie Curie. Après plusieurs années de recherche dans un laboratoire du CNRS pendant lequel il expérimente de nombreux algorithmes d'analyses données

sur de nombreux cas pratiques, il s'oriente vers le conseil comme Responsable scientifique d'une solution logiciel. Passionné par la data science et l'innovation dans les entreprises il rejoint l'équipe New Business de PwC en 2015 afin d'élargir l'offre de conseil en technologie.

Loïc Mesnage

Partner

PwC



Loïc Mesnage, est diplômé d'un MBA de la Booth School of Business (University of Chicago) et de l'Institut Supérieur du Commerce. Il débute sa carrière comme contrôleur de gestion chez Carbone Lorraine (Groupe Pechiney), avant de rejoindre Concept, éditeur de logiciel financier, à différents postes. En

2001, il intègre PwC au sein de l'activité Développement, avant de rejoindre en 2008 les équipes Consulting. Spécialisé dans les secteurs Energy & Utilities et Consumer Goods, Loïc Mesnage est spécialisé en stratégie des systèmes d'information, transformation par les systèmes d'information, conception et mise en œuvre de systèmes d'information financiers, et Big Data.

TURN

TURN fournit des informations en temps réel qui révolutionnent le processus de prise de décision en matière de marketing des agences média et des entreprises leader. Notre plateforme digitale dédiée aux professionnels du marketing (DSP + DMP) permet de centraliser les données, de lancer des campagnes sur différents terminaux et de réaliser des analyses poussées, le tout en ayant accès en un clic à plus de 150 partenaires technologiques et de données intégrées. Turn, dont le siège se situe dans la Silicon Valley, compte des clients utilisateurs de ses produits et services dans le monde entier. Pour plus de détails, rendez-vous sur www.turn.com ou suivez-nous sur [@turnplatform](https://twitter.com/turnplatform).

Digital Hub de Turn pour les spécialistes du marketing

*Des renseignements au passage à l'action.
Une plate-forme intégrée et unique de marketing.*

Bienvenue dans l'ère du marketing vivant et évolutif

Digital Hub de Turn pour spécialistes du marketing est une plateforme intégrée dès l'origine, qui vous met en contact avec vos audiences et leurs besoins en constante évolution, si bien que chaque interaction est motivée par des données adaptées et spécifiques à une audience précise. Que l'objectif soit le développement de votre marque ou le lancement d'une campagne de réponse directe, notre accent sur l'intégralité du parcours d'achat vous apporte les données en temps réel et la profondeur de renseignements nécessaire à l'atteinte de vos objectifs.

Le marketing guidé par les données n'a aucune raison d'être compliqué

Digital Hub simplifie et rationalise le marketing en supprimant les obstacles entre sources de données et actions de marketing. Notre plateforme unique allie une puissante plateforme de gestion des données (DMP) et une plateforme côté demande (DSP) étendue, le tout supporté par une analyse robuste des données et un vaste écosystème de partenaires. Ceci vous permet de comprendre les données d'audience et de campagne, puis de les utiliser à des fins de planification et d'activation sur tous les canaux. Vous réagissez ainsi aux actions de votre audience tout en offrant à chacun de vos clients une expérience de marque cohérente.

La puissance d'une plateforme intégrée

Grâce à Digital Hub, votre gestion des données, vos segments d'audience, vos achats numériques et vos analyses avancées fonctionnent toutes sur les mêmes profils de consommateurs. Ainsi, vos données d'audience sont constamment mises à jour et vos achats programmatiques sont toujours basés sur les données d'audience et de campagne les plus récentes et les plus appropriées. En outre, l'intégration supplémentaire des analyses granulaires de marché et le reporting en temps réel vous donnent un accès direct à des données et à des renseignements de grande valeur, que ce soit en termes d'optimisation immédiate ou de planification de campagnes à venir.

Aucune perte de données : touchez 100% de votre audience

Lorsqu'une plateforme DMP autonome se connecte à une DSP également autonome, elle subit une perte de données allant de 20 à 40%. À quoi correspond cette déperdition ? À votre capacité à atteindre les segments d'audience prévus dans votre DMP. Ceci est dû au fait que ces systèmes distincts utilisent des ID d'utilisateur différents, ce qui rend impossible une correspondance parfaite. Et si vous ne parvenez pas à faire correspondre les utilisateurs de votre DMP à ceux de la DSP, vous ne pouvez jamais les atteindre. En revanche, la plateforme de Turn est intégrée dès l'origine, ce qui élimine les pertes de données entre les systèmes et vous permet d'atteindre toutes les audiences qui représentent un intérêt pour vous.

Aucune déperdition : accédez à l'intégralité de vos données, quel que soit le moment où vous en avez besoin

Les DMP autonomes ne permettent pas un accès immédiat aux données de média vitales générées dans la DSP, données qui sont pourtant cruciales pour une bonne compréhension de la manière d'optimiser les campagnes et d'interagir au mieux avec votre audience. De plus, les plus grands réseaux publicitaires, tels que Google Display Network, appliquent des règles qui empêchent les plateformes de gestion des données (DMP) autonomes de recueillir des données de campagne. Seule la plateforme intégrée de Turn est capable de fournir un accès instantané aux renseignements dont vous avez besoin : performance de votre campagne, sur quels médias et auprès de quelles audiences. Il vous suffit alors de les relier à vos profils d'audience personnels pour avoir une vision claire de vos données publicitaires.

Aucune latence : ne manquez aucune occasion d'interaction

En matière de programmation, chaque milliseconde compte. L'action en temps réel est ce qui sépare l'interaction aux moments cruciaux de la perte d'occasions qui auraient pu influencer la décision des clients ou améliorer leur expérience de marque. Les DMP autonomes mettent du temps à se synchroniser avec les DSP – jusqu'à 24 heures dans la plupart des cas, ce qui équivaut à environ 485 occasions ratées. Grâce à la plateforme intégrée de Turn, vos données sont mises à jour en quelques millisecondes – ce qui vous permet de tirer profit d'une segmentation et d'une classification en temps réel pour identifier, convertir et interagir avec les bonnes audiences.



Contact : Kamal Mouhcine

Directeur Commercial de Turn en Europe du Sud
kamal.mouhcine@turn.com | +33 6 42 10 97 69

18 rue Pasquier - 75008 Paris | +33 1 70 61 05 06 | www.turn.com

Avec plus de 10 ans d'expérience dans l'industrie des médias, Kamal Mouhcine a pour principales missions de développer le chiffre d'affaires de la société pour l'Europe du Sud. Avec un début de carrière chez Microsoft Advertising dans le cadre du programme Mach réservé aux « hauts potentiels », où il était en charge du développement des offres commerciales de la régie pour les plus grandes agences stratégiques comme AEGIS et Publicis, Kamal a par la suite acquis une solide expérience internationale de Management d'équipe chez Yahoo Europe (Barcelone). Il a dans un premier temps développé le Midmarket pour les marchés Français et Espagnol avant de revenir chez Yahoo France (Paris) pour prendre le management des équipes Annonceurs en charge des verticaux stratégiques Telco, Finance et Gambling.

LA VIE D'UNE PUBLICITÉ

Si l'élaboration de la stratégie de campagne publicitaire parfaite peut prendre des semaines au marketing, il suffit d'une fraction de seconde pour livrer et afficher la publicité.



ÉLABORATION D'UNE CAMPAGNE PUBLICITAIRE EN LIGNE

1. CONNECTEZ les données first party provenant du CRM, de la campagne et du site web de l'annonceur avec les données provenant des analyses, comportementales, contextuelles et démographiques (third party) au sein d'une plate-forme de gestion des données (DMP).

2. DÉFINISSEZ les segments d'audience dans la plate-forme de gestion des données (DMP) en fonction des besoins de

3. ÉLABOREZ une campagne publicitaire qui cible votre audience.

4. CONVENEZ D'UN BUDGET pour la campagne publicitaire en ligne et développez un plan média.

5. CONCEVEZ une annonce adaptée à plusieurs supports (vidéo, display, mobile ou réseaux sociaux) et appareils.

6. DIFFUSEZ LA PUBLICITÉ à partir d'une Demand Side Platform (DSP – plate-forme axée sur la demande), la technologie d'achat média.

7. OPTIMISEZ la performance de votre campagne et analysez les résultats.

8. RENSEIGNEZ vos futurs projets en sauvegardant les données de votre campagne actuelle dans la plate-forme de gestion



ACHAT D'UNE PUBLICITÉ EN TEMPS RÉEL

0

SECONDE

0,04 seconde

Dès que l'utilisateur X clique sur une URL, le contenu de l'éditeur commence à se télécharger dans le navigateur.

0,08 seconde

L'éditeur demande à son serveur publicitaire s'il y a une annonce disponible à afficher. S'il n'y en a pas, il fait appel à un Ad Exchange.

0,10 seconde

L'Ad Exchange diffuse la requête d'annonce publicitaire à plusieurs plates-formes de gestion de la demande (DSP), la technologie d'achat média.

0,12 seconde

L'Ad Exchange envoie à chaque DSP le profil anonyme de l'utilisateur X, la catégorie du site Internet, et les informations de sécurité de la page.

0,125 seconde

Chaque DSP intègre les règles de ciblage et de budgétisation de l'annonceur et applique les données de third-party.

0,13 seconde

Chaque algorithme de DSP évalue et calcule l'enchère optimale à soumettre à l'annonceur.

0,14 seconde

Chaque DSP soumet une offre à la requête de l'Ad Exchange.

0,18 seconde

L'Ad Exchange effectue alors une seconde enchère et sélectionne l'offre gagnante en fonction des réponses des DSP.

0,19 seconde

L'Ad Exchange envoie le tarif et l'annonce de l'offre gagnante au serveur publicitaire de l'éditeur.

0,23 seconde

Le serveur publicitaire de l'éditeur indique au navigateur

0,31 seconde

Le serveur publicitaire de l'annonceur envoie

0,36 seconde

Le navigateur affiche la page web en intégrant l'annonce gagnante et informe le DSP gagnant que

0,36

SECONDE



Avec 600 sociétés adhérentes, dont l'intégralité du CAC 40 et du SBF 120 et plus de 110 000 professionnels, l'**EBG** constitue le principal think-tank français sur l'économie digitale.

L'**EBG** a pour vocation d'animer un réseau de décideurs, en suscitant des échanges permettant aux cadres dirigeants de se rencontrer et de partager bonnes pratiques et retours d'expérience.

Plus de 150 événements et 5 à 6 ouvrages sont réalisés chaque année, permettant de fédérer des décideurs d'entreprises issus de tous les métiers : Directeurs Marketing, Directeurs Digital, Directeurs Achats, DSI, DRH, DG etc.

Le Conseil d'Administration de l'EBG se compose des personnalités suivantes :

Stéphane Richard, CEO d'Orange – actuel Président de l'EBG

Jean-Bernard Levy, PDG d'EDF

Steve Ballmer, ex-CEO de Microsoft

François-Henri Pinault, Président de Kering

Pierre Louette, Directeur Général Adjoint d'Orange

Patrick Le Lay, Ancien PDG de TF1

Grégoire Olivier, Directeur zone Asie de PSA Peugeot-Citroën

Didier Quillot, Administrateur du fonds 21 Centrale Partners

Sir Martin Sorrell, Président de WPP

Jean-Daniel Tordjman, Ambassadeur, Inspecteur Général des Finances

Wu Janmin, Président de l'Institut de la Diplomatie de Beijing, Président du Bureau International des Expositions

Philippe Rodriguez, Trésorier

Pierre Reboul, Secrétaire Général

LE PÔLE ÉTUDES DE L'EBG

L'EBG édite quatre collections d'ouvrages uniques en leur genre, permettant de recueillir les témoignages les plus pointus et les visions de nos adhérents sur des sujets d'actualité.

• Les Référentiels :

- étude de grande ampleur sur l'évolution d'un métier, d'un secteur, ou une grande mutation des organisations
- 100 interviews de Directeurs de grands groupes,
- 200 pages d'analyses, cas concrets et citations.

Titres parus : *Référentiels des Directeurs Achats*, *Référentiels des Directeurs Marketing*, *Référentiels des DSI*, *Référentiel de la Transformation Digitale*...

• Les Livres Blancs

- étude sur un sujet innovant (Data Visualization, Cloud etc.)
- 30 interviews de Décideurs qui portent un projet lié à la thématique
- entre 100 et 150 pages d'analyses, cas concrets et citations

Titres parus : *Cloud et nouveaux usages de l'IT*, *Data Visualization*, *Big Data*, *Marketing comportemental*, *Internet des Objets*, *Encyclopédie des Big Data*...


• Les Baromètres

- étude quantitative menée auprès de toute la communauté EBG pertinente
- entre 500 et 1000 répondants par étude
- 20 à 30 pages d'analyses, de tableaux et graphiques

Titres parus : *Performance du Marketing Digital*, *État des lieux du Programmatique en France*, *L'impact du digital dans la performance marketing et commerciale*

• Internet Marketing

- 70 décryptages de campagnes marketing
- 10 000 exemplaires diffusés
- 500 pages de techniques et méthodes



**Pour plus d'informations
sur les événements
ou le pôle études de l'ebg**



Arthur Haimovici

Responsable du Pôle Études / Pôle BtoB

01 48 01 65 61

arthur@ebg.net



Ligia Rodrigues

Chargée de Projets du Pôle Études

01 48 00 00 38

ligia.rodrigues@ebg.net

L'AUTEUR



Clément Imbert

Diplômé du CFJ,
et ancien collaborateur de
l'association des journalistes
économiques et financiers,

Clément Imbert est journaliste freelance
et collabore régulièrement aux titres
du groupe Prisma Media.

Imprimé en France
par Aubin Imprimeur, 86 240 Ligugé

Conception graphique/maquette :
Thierry Badin : www.hite.fr

Copyright © 2016 EBG-Elenbi – 55 – IBM – PwC – Turn

Tous droits réservés. Cet ouvrage ne peut en aucune manière être reproduit en tout ou partie, sous quelque forme que ce soit ou encore par des moyens mécaniques ou électroniques, y compris le stockage de données et leur retransmission par voie informatique sans autorisation des éditeurs, EBG-Elenbi, 55, IBM, PwC, Turn.

La citation des marques est faite sans aucun but publicitaire. Les erreurs ou les omissions involontaires qui auraient pu subsister dans cet ouvrage malgré les soins et les contrôles de l'EBG-Elenbi, 55, IBM, PwC et Turn ne sauraient engager leur responsabilité.

EBG-Elenbi – 55 – IBM – PwC – Turn

